

企业 AI 稳定产出手册

从最小闭环到企业运行系统：面向业务、交付、治理与培训的可复现
AI 工作方法

Jace 著

betta-labs

2026 年 8 月 · v2.0.0

目录

- 自序 1
- 第 1 章 企业 AI 为什么难以稳定产出 3
- 第 2 章 自诊断：定位你的真实问题 6
- 第 3 章 认知校准：AI 的真实能力边界 11
- 第 4 章 从单次生成到可复现工作流 16
- 第 5 章 数据、知识与上下文：稳定产出与 Agent 协作的运行底座 21
- 第 6 章 场景落地：最小闭环设计 29
- 第 7 章 员工工作方法：人机协作的日常实践 33
- 第 8 章 从 1 到 N：多场景扩展与优先级管理 40
- 第 9 章 Agent 与自动化：决策框架与治理要点 47
- 第 10 章 能力专题：RAG、Agentic retrieval、记忆、微调与多模态的适用判断 55
- 第 11 章 价值评估与评测体系：如何算清 AI 的账 62
- 第 12 章 让结果长期可靠：评测、治理与组织协同 70
- 第 13 章 人机协同与组织生产方式：从对话辅助到目标受托 76
- 第 14 章 AI 依赖、韧性与运营准备度 82
- 第 15 章 安全与合规：企业 AI 不可避免的问题 87
- 第 16 章 公开案例、教学情景与完整案例集 94
- 后记 从个人提效到企业级稳定产出 102
- 附录 A 可直接复用的清单与模板 103
- 附录 B 常用指标与评测方法 160
- 附录 C 模型与工具核验指南 167
- 附录 D 来源、公开案例与事实维护规范 171
- 附录 E 关于作者与进一步交流 177
- 附录 F 术语表 178
- 附录 G AI Failure Casebook（故障与失败案例集） 182

自序

一个系统如果输出不稳定、不可验证，或无法在组织中持续、可靠地运行，它对企业的实际价值就需要重新评估。反过来，某个 AI 工具即使在单次演示中表现出色，若不能融入日常流程、经受变更并在异常时安全降级，其价值也不应只用演示效果衡量。

近年的企业 AI 实践呈现出一个常见张力：模型与工具能力持续变化，个人层面的写作、整理、分析与编程辅助更加容易获得；但要把这些局部改进转化为可复现、可验证、可治理的组织结果，仍需要补齐流程、数据、责任、评测和运营机制。不同企业的起点、数据条件、业务风险和技术环境并不相同，因此本书不以单一成功率、统一工具清单或“最佳模型”给出结论，而是提供一套可以在本组织中验证和调整的方法。

本书的核心问题是：**在明确业务边界、人工责任和风险控制的前提下，如何让 AI 参与的工作产生可复核、可维护的结果。**它关注的不是调用次数，也不是单次输出是否显得聪明，而是一个用例能否被定义、测试、发布、观察、变更、回退、移交和退出。

本书的定位

这不是一本 Prompt 合集，也不是对技术趋势的预测。本书是一份面向企业实践者的工作手册：从能力边界和工作流设计开始，逐步覆盖数据与知识、场景试点、组织协同、价值评估、风险治理、运营韧性与能力移交。各章尽量提供可复用的框架、清单和模板，并将动态模型、工具和服务条件与相对稳定的方法原则分开管理。

本书适合以下读者：

- 在业务、运营、销售、产品、工程或支持岗位中实际使用 AI 的人员；
- 需要定义场景、配置资源、承担业务结果或治理责任的管理者；
- 负责知识、技术、风险、安全、交付或 AI COE 工作的实践者；
- 希望将个人提效转化为组织能力，并愿意用真实证据检验结果的团队。

建议的阅读方式

建议先阅读第 1 至第 6 章，建立从问题诊断、能力边界到最小闭环的共同语言。时间有限时，可按实际任务选择路径：需要校准预期时阅读第 1、2、3 章；需要设计并验证工作流时阅读第 4、5、6 章；需要推动团队协同、治理与交付时阅读第 7 至第 15 章；需要直接开始实践时，配合附录 A、B、C、D 与 evidence/ 目录中的资产使用。

附录中的模板应按组织的业务、数据、行业、合同和监管环境调整。它们用于帮助团队提出必要的问题、留下可复核证据，而不是替代法律、信息安全、隐私、采购、财务或行业专业判断。

关于证据、案例与局限

本书明确区分四类内容：相对稳定的方法原则、需要定期复核的外部动态事实、组织内部运行证据，以及经过去标识化处理的案例。模型、端点、功能、价格、数据处理和服务条件等信息应进入动态事实卡，并附来源、适用范围与核验日期；用例是否有效，应以本组织的 Golden Set、回归、发布、健康、事件和移交记录判断。

书中的模板、已填写示例和案例用于说明方法，不应自动视为任何组织已经实现的生产结论。尤其是 evidence/ 中的 P2 试点证据包，已经明确标出待现场验证项目；在没有受控样本、审核记录、配置证据和业务 Owner 确认前，不应据此扩大范围或宣布验收。

本书仍可能存在未覆盖的行业要求、语境差异和需要更新的内容。欢迎读者依据具体证据提出修订建议；任何动态信息、外部案例或重要数值都应回到附录 D 与事实卡登记册中复核。

版本说明

当前工作版本：v2.0.0。

后续版本将根据已验证的实践记录、读者反馈与动态事实复核结果迭代。

Jace

2026 年 8 月

第 1 章 企业 AI 为什么难以稳定产出

企业使用 AI 时，常会同时出现两种体验：一些个人任务的初稿、整理或查询速度提高了；同一套做法进入多人协作、关键流程或持续运行后，却出现输出波动、审核负担、知识失效、责任不清或难以复用等问题。这两种体验并不矛盾，因为个人效率改善与组织稳定产出衡量的是不同层次的结果。本章不试图用单一比例判断“企业 AI 成功率”，也不把个别企业案例外推为普遍规律。它说明一类常见的结构性问题：当组织只引入工具而未同步定义任务、数据、验证、责任和运行控制时，局部收益未必能转化为可重复的业务结果。

一、个人提效不等于组织稳定产出

个人层面的 AI 使用，通常围绕一项即时任务展开：写邮件、整理会议纪要、准备初稿、转换格式、生成代码建议或辅助检索。使用者可以凭个人经验补足缺失信息、判断输出是否可用，并在结果不理想时自行重试或放弃。

组织层面的用例则需要面对更多条件：输入由谁提供、规则何时更新、错误如何发现、谁有最终决定权、输出是否可以发送或写入、多人能否复现、发生异常时是否能够回退。若这些条件没有被设计出来，某个人的熟练操作通常难以稳定迁移给团队。

维度	个人任务辅助	组织稳定产出
主要目标	完成一次任务，提升个人效率	持续产出可复核、可维护的业务结果
输入与知识	由使用者即时补充和判断	需要明确来源、版本、权限与更新责任
输出处理	使用者自行采用、修改或放弃	需要定义验证、人工确认、发送/写入边界与记录
责任	主要由单一使用者承担	需要业务、知识、技术和风险等角色协同
变更与异常	临时调整或重新尝试	需要回归、发布、Runbook、人工备用与复盘
成功证据	一次输出可用或节省时间	质量、价值、风险、采用和运行证据共同支持阶段决策

因此，本书所说的“稳定产出”并不是要求每次输出完全相同，也不是要求自动化率最大化。它指的是：在已定义的范围内，组织能够解释结果从何而来、如何验证、谁负责、何时暂停，以及怎样在变化或异常后恢复。

二、企业采用的常见起点与相应风险

企业的采用路径不止一种。以下三种起点可以并存；它们不是优劣排序，而是提醒团队识别需要补齐的条件。

起点	常见优势	常见缺口	应优先补齐的机制
自上而下	资源、方向和跨部门协调相对容易获得	容易把工具采购或使用量误当作业务结果	用例立项、业务 Owner、阶段闸门和价值证据

起点	常见优势	常见缺口	应优先补齐的机制
自下而上	更贴近一线任务，容易发现具体痛点	资产分散、数据边界不清、难以复用	Skill/工作流资产、知识责任、风险初筛与组合台账
混合推进	既有资源支持，也有真实任务反馈	如果决策权和接棒责任不清，仍可能形成双重管理	RACI、共创交付、验收与能力移交

工程、运营、客服、销售或其他职能都可能成为先行者，取决于任务结构、数据条件、专业风险和业务 Owner 是否愿意参与。与其预设哪个部门一定领先，不如从低风险、高频、可验证且人工备用可行的用例开始，用实际证据决定下一步。

三、结果难以稳定的四类结构性原因

1. 预期与证据错位

当组织把“模型能力提升”“账号开通”或“单次演示效果”直接视为业务收益时，项目目标容易失焦。管理者可能期待短期节省或规模化，使用者则更关心输出是否可靠、审核是否增加负担、发生错误后由谁处理。若成功标准、停止条件和证据口径没有事先约定，不同角色即使都在投入，也可能对项目状态作出相反判断。

应对方向：先用用例立项卡定义业务问题、当前基线、边界、成功/停止条件与下一决策；再用实际评测和运行记录讨论是否扩大，而非用调用量或宣传性指标替代业务证据。

2. 能力边界与任务风险错位

大模型能够生成、整理、分类和辅助推理，但输出并不天然等于事实、规则或最终决定。输入不完整、知识过期、任务目标模糊、上下文变化、模型或工具版本变化，都可能影响结果。多步骤流程和工具调用还会把错误传递到后续环节。

应对方向：根据结果容错率、信息完整性、可验证性、行动影响和回退能力确定 AI 的参与深度。对外沟通、写入、敏感数据、高影响决策或高自主性用例，应提高人工控制、风险评估、证据和回退要求。第 3、9、14 章分别说明能力边界、Agent 治理和风险控制。

3. 工具引入与流程设计错位

如果只在原有流程上增加“让 AI 生成”这一步，任务拆解、输入准备、验证标准、例外处理和结果沉淀仍然缺失，AI 往往只会加快某个局部环节，而无法减少整体摩擦。有时，额外的审核、格式转换和沟通成本会抵消局部节省。

应对方向：将高频任务逐步封装为 Prompt、Skill、固定工作流或受控 Agent；同时明确输入输出契约、质量 Rubric、人工控制点、异常路径、版本、Owner 和回退方式。是否采用 Agent 应由任务和控制条件决定，而不是由工具功能决定。

4. 一次性试点与持续运营错位

试点完成后，知识会更新，模型、工具和权限会变化，人员也会轮换。若没有 Golden Set、回归报告、发布登记、健康卡、Runbook 和移交机制，团队很难判断质量变化来自何处，也无法在异常时安全暂停、恢复或转人工。

应对方向：把试点看作运营起点，而不是项目终点。用例在扩大前应完成必要的风险初筛、评测、发布、观察和接棒验证；不满足条件时，缩小范围、修复或停止都是合理决策。

四、从“使用工具”转向“经营用例”

企业 AI 落地的基本单位不是模型账号，而是一个有明确业务目的、边界、Owner、控制与证据的用例。围绕每个用例，组织需要持续回答以下问题：

1. 业务问题是否真实存在，当前基线和成功标准是什么？
2. 哪些输入、知识、模型、工具、权限和人员依赖会影响结果？
3. 输出由谁审核、谁决定采用、哪些动作必须禁止或转人工？
4. 发生知识、版本、工具或人员变化时，如何评测、发布、回退和通知？
5. 用例是否持续产生足以支持扩大、维持、修复或退役的证据？

这些问题不会让项目变慢。相反，它们帮助团队在投入更多资源前发现范围、控制和责任上的缺口，并将讨论从“某个工具好不好用”转向“这个用例是否值得、是否可控、是否可以持续运行”。

五、本章小结

企业 AI 难以稳定产出，通常不是由单一模型能力决定，而是由预期、任务、知识、流程、责任和运营控制之间是否匹配决定。个人提效可以成为起点，但只有当组织把这些要素转化为可复核的资产和运行机制时，局部改进才可能形成稳定的业务能力。

下一章将从自诊断开始，帮助团队定位当前最优先需要修复的层面。

第 2 章 自诊断：定位你的真实问题

在开始任何改进行动之前，先回答一个前置问题：**你现在卡在哪一层？**

这一章的目标不是给你更多方法，而是帮你在 30 分钟内定位自己的真实问题所在。原因很简单：企业 AI 使用中最常见的浪费，不是“方法用错了”，而是“用对了方法解决了错误的问题”。

把“知识库过期”误诊为“模型不够聪明”，会导致花钱换更贵的模型，问题依旧；把“任务定义模糊”误诊为“提示词写得不好”，会导致反复上提示词课程，输出仍然不稳定。误诊的成本，远高于没有方法。本章提供四层诊断流程，完成后你会得到一张**个人行动路由表**，告诉你该优先读哪几章、跳过哪几章。

一、第一层：症状识别

先不做分析，只做观察。勾选你在过去一个月内**实际遇到过**的现象（可多选）：

输出质量类

- ☐ A1 输出时好时坏，无法预测，同样的任务不同时间结果差异很大
- ☐ A2 格式经常不对，需要反复手动调整
- ☐ A3 内容看起来合理，但包含事实错误或引用了过期信息
- ☐ A4 关键信息遗漏，重要内容没有出现在输出中
- ☐ A5 把讨论中的建议写成了决议，或把“可能”写成了“确定”

使用状态类

- ☐ B1 刚上线时效果不错，用了几周后越来越差
- ☐ B2 Demo 效果惊艳，但放到真实业务场景后就不行了
- ☐ B3 某个人用效果好，换个人或换个场景就失效
- ☐ B4 用了一段时间后，团队成员悄悄回到了原来的工作方式
- ☐ B5 知道 AI 能帮忙，但不知道每天具体怎么用、用在哪里

组织层面类

- ☐ C1 个人可以用，但无法让整个团队稳定复现
- ☐ C2 有效的提示词和方法停留在个人脑海里，无法沉淀和共享
- ☐ C3 领导问“AI 到底带来了什么价值”，答不上来
- ☐ C4 不同部门各自为政，没有统一的使用标准
- ☐ C5 花了不少钱（工具订阅、培训、人力），但说不清效果

风险与顾虑类

- ☐ D1 不确定哪些数据可以输入 AI，担心数据泄露
- ☐ D2 发现员工在用个人账号处理公司业务（Shadow AI）
- ☐ D3 担心如果 AI 服务停了或涨价，业务会受很大影响
- ☐ D4 感觉员工越来越依赖 AI，自己的判断能力在下降

二、第二层：快速分诊

根据你勾选的症状，对照下表找到**主要问题层面**。通常勾选数量最多的区域对应你的主要瓶颈。

症状组合	问题层面	核心原因
A1、A2、A4 为主	任务定义层	任务描述模糊，输入不完整，输出约束不清晰
A3、B1 为主	数据/知识层	知识库过期、冲突或缺失，数据质量不达标

症状组合	问题层面	核心原因
A5、B2 为主	认知层	对 AI 能力边界理解有偏差，预期与现实错位
B3、C1、C2 为主	工作流程层	有效经验停留在个人，缺少可复现的流程设计
B4、B5 为主	员工方法层	一线员工不知道如何在日常工作中具体协作
C3、C5 为主	评测/ROI 层	缺乏度量机制，无法量化和汇报价值
C4、C1 为主	治理/组织层	缺少统一标准、责任人和协同机制
D3、D4 为主	AI 依赖层	过度依赖带来的韧性风险和技能退化风险
D1、D2 为主	安全/合规层	数据处理和使用边界不清晰

三、第三层：根因深挖

找到主要问题层面后，用对应的诊断问题组精确定位。对每个问题回答“是 / 否 / 不确定”。

诊断组 1：任务定义层

1. 你使用的提示词，是每次临时写的，还是有固定模板？
2. 你能在 30 秒内说清楚这个任务的“输入是什么、输出应该长什么样”吗？
3. 输出不合格时，你能快速判断是提示词问题、输入信息问题还是模型问题吗？
4. 你的提示词中，有没有明确写“禁止做什么”？
5. 每次输出后，你是凭感觉判断好不好，还是对照明确的标准清单？

超过 3 个“否”或“不确定” → 主要瓶颈在任务定义，优先读第 4 章和第 6 章。

诊断组 2：数据/知识层

1. 你的 AI 工作流引用的业务规则文档，是否仍在其声明的有效期内，并能证明它与当前业务规则一致？
2. 如果有人问“这份文档谁负责维护”，你能在 10 秒内说出名字吗？
3. 你的知识库中，是否存在两份文档对同一件事描述不同的情况？
4. 过去一个月内，是否出现过“AI 基于过期信息生成了错误输出”的情况？
5. 你的提示词或上下文中是否塞入了大量背景信息、完整材料或冗余工具返回，且没有按任务、权限和需要做选择、压缩或按需检索？

超过 3 个“否”或“不确定” → 主要瓶颈在数据/知识，优先读第 5 章。

诊断组 3：认知层

1. 你能举出 2 个以上“AI 做不好、不该交给 AI”的具体场景吗？
2. 最近一次 AI 给出错误输出，你是“意外惊讶”还是“在预期内”？
3. 你的团队对 AI 有没有统一的能力预期，还是每个人理解不同？
4. 你有没有为同一任务测试过不同模型，并有数据比较？

5. 你是否清楚所用模型、端点和部署的上下文/工具条件，并已用本组织的长文档、检索或长任务样本验证其实际表现？

超过 3 个“否”或“不确定” → 主要瓶颈在认知，优先读第 3 章。

诊断组 4：工作流层

1. 你们有没有一份团队共享的、有版本号的提示词模板？
2. 有效的使用方法，能否被其他同事直接复制，而不需要你亲自示范？
3. 出现问题时，你能快速找到是哪个环节出了问题吗？
4. 你们有没有明确的“出错后怎么办”的回退路径？
5. 提示词上线前，有没有经过至少 3 次真实任务测试？

超过 3 个“否”或“不确定” → 主要瓶颈在工作流，优先读第 4 章和第 6 章。

诊断组 5：员工方法层

1. 你的团队成员能清楚说出“这类子任务我会交给 AI，那类我自己做”吗？
2. 员工在使用 AI 时，知道什么时候该“停止迭代、接受够用的输出”吗？
3. 员工有没有养成“输出后对照清单检查”的习惯，还是凭感觉判断？
4. 当 AI 给出不确定的输出时，员工知道如何保持独立判断，而不是直接采用吗？
5. 新员工入职后，有没有 AI 协作工作方法的标准培训流程？

超过 3 个“否”或“不确定” → 主要瓶颈在员工方法，优先读第 7 章。

诊断组 6：评测/ROI 层

1. 你能用具体数字回答“引入 AI 后，这个任务的耗时下降了多少”吗？
2. 你们有没有每周记录“一次通过率”和“实际采用率”这两个指标？
3. 你知道你们每月在 AI 工具上花了多少钱，以及它对应产生了多少可量化的价值吗？
4. 当领导问“AI 的效果怎么样”时，你能用数据而不是感受回答吗？
5. 你们有没有在评测中区分“通过了检查”和“真的被业务使用了”这两件事？

超过 3 个“否”或“不确定” → 主要瓶颈在评测，优先读第 11 章。

诊断组 7：治理/组织层

1. 你们有没有明确的人负责维护提示词和检查清单？
2. 业务规则变更后，有没有规定的时限要求更新 AI 工作流？
3. 有没有明确的“谁可以使用、谁有权修改、输出可以用于哪些场景”的规定？
4. 当 AI 输出出现严重问题，有没有预先定义的升级路径和响应时限？
5. 管理层是否能定期看到 AI 使用的效果数据，而不是只听汇报？

超过 3 个“否”或“不确定” → 主要瓶颈在治理，优先读第 12 章。

诊断组 8：AI 依赖层

1. 如果你们用的主要 AI 工具明天停止服务，业务能正常运转吗？
2. 你的核心业务知识（如判断标准、业务规则）是存在内部文档里，还是主要存在 AI 工具的提示词和对话中？
3. 员工是否还保持着独立完成关键任务的能力，没有过度依赖 AI 协助？
4. 你们的工作流是否绑定了单一模型/供应商，切换成本是否过高？
5. 对于关键决策，员工是否仍然会独立思考，而不是直接采纳 AI 的建议？

超过 3 个“否”或“不确定” → 主要瓶颈在依赖与韧性，优先读第 14 章。

四、第四层：输出你的行动路由表

完成上面三层后，填写下面的路由表。这是本章的核心输出。

我的主要问题层面：_____

对应优先阅读章节：_____

我的次要问题层面（如有）：_____

对应次要阅读章节：_____

可以暂缓的章节：_____（与我当前问题关联度低的）

我决定本周开始执行的第一个动作：_____

五、诊断路由速查表

主要问题层面	典型症状	优先读	可暂缓
认知层	期望过高/过低、一次失败就放弃	第 3 章	第 8、9、13 章
任务定义层	输出不稳定、格式混乱、信息遗漏	第 4、6 章	第 9、10、13 章
数据/知识层	越用越差、内容过时、来源冲突	第 5 章	第 9、10 章
工作流层	个人能用但无法复制	第 4、6 章	第 9、13 章
员工方法层	不知道日常怎么协作	第 7 章	第 9、10 章
评测/ROI 层	说不清效果、ROI 答不上来	第 11 章	第 9、10 章
治理/组织层	推不动、无人负责	第 12 章	第 10 章
AI 依赖层	离开 AI 不会做了、切换恐慌	第 14 章	第 9、10 章
安全/合规层	不确定数据能不能给 AI	第 15 章	第 8、9 章

六、给管理者的团队诊断建议

如果你是管理者，希望了解整个团队的 AI 使用瓶颈分布，可以这样操作：

1. 把**第一层症状识别**（A1~D4 共 16 个选项）发给团队所有成员，让每个人独立匿名填写
 2. 汇总后统计各类症状的勾选频率
 3. 勾选率超过 50% 的症状组，就是你们团队当前最需要解决的问题层面
 4. 据此确定下一个季度的 AI 能力建设重点
- 这个方法比“开大会讨论 AI 使用情况”更有效——因为它让问题可量化，而不是停留在感受层面。

七、本章小结

诊断不是目的，行动才是。

完成本章后，你应该有了一张明确的路由表，知道自己该先解决哪一层的问题。接下来，按照路由表直接跳到对应章节，不需要从头顺序阅读。

本书每一章都回答一个具体的决策问题。你可以在解决完主要问题后，再回来做一次诊断，看看次要问题是否浮现或已经自行消解。

如果你不确定从哪里开始：按顺序读第 3 章（认知校准）和第 6 章（最小闭环设计）。这两章对绝大多数处于起步阶段的团队都是最直接有效的。

第 3 章 认知校准：AI 的真实能力边界

在企业实际使用中，产出结果不稳定的起点往往是对 AI 能力边界的误判。有人把它当作可以完全信赖的决策助手，直接采用输出作为最终结论；有人则因一次明显错误而彻底放弃，重新回到纯人工方式。两种极端都会降低使用的持续性与可靠性。

要让 AI 稳定产出，首先需要建立准确的能力边界认知。本章给出相对稳定的判断原则与选型方法；会频繁变化的模型版本、基准、价格、上下文、功能支持、数据处理条件与工具能力，不作为正文的长期结论，而应记录在[模型与工具动态事实卡登记册](#)中，并按附录 D 与登记册中的机制复核。

阅读原则：公开榜单和供应商资料可帮助缩小候选范围，却不能证明某个模型或工具适合你的业务。正式选择必须以你的用例立项卡、数据边界、Golden Set、回归结果和发布条件为依据。

一、应关注的能力与边界，而非“当前最强模型”

不同模型、版本和部署方式的能力会持续变化，但以下判断对企业工作设计更稳定。

1. 文本生成、整理与结构化输出

大模型可用于邮件、报告、会议纪要、摘要、分类、翻译和初稿等工作。效果通常取决于任务目标是否清楚、输入是否完整、输出格式是否明确，以及是否有可执行的验证标准。它们能提高生成和整理速度，但不能替代事实核查与业务判断。

2. 代码与工程辅助

模型可以协助生成代码片段、测试、文档、重构建议和问题排查思路。对结构清晰、可测试、可回退的工程任务，价值通常更容易验证；对安全敏感、性能关键、架构级或生产部署决定，仍应保留适当的人工设计、审查和测试责任。

能力提升不等于验证要求降低。生成更快或候选方案更多，只会使验证、回退和变更控制更重要。

3. 模式识别、语言处理与多模态理解

模型适合从已有材料中提取模式、转换格式、识别类别、进行多语言处理，或对文本、图像、音频等输入做初步理解。对于缺少明确事实依据、跨来源冲突、带有强情境判断或影响个人权益的任务，应把模型结果视为待验证输入，而不是最终结论。

4. 多步骤与工具调用

模型可以在受限条件下规划步骤、调用工具和整合中间结果；同时，错误也可能沿步骤链传播。能否使用多步骤工作流或 Agent，不取决于“某模型是否宣称支持 Agent”，而取决于任务是否已被拆成可验证的 Skill、权限是否最小化、异常能否接管，以及组织是否能够持续评测、审计和回退。第 9 章给出了相应决策框架。

5. 能力事实必须与服务条件一起理解

模型名称本身不是充分的选型信息。同一模型在不同 API、区域、项目配置、工具组合、数据处理安排或版本快照下，可能具有不同的功能、限制、价格、留存或合规条件。任何“支持”“可用”“零留存”“长上下文”之类的结论，都必须带上适用的端点、版本、部署方式、合同或配置前提，以及验证日期。

二、必须正视的固有局限

与能力相对应，当前大模型存在几类无法通过简单提示词完全消除的局限。

- 1.事实性幻觉。模型会生成看似合理、实则错误的内容。它不会可靠地主动标记不确定性，高置信度表达与准确性之间没有稳定对应关系。
- 2.上下文与长期状态的条件性。当前 Agent 可借助更长上下文、检索、工具、压缩摘要、外部记忆和子 Agent 执行较长任务；但任务链条变长后，早期信息仍可能丢失、被压缩、过期或被后续信息覆盖。跨会话“记忆”依赖外部系统、数据边界、写入规则和状态设计，不能被视为天然可靠。
- 3.目标、责任与现实世界状态的错位。模型和 Agent 可以在外部工具、状态与清晰任务定义支持下规划步骤、追踪进度、纠错并完成多约束任务；但它们不拥有业务目标、法律责任、授权边界或对现实后果的独立判断。组织不能把“能够完成步骤”误写为“可以自行承担长期目标 and 责任”。
- 4.非确定性输出。同一提示词在不同时间、参数、模型版本或服务环境下，可能产生不同结果。这对需要高度一致性和可复现的企业流程构成直接挑战。
- 5.对数据与知识质量的强依赖。输入信息过时、冲突或不完整时，输出质量会快速下降。模型无法自行识别企业私有知识的权威性、适用范围或生效日期。
- 6.工具调用与行动的脆弱性。在调用外部系统、执行多步骤操作或处理不可信输入时，错误会沿调用链放大。没有校验、最小权限、状态限制与回退机制，能力越强反而可能扩大影响范围。这些局限不会因模型、上下文窗口或工具能力提升而自动消失；它们是 workflows、风险控制、评测、权限边界和人工责任必须存在的原因。

三、能力边界判断框架

面对具体任务时，可用以下维度判断 AI 的参与深度与人工介入方式。

维度	适合 AI 深度参与	需要严格人工主导
结果容错率	允许一定波动，后续可修正	要求高度准确、不可逆或影响权益
信息完整性	输入清晰、来源可追溯、上下文有限	依赖大量未结构化、冲突或实时变化的信息
可验证性	输出易于人工或规则快速检查	验证成本高、专业门槛高或缺少权威依据
行动影响	仅生成内部草稿或建议	直接发送、写入、交易、分配资源或对外承诺
回退能力	可快速转人工或恢复稳定版本	错误难以补救、影响范围大或恢复成本高

多数企业任务处于中间地带：AI 负责生成与初步处理，人工负责关键校验、决策与最终确认。清晰划分两者责任，是稳定产出的前提。

四、模型与工具选型框架

模型和工具选型不是一次性决策。企业需要的是一套能在版本、价格、功能和供应商变化后重复执行的选择机制，而不是记住某个“当前最佳”名称。

1. 先区分三类证据

证据类型	回答的问题	主要载体	不能替代什么
动态事实	某个版本/功能/服务条件在何时、何范围内被官方声明为可用	事实卡、官方文档、合同或配置证据	不能替代企业自己的业务测试。
内部评测	它在我们的任务、数据边界和质量标准下表现如何	Golden Set、Rubric、回归报告	不能替代安全、法律或采购审查。
运行证据	上线后是否持续带来价值且保持可控	健康卡、发布登记、日志、事件与回退记录	不能替代新版本或新范围的重新评估。

附录 D 与动态事实卡登记册规定如何维护动态事实；附录 A 第 29、31、32 节分别规定如何建立评测集、形成回归结论和受控发布。

2. 选型的六个核心维度

维度	评估什么	如何验证	对稳定产出的影响
任务适配度	在具体任务上的质量、完成度与可解释性	用脱敏的 Golden Set 比较候选方案	同一提示词在不同模型上可能产生不同业务效果。
输出一致性	相同或相近输入下的稳定程度	对关键样本重复测试并比较差异	一致性不足会增加验证与返工负担。
格式与接口契约	是否稳定符合 JSON、表格、字段或工具调用约束	对固定格式、异常输入和边界条件测试	格式不稳会破坏下游自动化与审计。
性能与全成本	响应、吞吐、失败重试、模型费用、验证与维护成本	在业务负载下记录端到端耗时与成本	低单价不等于低总拥有成本。
数据与控制条件	留存、训练使用、区域、访问、日志、权限、工具/端点限制	以当前官方文档、合同与实际项目配置核验	处理条件不匹配时，质量再好也不能进入相应用例。
退出与韧性	是否可导出资产、替换模型、降级或回到人工流程	演练切换、回退和人工接管	单一依赖会提高运营中断与锁定风险。

3. 按任务分层，而不是迷信单一模型

多数企业不需要为所有任务选择同一个模型或工具。可按任务的复杂度、风险、成本、数据条件和验证能力分层使用：对简单转换类任务优先选择满足质量门的低复杂度方案；对常规生成类任务选

择通过内部评测、方便运营的通用方案；对高风险或高约束任务，先提高人工控制、证据和回退能力，再考虑更强的模型或更复杂的编排。
分层策略的价值是让“能力、成本和控制”一起被优化，而不是只比较单次生成效果。

4. 探索界面、正式服务与企业控制面

使用方式	适合场景	最低要求	不适合直接承担的职责
个人或团队探索界面	个人探索、临时任务、验证想法	遵循组织的数据与使用政策；不输入未经批准的数据	正式 workflow、关键知识、需审计或需回退的生产任务。
API 或受控平台	团队 workflow、结构化输出、需要版本和日志的任务	记录端点、版本、项目配置、权限、数据处理条件和成本预算	未经评测和风险审查就自动扩大到高影响范围。
企业网关或平台控制面	多团队共用、需要集中身份、成本、审计、路由与数据控制	最小权限、配置管理、日志、模型切换和退出预案	把网关本身误当成对输出质量或合规的自动保证。

正式使用不等于必须使用某一种技术形态；它要求所选形态能够满足 workflow 合约中定义的版本、权限、数据、日志、回退和责任要求。

5. 版本、工具与服务条件变化的应对

模型提供商和工具平台会更新版本、端点、价格、功能、数据处理方式和弃用计划。每次变化都应先由动态事实卡确认“发生了什么、适用于何处、来源是什么、何时验证”，再判断它是否影响用例立项卡、风险初筛、workflow 合约、Golden Set、回归报告或发布登记。
推荐顺序是：**事实更新** → **影响分析** → **受影响样本回归** → **发布/回退决定** → **健康卡观察** → **更新事实卡与证据索引**。没有验证的“新版本更强”或“新工具更便宜”不应成为正式 workflow 切换依据。

6. 最小选型流程

1. 使用用例立项卡明确业务问题、数据边界、成功/停止条件与 Owner。
2. 用动态事实卡收集候选模型或工具的官方来源、版本、处理条件、权限和退出信息。
3. 对候选方案完成风险初筛；R2/R3 或重大变化时完成 AI 影响评估。
4. 使用 Golden Set 和 Rubric 做内部比较，而不是用公开榜单直接作决定。
5. 将通过方案写入 workflow 或 Agent 合约，记录版本、配置、权限与回退方式。
6. 通过回归报告和发布登记限量上线；以健康卡和真实运行证据决定是否扩大、替换或退役。

五、常见认知偏差及其影响

在企业环境中，几种认知偏差会显著降低结果稳定性。

- **过度信赖**：将模型输出、供应商宣传或公开榜单直接当作最终结论，跳过内部验证。
- **一次失败即放弃**：因单次错误全面否定工具价值，而不是定位任务、知识、配置或控制问题。
- **成本低估**：只比较单价，忽视验证时间、错误修复、工具依赖、维护和组织协调成本。
- **能力外推**：将某个模型或工具在一种任务、版本、区域或配置下的表现，直接推广到不同业务场景。
- **事实与决策混淆**：把“供应商说支持某功能”误认为“本组织已经批准且适合使用”。

这些偏差的共同点是，未能把外部动态事实、内部评测和实际运行证据分开管理。

六、本章小结

准确认识 AI 的能力与局限，是稳定产出的起点。模型和工具的动态能力可能扩大可行场景范围，却不会取消幻觉、非确定性、知识时效、权限与行动风险，也不会取代人工责任。

企业应以用例和证据而非模型名作选型：动态事实卡回答“当前外部条件是什么”，内部评测回答“它在我们的任务中是否通过”，运行证据回答“它是否值得继续”。把这三类证据与风险、发布和回退机制连在一起，才能在技术变化中保持稳定产出。

下一章将在此基础上，讨论如何从单次生成走向可复现的工作流设计。

第 4 章 从单次生成到可复现 workflow

在校准了 AI 的能力边界之后，下一步是解决实际使用中最常见的问题：如何让输出从“偶尔可用”变成“可重复、可验证、可迭代”。

多数人的使用方式停留在单次对话——输入一段提示，获得一段结果，满意就采用，不满意就重新生成或放弃。这种方式在简单任务上有效；一旦进入需要多人协作、多步骤执行或长期维护的企业场景，稳定性会迅速下降。

本章讨论如何把单次生成升级为可复现 workflow，并说明 Prompt、Skill、工作流与 Agent 在其中分别承担什么角色。

一、单次生成的局限

单次生成的核心特征是：提示词临时编写，结果即时判断，过程缺乏记录与约束。

它在个人探索、临时灵感、低风险任务上完全够用。但一旦进入企业正式场景，就会暴露出三个问题。

1. **结果波动大，标准无法统一。** 同一任务在不同时间、不同表述下，输出质量差异明显。团队成员之间难以形成一致标准，最终变成“谁生成的谁负责改”。
2. **经验无法沉淀，组织不积累。** 有效的提示方式和判断标准停留在个人脑海中，无法被同事复用，也无法在组织内积累。
3. **错误难以追溯与隔离。** 当输出出现问题，很难快速定位是提示词、输入信息、知识材料、工具调用还是模型本身的原因，修复成本高。

这些局限在个人临时任务中可以接受，在企业正式流程中会直接转化为不稳定。可以把它总结为一句话：**单次生成适合“我自己用得爽”，可复现 workflow 才适合“组织能长期用”。**

二、可复现 workflow 的五个基本要素

一个能够稳定产出的 workflow，通常包含以下五个要素。

1. 明确的任务定义

清楚说明目标、输入要求、输出格式、质量标准与禁区。模糊的任务描述是波动的最大来源。很多团队觉得“大家心知肚明就行”，结果每个人理解都不一样。

场景例子：周会纪要提取。如果只写“帮我整理会议纪要”，输出可能天马行空。如果明确“只记录已达成的决议；每条待办必须包含负责人、具体行动、截止日期；格式固定为表格”，波动会大幅降低。

2. 结构化的提示与约束

把角色、上下文、步骤、输出格式、示例固化下来，而不是每次重新组织语言。约束越清晰，结果越可控。

关键点：不是把提示词写得越长越好，而是把“必须遵守的规则”和“禁止出现的内容”写清楚，并配上 1-2 个正确示例。

3. 固定的验证环节

对输出进行事实检查、逻辑检查、格式检查或业务规则检查。验证标准需要事先定义，并尽量可执行，最好是检查清单。

没有验证环节的 workflow，本质上还是“碰运气”。很多团队把验证完全交给“感觉”，结果错误悄悄流入下游。

4. 版本与记录

对有效的提示词、workflow 步骤、输入输出样本进行版本管理，便于回溯、对比与改进。

没有版本管理，就无法回答“这个提示词到底改了些什么”“上次为什么突然变差了”。企业级使用必须把这个习惯养成。

5. 错误处理与回退机制

预设当输出不符合标准时的处理路径：重新生成、人工接管、降级处理或终止流程。
没有回退机制的工作流，一旦出错就会卡住或把错误放大。真正的稳定，是提前想好“出问题了怎么办”。
这五要素共同构成可复现的基础。缺少其中任何一项，稳定性都会受到影响。

从“五要素”到 workflow 合约

当一个流程进入跨人协作、持续维护或正式业务使用阶段，团队不应只保存提示词、检查清单和零散说明，而应将上述五要素连同业务目标、适用边界、责任、依赖、变更、发布、回退与记录要求固化为一份 **workflow 合约 (Workflow Contract)**。它是面向整个流程的运行说明书：Skill 卡定义单项能力，workflow 合约定义多项能力和人工节点如何协作完成一个业务用例。
workflow 合约不是增加文书负担。对低风险、小范围试点，它可以是一页表；对涉及多个 Skill、外部沟通、工具调用或正式生产流程，它应成为发布、回退、移交和审计的共同依据。附录 A 第 25 节提供用例立项卡，第 26 节提供通用 workflow 合约；两者分别回答“为什么做、在什么边界内做”和“怎样以受控方式运行”。

这五要素缺一不可的反例：

- 只有任务定义和提示词，没有验证 → 输出看起来漂亮，但错误率居高不下。
 - 有验证但没有版本管理 → 改了提示词后无法回退，团队陷入“越改越乱”。
 - 有前面四项，但没有回退机制 → 遇到边界情况就彻底中断，业务受影响。
- 这五要素直接对应企业里最常见的三种失败模式：波动、失传、不可追溯。

三、从 Prompt 到 Skill：把个人经验封装为可运营能力

“Prompt 已经过时，Skill 才是未来”是一种容易误导企业的说法。更准确的关系是：**Prompt 是任务指令组件；Skill 是对一类任务的可运营封装；workflow 负责安排多个步骤；Agent 只在需要动态选择步骤、上下文和工具时才负责有限编排。** 它们不是相互替代的版本关系，而是不同层级的能力单元。上下文资产贯穿所有层级：Prompt 需要当前任务信息，Skill 需要可复用的权威知识与示例，workflow 需要受控的数据传递和状态，Agent 还需要在每一步按权限选择来源、工具结果和必要记忆。

层级	它解决的问题	核心组成	典型例子	最低控制
Prompt	这一轮模型怎样完成任务	角色、目标、规则、格式、少量当前任务信息与示例	“把会议转写整理成纪要”	模板、变量、输出格式检查
Skill	这类任务怎样稳定、可复用地完成	触发条件、输入输出、Prompt、上下文包、知识、工具、验证、回退、Owner、版本	“会议纪要提取与核验”	Skill 卡、上下文包、样本、验证清单、版本、责任人
workflow	多个固定步骤怎样可靠协同	步骤顺序、状态、受控的数据 / 上下文传递、控制点	转写 → 纪要 Skill → 待办校验 → 人工发布	流程图、状态、日志、SOP、workflow 合约

层级	它解决的问题	核心组成	典型例子	最低控制
Agent	在受限范围内怎样动态选择 Skill、来源或工具	目标、状态、上下文来源、工具、记忆、权限、预算、审批、熔断	在只读系统中调查异常工单并形成建议	上下文/动作白名单、最小权限、人工审批、熔断、审计

1. Prompt：仍然必要，但不应是唯一资产

提示词负责把单个模型调用的目标、规则和输出形式表达清楚。它仍然是稳定产出的组成部分，但企业不应把一段“神奇提示词”当成完整解决方案。

正式使用的 Prompt 应作为 Skill 的一个受控组件保存，而不是散落在个人聊天记录、笔记软件或即时通信群中。Prompt 改动可能影响质量、成本和风险，因此也需要版本、样本验证和回退。Prompt 不是全部上下文：其外部资料、检索规则、工具结果和记忆同样需要在第 5 章定义来源、范围、权限与失效条件。

2. Skill：企业应重点沉淀的最小能力单元

本书所说的 Skill，不是某个平台专有的功能名称，也不是一段更长的提示词。它是针对一类重复业务任务的、可以被发现、调用、测试、版本化、授权、观测和退役的能力包。

一个可进入团队正式使用范围的 Skill，至少应说明以下内容：

- **业务目的与适用边界：**它解决什么问题；什么情况不得使用。
- **触发条件与输入输出契约：**何时启动；需要什么输入；输出给谁、以何种格式交付。
- **受控组件：**所用 Prompt、上下文包、知识材料、工具、模型或规则。
- **质量与验证：**什么是合格输出；由规则、人工或系统如何验证。
- **人工控制与回退：**谁在什么节点审核；失败、超时、信息缺失或规则冲突时怎么办。
- **责任与版本：**业务 Owner、知识 Owner、修改权限人、当前版本和变更记录。
- **运行指标：**通过率、采用率、总耗时、失败类型、成本或其他场景特定指标。

附录 A 第 11 节提供可直接复制的 Skill 卡模板；第 25、26 节分别提供用例立项卡和工作流合约。建议先用立项卡确认业务问题与边界，再把已经跑通的提示词和检查清单整理成 1-2 个 Skill；需要多人、多步骤协作时，再用工作流合约连接这些资产，最后才讨论更复杂的自动化。

3. 工作流：让经过验证的 Skill 按固定方式协作

工作流把一个或多个 Skill 与确定性步骤连接起来。对大多数企业场景而言，最稳定的形式不是让模型自由决定全过程，而是把顺序、数据传递和人工控制点预先设计好。

例如，“客户回复交付”工作流可以是：问题分类 → 检索知识 → 客户回复草拟 Skill → 合规检查 Skill → 人工确认 → 发送。即使其中两步使用 AI，流程本身仍应保持清楚、可追踪、可回退。

4. Agent：只负责编排通过认证的能力，不替代控制

Agent 适合处理步骤无法完全预先固定、但又必须根据中间结果选择下一步的任务。它不应从零开始“自由发挥”，而应在受限状态下，调用已经定义清楚、经过验证的 Skill、上下文来源和工具。Agent 每一步可见的信息与可执行的动作都必须被约束：来源白名单、排除来源、工具权限、返回量、记忆和停止条件属于同一控制面。

因此，推荐的企业路径是：**先稳定 Prompt，再封装 Skill；先连接固定工作流，再评估是否真的需要 Agent。**如果一个任务可以用确定性规则、固定工作流或人工决策完成，就不应为了“更智能”而增加 Agent 自主性。第 9 章将进一步说明 Agent 的适用条件、运行合约和治理要求。

四、单次生成、Skill、工作流与 Agent：如何选择

你面对的情况	优先选择	原因
一次性、低风险、个人探索任务	单次 Prompt	成本最低，快速获得思路即可
高频、单类、可验证的任务	Skill	把经验、知识、验证和责任沉淀为可复用能力
多步骤但顺序明确的任务	固定工作流	可控性高，便于追踪和设置人工节点
步骤依赖中间结果，且具备长期治理能力	受限 Agent	仅在动态编排确有额外价值时使用

这个选择顺序体现的是“**复杂度后置**”，而不是技术保守。企业真正需要的不是最高的自主性，而是在满足业务目标的前提下，以最低必要复杂度获得稳定结果。

五、从单次到可运营能力的升级路径

实际操作中，可以按以下六步逐步升级。每一步都有明确产出物，方便团队检查进度。

第一步：固化有效 Prompt

把已经验证过的提示词整理成模板，明确必填变量与可选参数。避免每次从零开始编写。

产出物：可直接复制的 Prompt 模板，含变量说明和 1-2 个正确示例。

第二步：定义任务与输出契约

明确触发条件、输入来源、输出格式、质量标准、禁止事项和人工责任。不要等系统完成后再讨论“这个结果到底能不能用”。对于个人探索或最小试点，任务定义足以起步；一旦流程需要共享、多人协作、持续维护或正式使用，就必须升级为工作流合约，并关联对应的用例立项卡。

产出物：任务定义；进入正式试点后，为用例立项卡和工作流合约。

第三步：加入验证与回退

在关键输出后设置检查点。简单任务可用规则校验，复杂任务保留人工确认；同时定义重新生成、补充信息、转人工和终止的条件。

产出物：验证清单和回退说明。

第四步：封装为 Skill

将 Prompt、上下文包、知识、工具、验证、回退、Owner 与版本记录放入同一张 Skill 卡。此时，其他同事应能在不依赖原作者口头解释的情况下使用它。

产出物：Skill 卡 v1、上下文包、成功/失败样本、责任人与修改权限。

第五步：连接为固定工作流并持续评测

把经过验证的 Skill 接入固定顺序的流程，记录通过率、采用率、总耗时和主要失败类型。任何改动都应保留版本并进行必要的回归检查。

产出物：工作流合约、工作流图、周度记录、版本记录和问题升级路径。

第六步：仅在必要时评估 Agent

只有当步骤无法固定、动态选择确实创造额外价值，并且团队具备上下文管理、评测、权限、监控、熔断、人工接管和审计能力时，才考虑让 Agent 编排多个 Skill、来源与工具。

产出物：Agent 运行合约、上下文包、记忆合约、工具/MCP 控制卡、权限矩阵、评测集、熔断与回退 Runbook。

完成以上步骤后，单次生成就转变为可被团队共享、可被重复执行、可被持续改进的工作流和能力资产。

六、常见实施误区

在升级过程中，有几类做法会削弱稳定性：

- 把 Skill 理解为“把提示词写得更长”。正确做法是同时封装边界、输入输出、知识、验证、责任、版本和回退。
- 在没有稳定 Skill 的情况下直接做 Agent。这样会把不稳定的单步能力放大为不稳定的多步系统。
- 提示词不断叠加规则，最终变得冗长且相互冲突，无人敢删改。正确做法是定期做“减法”，只保留真正有效的约束。
- 只关注生成速度，忽略验证成本，导致错误流入下游环节。验证不是额外负担，而是稳定产出的必要成本。
- 把所有步骤都交给模型自动执行，缺少关键节点的人工把关。尤其在高风险或不可逆场景，人工确认必须保留。
- 没有对 Skill 和工作流本身进行效果评估，无法判断改进是否真正有效。没有数据就没有改进，周度简单记录比不做强。

这些问题的共同特征是：把“能跑起来”等同于“能稳定产出”。真正的可复现，需要把控制点前移，并把验证变成流程的一部分。

七、本章小结

单次生成适合探索与临时任务；Skill 适合把高频、可验证任务沉淀为团队可复用能力；固定工作流适合安排多个受控步骤；Agent 只适合在动态编排确有价值且控制条件齐备时使用。

实现升级的关键不是追求更复杂的技术，而是明确任务、固化约束、设置验证、进行版本管理，并预设错误处理路径。先把 Prompt 和 Skill 做稳，再连接工作流，最后才谨慎提高自主性，才能把个人有效经验转化为团队可共享的稳定能力。

下一章将讨论支撑这些工作流、Skill 与 Agent 的运行底座——数据、知识与上下文的管理。

第5章 数据、知识与上下文：稳定产出与 Agent 协作的运行底座

前面章节解决了能力边界、任务定义和工作流设计问题。但再好的 Prompt、Skill 或 Agent，如果每一步拿到的数据、知识和运行上下文本身过期、冲突、越权或无关，输出仍然难以稳定。

对企业而言，**数据是原材料，知识是经确认的规则与事实，上下文则是特定任务、状态与权限下允许进入模型推理的最小必要信息集合**。三者相互关联，但不能混为一谈。把全部文档、聊天历史或工具结果一次性塞给模型，并不等于给了它更好的上下文；这通常只会增加噪音、成本、泄露风险和错误决策的机会。

本章讨论如何把分散的资料、规则、任务事实、运行状态、工具返回和必要记忆，组织为可验证、可追溯、可维护、可回退的运行底座。其适用于固定工作流，也适用于受限 Agent。对于 Agent，推荐使用以下入门理解：

受控 Agent = LLM + 最小必要上下文 + 受控工具 + 任务/状态契约 + 身份权限 + 验证批准 + 可观测性 + 人工接管与回退。

其中，上下文不是提示词的同义词。公开工程实践将其定义为模型每次推理时可用信息的持续策划与维护，范围可包括系统指令、工具定义、外部数据、消息历史和状态；其目标是以尽可能小、但足够高信号的信息集合支撑期望行为。¹

一、从数据质量到上下文质量

1. 为什么“资料正确”仍可能产生错误输出

同一条业务规则即使内容正确，若在错误任务、错误客户范围、错误时间、错误权限或大量无关资料中被调用，仍可能导致错误结果。下表说明数据、知识与上下文分别解决什么问题。

对象	它回答的问题	典型例子	常见失效方式
数据	原始记录是什么？	会议转写、交易记录、表单字段、系统日志	缺失、错位、格式异常、未经批准使用
权威知识	哪些规则或事实可以作为依据？	当前产品政策、审批规则、标准 SOP、已发布合同条款	过期、冲突、无 Owner、没有生效范围
任务上下文	此刻要解决什么，面向谁，在什么边界内？	客户问题类别、会议类型、任务目标、允许输出	目标模糊、对象错配、范围膨胀
运行状态	当前任务已完成什么、还缺什么、处于哪个合法步骤？	已审批/待审批、检索完成、工具超时、待人工确认	状态丢失、重复执行、越过审批节点
工具结果	外部系统在本次调用中返回了什么？	查询结果、代码测试报告、工单详情、库存状态	返回过长、无关、错误、恶意或未经核验

对象	它回答的问题	典型例子	常见失效方式
持久记忆	哪些跨轮次信息可以保留并在后续引用？	已确认的决定、未解决问题、工作笔记、项目偏好	把假设写成事实、过期、跨用户混用、无法删除

核心原则：只有具备明确任务、来源、范围、时效和权限边界的信息，才可以成为正式运行上下文。模型不能仅凭生成机制保证企业私有事实、权限或时效正确；即使接入检索或工具，也仍需通过来源、版本、范围和验证控制来证明结果可用。1 3

2. 上下文质量八项标准

原始数据的完整性、准确性、时效性、一致性和可读性仍然必要。进入正式 Skill、工作流或 Agent 前，还应增加相关性、可定位性、最小必要性和权限适配等检查。

标准	要求	最低验证方式	典型失败信号
相关性	信息与当前任务、对象和决策问题直接相关	说明每类上下文为何进入本次任务	大量背景资料被加载，但无法支持当前决定
权威性	规则和事实来自被批准的来源	标注来源、Owner、版本和生效范围	搜索结果、旧文档或个人笔记被当作正式政策
完整性	支持任务的关键字段、条件和例外没有缺失	对照任务字段与边界清单	有结论但无适用条件、日期或例外处理
时效性	信息在本次使用时仍有效	记录更新时间或生效日期；触发复核	已下架产品、失效价格、过期流程仍被引用
一致性	同一事实或规则未解释冲突	冲突时显示来源并转人工或按优先级处理	多份文档互相矛盾，模型任选其一
可定位性	人工可以追溯到具体来源、片段或工具记录	输出保留来源 ID、链接、版本或证据位置	只能看到“AI 说了什么”，看不到依据
最小必要性	仅提供完成当前任务所需内容	设置字段、文件、返回量或 token 预算	全量知识库、完整会话历史、整库日志被注入
权限适配	上下文的读取、保存和外发均符合数据与角色边界	检查数据分级、访问权限、留存和目的	使用者或 Agent 看到不应访问的客户、人员或商业信息

这些标准不要求每个低风险试点都建立复杂平台。对简单、内部、只生成草稿的 Skill，可以用一页上下文包和人工检查完成；对跨系统、对外沟通、长期运行或有工具动作的 Agent，则应把这些要求固化为可审计的运行控制。

二、企业上下文的六类资产

1. 权威知识、示例与反馈仍是基础

企业知识库仍应以三层结构维护：基础层存放已批准的产品、规则和流程；示例层存放正常、边界和历史失败情形；反馈层记录运行中发现的错误、缺失和修复线索。三层共同服务于 Skill、工作流与 Agent，但它们不是 Agent 可随意访问的“全量资料池”。

知识层	内容	Owner	进入上下文的方式
基础层	产品文档、业务规则、流程规范、术语、政策	知识 Owner	按任务和权限检索权威片段，显示版本与生效范围
示例层	正常输出、边界案例、历史失败与修复案例	Skill/流程 Owner 与使用者	选择少量有代表性的示例，用于说明预期行为与禁止行为
反馈层	错误、遗漏、审核修改、用户问题和事件线索	使用者与运行 Owner	先作为待验证线索；确认后才进入示例层或基础层

知识责任人不必是技术岗位，但必须有权确认规则来源、适用范围和生效日期。未明确 Owner、无来源或已过期的内容，不应作为高影响任务的权威依据。

2. 任务、状态、工具结果和记忆是运行资产

当系统从单次生成发展为多步工作流或 Agent 时，除知识库外还会出现四类运行资产：任务上下文、合法状态、工具结果和持久记忆。它们必须有不同的生命周期。

资产	默认生命周期	可以写入什么	不应承担什么
任务上下文	当前任务结束即失效，除非组织政策另有规定	任务目标、对象范围、用户提供的经批准材料	不能替代长期知识库或个人档案
运行状态	当前工作流或 Agent 运行期间	已完成步骤、待审批事项、异常、重试计数	不能绕过状态机、审批或恢复检查
工具结果	按任务与日志政策保留	查询结果摘要、必要标识、错误与证据位置	不能默认等同于权威事实或永久记忆
持久记忆	仅在明确目的、权限和保留期下存在	已确认决定、可复用工作笔记、明确偏好	不能保存未经确认的推测、敏感原文或跨用户信息

事实、假设和待核验项必须分开记录。例如，Coding Agent 的工作笔记可以记录“测试未通过，待人工确认原因”；但不应把“某模块应由某团队负责”写成永久事实，除非其来源、责任人和适用范围已经确认。

三、构建最小上下文包

1. 上下文包的定义

上下文包（Context Pack）：在特定任务、状态和权限下，允许进入模型推理的最小必要信息集合。它说明“要解决什么、允许看什么、为什么看、看多少、谁负责、何时失效、出错时如何停止”。

上下文包不是一次性的长 Prompt，也不是全部企业资料的压缩版。它是可版本化的运行资产，应与用例立项、Skill 卡、工作流合约、Agent 运行合约和评测记录关联。附录 A 的“上下文包卡”模板可用于正式记录。

字段	必须说明的内容
用途与任务	本次任务要支持的业务问题、对象、输出和不可接受后果
允许来源	权威知识、文件、系统、工具或记忆的白名单，以及来源优先级
排除来源	不应读取、保存、外发或作为依据的内容，例如未批准资料、敏感字段、旧版本
选择逻辑	哪些字段预置；何时按需检索；冲突、空结果或低置信时如何处理
内容预算	文件、字段、返回量、步骤或 token 的上限；必要时采用分页、过滤或摘要
数据与权限	数据分级、读取范围、保存位置、外发限制、使用者与 Agent 权限
版本与 Owner	上下文包版本、知识/工具/记忆版本、业务 Owner、知识 Owner、技术 Owner
证据与失效	来源位置、核验日期、失效条件、回退路径和受影响评测样本

2. 从资料到上下文包的五步法

- 先定义任务，而不是先搜资料。**明确任务对象、输出、决定边界、人工责任和停止条件。
- 建立来源白名单。**列出本任务允许使用的权威知识、工具和记忆；不确定来源只可作为待核验线索。
- 只预置不可缺少的信息。**例如固定规则、输出契约、当前对象标识、必要安全边界和少量规范示例。

- 4. **将其他信息改为按需获取。**通过受控检索或工具按问题、时间、对象和权限逐步加载，而不是预先加载整个库。
- 5. **保留证据并测试失败路径。**测试空结果、冲突规则、过期知识、权限拒绝、工具超时和异常输入时，系统是否停止、转人工或回退。

3. 示例：客户咨询回复的最小上下文包

用途：为授权审核者生成客户咨询回复草稿；不自动发送、不作例外承诺。

预置：回复结构、禁止承诺、转人工条件、当前问题类别、审核要求。

允许知识：知识 Owner 批准且带版本、生效日期和适用范围的规则条目。

按需检索：仅检索当前问题类别、地区、产品和生效期对应的条目。

排除：历史失效规则、未批准补偿口径、完整客户画像、与当前问题无关的内部材料。

工具结果：只返回与问题相关的字段、来源ID和生效日期；空结果或冲突时转人工。

记忆：不保存客户原文或未确认承诺；仅在批准的业务系统按政策保留必要审核记录。

人工控制：审核者查看来源、版本、适用范围和草稿后决定采用、修改、拒绝或转人工。

这个示例说明：最小上下文包既减少噪音，也使审核者能判断“系统为什么这样回答”。对外沟通、高影响决定、敏感数据或工具写入任务，应提高来源、权限、审批和运行证据要求。

四、知识、检索、记忆与工具结果如何配合

企业不应把“放不下就上 RAG”当成唯一升级路径。不同机制解决的是不同问题，可以组合使用。

机制	主要解决的问题	优点	必须控制的风险
Prompt 与固定参考材料	少量稳定规则、格式、角色与输出要求	快速、透明、便于起步	规则堆叠、过期、上下文过长
引用文件或结构化上下文包	当前任务的少量明确资料	来源清楚、易审核	文件版本、权限、范围与最小必要性
RAG	大量文档中的相关权威片段检索	可按任务返回相关内容	检索偏差、过期索引、引用缺失、权限过滤不足
Agentic retrieval	Agent 在受限工具和路径中逐步定位所需资料	适合复杂探索和长任务	搜索死角、无效循环、越权检索、过度加载
工具生成的上下文	获取实时状态、系统记录或确定性计算	及时、可执行、可减少模型猜测	参数错误、返回污染、过长输出、工具可信度与权限
持久记忆与压缩摘要	跨轮次维持经过确认的决定、待办和进度	支撑长任务连续性	错误写入、失效、跨用户混用、不可删除
微调	固化格式、风格或重复行为模式	有助于一致性	不适合承载频繁变化的事实、政策或权限判断

对于多数起步用例，推荐顺序仍是：先用最小上下文包和固定工作流跑通闭环；知识规模、任务动态性或运行时效确实需要时，再逐步增加检索、工具或记忆。RAG、Agentic retrieval 和微调都不是质量保证；它们改变信息进入模型的方式，仍需使用真实任务样本、来源归因、人工审核和回归评测证明其价值。

1. 按需检索优于全量灌入

上下文工程的公开实践建议，在长任务或大规模资料场景中保留轻量索引，通过文件路径、查询、链接或其他引用按需发现内容，而不是预先加载全量对象；这能保持工作记忆聚焦，但需要为 Agent 提供清晰的工具、命名、范围和启发式规则。¹

对企业的最低要求是：检索工具应支持过滤、范围限制、分页或截断；返回内容应包含能支持下一步判断的高信号字段与来源，而非默认返回整库内容。工具职责、参数和错误信息越清楚，Agent 越容易在合法范围内正确使用它。²

2. 记忆与压缩不是无损存档

长时任务可以使用压缩历史、结构化工作笔记或受限子 Agent 等方式保持连续性，但必须明确：什么可以保留、谁可以写入、何时过期、如何纠错、是否跨用户隔离、重新读取时怎样定位原始来源。

情形	可采用的方式	最低控制
长会话接近上下文限制	压缩为带来源的任务摘要	保留关键决定、未解决项、版本和证据位置；不把摘要当作原始事实替代品
多步骤项目推进	结构化工作笔记或任务状态	区分事实、假设、待确认项；限制写入人和读取范围
复杂研究或代码库探索	子 Agent 处理局部探索，返回浓缩结果	隔离子任务上下文；主 Agent 只接收必要结论、来源和不确定项
跨用户服务	默认不共享个人或客户记忆	以身份、租户、数据分级和明确目的隔离；提供删除与失效路径

五、上下文变更、记忆治理与回归

知识变更不是“改完文档就结束”，上下文变更也不是“换了一个检索器或模型就结束”。任何规则、工具、记忆、权限、索引、提示、状态机或选择逻辑的变化，都可能影响已运行的 Skill、工作流或 Agent。

变化类型	例子	最低动作	发布方式
低风险表达优化	修正错别字、统一术语、改进不影响结论的工具描述	记录版本与原因；抽样检查	常规维护窗口
中风险上下文调整	新增示例、优化检索过滤、修改摘要模板、调整工具返回字段	分析受影响任务；回归正常与边界样本；确认来源和权限未变化	限量试运行或由 Owner 确认后发布

变化类型	例子	最低动作	发布方式
高风险规则或动作变化	政策/价格/合同变化、数据范围扩大、新工具/连接器、记忆跨域、写入权限或审批变化	确认权威来源与生效时间；完成风险审查、影响分析、正常/边界/失败样本回归、审批和观察期	先离线回归，再限量发布；保留上一稳定版本与人工回退

任何变更都应回答六个问题：**什么变了？为什么变？影响了哪些上下文包、Skill、工具、记忆和用例？哪些样本必须回归？谁批准恢复或扩大？出问题时回退到哪里？**

对规模较小、低风险的内部 Skill，这个过程可以很轻：知识 Owner 更新条目，使用者用代表性样本验证，再记录版本即可。对外沟通、高影响决定、多个团队共用知识、跨系统工具或持久记忆，则必须提高证据、审批和隔离要求。

六、评测上下文，而不只评测最终答案

“检索命中”或“Agent 完成任务”都不足以证明上下文设计可用。正式评测应同时检查：系统是否取得了正确的信息、是否在正确范围内使用、是否清楚展示依据、是否在不确定时停止，以及最终任务是否满足业务标准。

评测层	要验证的问题	代表性样本或证据
来源与权限	是否只读取允许来源；是否拒绝越权或敏感材料	权限拒绝、跨区域、跨客户、未批准文件
检索与选择	是否检索到正确规则、范围和版本；是否避免无关内容	正常、冲突、过期、信息不足、相近但不适用问题
工具与返回	工具参数、返回量、错误处理和来源是否适合任务	空结果、超时、长返回、参数错误、恶意或错误返回
记忆与状态	是否区分已确认事实、假设和待办；是否正确失效或恢复	会话压缩、任务中断、跨用户、规则变更、人工纠正
任务与业务结果	最终输出、行动建议或受控动作是否满足 Rubric	真实去标识化历史任务、边界、失败与异常样本
人工接管与回退	失败时是否能看懂依据、停止并恢复业务	审批拒绝、知识冲突、工具不可用、预算或步骤限制触发

建议在健康卡和回归报告中按用例记录：来源可定位率、过期/冲突上下文拦截情况、权限拒绝是否正确、工具错误率、上下文或工具成本、人工接管率、以及最终任务质量。指标的阈值应由业务影响、基线和风险边界确定，不应复制其他团队的固定数字。

七、本章行动清单

员工与知识 Owner

- [] 为正在使用的一个 Skill 写出最小上下文包：任务、允许来源、排除来源、版本、生效范围、人工责任和停止条件。
- [] 检查当前资料中是否存在无 Owner、无日期、无来源、互相冲突或不应被当前任务读取的内容。

- [] 将运行中发现的问题先标记为“待核验线索”，不要直接写入权威知识或持久记忆。
- [] 对需要外发、写入或高影响判断的任务，确保审核者能够看到来源、范围和不确定项。

业务 Owner、技术 Owner 与 Agent 负责人

- [] 为每个正式 Agent 确定上下文来源白名单、工具白名单、记忆策略、读取/写入权限和失效条件。
- [] 将知识、检索、工具、状态或记忆变更接入影响分析、Golden Set、回归报告和发布登记。
- [] 用空结果、过期资料、冲突规则、越权请求、工具超时和人工审批拒绝测试停止与回退。
- [] 在附录 A 中建立上下文包、记忆和工具控制记录；将已验证资产交给可接棒的 Owner 维护。

八、本章小结

数据、知识与上下文共同构成企业 AI 稳定产出的运行底座。其质量不只取决于“资料是否正确”，还取决于：当前任务为何需要这些信息、其来源和版本是否可追溯、是否在权限内、是否足够且不过量、能否在变化后回归并在失败时停止。

固定工作流需要可靠上下文，Agent 更需要可靠上下文。推荐的升级顺序是：先准备最小上下文包并跑通受控 Skill；再把知识、检索和工具作为可验证组件接入固定工作流；只有在动态编排确有价值、并且状态、权限、评测、接管和审计条件齐备时，才让 Agent 在有限范围内使用这些资产。下一章将把这一运行底座转化为可执行的最小闭环设计。

参考资料

第 6 章 场景落地：最小闭环设计

前面章节解决了认知边界、工作流设计和数据基础问题。从本章开始，进入真正可执行的落地环节。目标只有一个：选择一个边界清楚的小场景，在一个足以获得代表性证据的短周期内跑通可重复、可验证的最小闭环，并产生可观察的结果。

本章的“最小”指范围最小，而不是跳过业务目标、责任、风险和回退。任何准备进入团队试点的场景，都应先填写附录 A 第 25 节的用例立项卡；当流程开始跨人协作、持续维护或进入正式使用时，再补齐附录 A 第 26 节的工作流合约。这样，后续的 Skill、评测、知识变更、发布和组合决策才能关联到同一个业务用例。

一、选择最小闭环场景的标准

先用以下标准快速筛选场景，避免一开始就做大而全的项目。必须同时满足的条件：

1. 任务以足够频率重复出现，能够积累同口径样本
2. 输入信息相对完整、可获取，且数据边界能够确认
3. 输出有明确的业务质量标准，能够由规则或人工验证
4. 当前人工流程存在可观察的整理、核验、等待或返工负担
5. 失败成本可控，能够人工纠正、停止或回退，不会产生不可接受后果

优先推荐的起步场景：

- 会议纪要整理+待办提取
- 客户/内部邮件的标准回复起草
- 周报/日报初稿生成
- 简单数据的结构化汇总与异常标记
- 产品/政策问答的标准答案生成（基于已有文档）

暂缓的场景：

- 需要跨多个系统实时写回的操作
- 涉及最终决策或对外正式承诺的内容
- 输入信息严重缺失或高度依赖个人经验判断的任务

二、最小闭环的完整操作步骤

按以下 7 步执行。第一轮周期和样本量应由任务频率、错误后果、审核能力和风险边界确定；关键在于获得足以支持下一次阶段决策的证据，而不是追求固定天数。

前置动作：填写用例立项卡（30-45 分钟）

在写提示词或搭建工具前，先使用附录 A 第 25 节确认：你要解决的业务问题是什么、当前基线在哪里、谁是业务 Owner、哪些结果不可接受、人工保留哪些判断、试点结束后要依据什么证据继续或停止。立项卡不能替代后续设计，但能防止团队“先做技术，再寻找价值”。

若用例涉及对外沟通、敏感数据、关键决策、写入操作或不可逆后果，应在进入测试前同步完成第 15 章的数据分级和附录 A 第 34 节的风险初筛；按 R2/R3 处理或发生重大变化的用例，还应完成附录 A 第 35 节的 AI 影响评估。无法明确边界、Owner、人工回退或控制要求时，缩小场景或暂缓试点。

步骤 1：明确任务定义和工作流边界（30 分钟）

用下面的模板写清楚：任务名称：触发条件：（什么情况下启动这个任务）输入：（需要哪些信息，从哪里获取）输出：（最终要交付什么，格式要求）质量标准：（怎样算合格）当前人工耗时：（平均每次多少分钟）目标：（希望降到多少分钟，或提升什么指标）示例：

- 任务名称：周会会议纪要与待办提取

- 触发条件：周会结束后
- 输入：会议录音转写文本或完整聊天记录
- 输出：结构化纪要+待办列表（负责人、截止日期）
- 质量标准：关键决议无遗漏、待办可执行、格式统一
- 当前人工耗时：35-50 分钟
- 目标：控制在 12 分钟以内（含人工检查）

任务定义应与立项卡保持一致：范围、禁止事项、目标用户和人工控制点不得在两份资产中相互矛盾。进入多人试点前，将该定义扩展到附录 A 第 26 节的工作流合约，明确步骤、执行者、验证和异常处理。

步骤 2：准备最小上下文包与代表性样本

不要先收集“尽可能多”的资料。先为当前任务建立最小上下文包：它应说明本次任务的目标、允许使用的来源、排除内容、知识版本、数据边界、人工责任和停止条件。上下文包模板见附录 A 的相关资产；第 5 章说明了为何资料正确仍不等于上下文正确。

最小资产	要求	现场检查问题
任务事实	当前对象、范围、输入字段、输出要求和不可接受后果	这是否足以支持当前任务，而不是泛泛背景？
权威知识	已批准的规则、版本、生效日期、适用范围和来源	它是否仍有效，是否适用于当前对象/地区/产品？
示例与反例	少量正常、边界和历史失败样本	是否同时说明“应如何做”与“绝不能怎样做”？
排除与权限	不应读取、保存、外发或作为依据的内容	是否存在敏感、过期、无 Owner 或超出目的的资料？
回退与 Owner	信息不足、冲突、过期或异常时的人工路径	谁确认来源，谁审核输出，谁有权停止？

若需要检索或工具调用，第一轮应只允许少量、职责清楚且可追溯的来源或工具；空结果、冲突结果、权限拒绝或超时必须转人工或停止，而不是让模型猜测。

步骤 3：固化提示词模板

使用固定结构，不要每次重新写。推荐模板如下：

角色：你是[具体角色]，负责[具体任务]。

任务目标：

[用一句话说明要完成什么，以及不得替代的人工判断]

输入信息：

[在这里粘贴或描述经批准的输入；标注知识版本、来源或适用范围]

必须遵守的规则：

- [规则 1]

- [规则 2]

- [规则 3]

信息不足、来源冲突、超出范围或不定时：

[说明应询问、标记待确认、转人工或停止]

输出格式：

[明确结构，优先使用可审核的 Markdown 或 JSON]

参考示例：

[放入少量正常或边界示例]

把这个模板保存为文件，后续只替换“输入信息”部分。

步骤 4：设置验证检查清单

每次输出后，必须按清单检查，不要凭感觉判断。示例检查清单（会议纪要场景）：

- [] 所有明确决议都已记录
- [] 待办包含负责人
- [] 待办包含可执行的行动描述
- [] 没有把讨论中的建议误写成决议
- [] 格式与模板一致
- [] 无明显事实错误

只有全部勾选通过，才进入使用环节。任何一项不通过，就返回修改或人工重做。

步骤 5：执行第一轮受控测试

使用少量具有代表性的真实或经批准的去标识化任务测试，至少覆盖正常、边界、信息不足或历史失败等情形。记录以下数据：

次数	生成耗时	人工检查耗时	是否通过验证	主要问题	最终是否采用
1	2	...			

步骤 6：根据测试结果快速迭代

重点检查并优先修复以下问题：

1. 任务定义、禁止事项或人工责任不清晰
2. 上下文包中的来源、版本、适用范围、权限或排除条件缺失
3. Prompt、检查清单或工具/检索返回无法支持审核
4. 输入信息不足、冲突、过期或无 Owner

每次变更应记录原因、受影响资产和需要回归的样本。低风险改动可以小范围复测；涉及规则、数据范围、工具、权限或对外行为的变更，应按第 5 章和附录 A 的影响分析、回归和发布资产处理。

步骤 7：固化并小范围共享

当试点样本已覆盖预定场景，质量、人工审核负担、风险控制和回退表现均达到用例立项卡中约定的阶段条件后，做以下固化：

1. 把最终提示词模板、检查清单、示例保存到共享位置。
2. 写一份不超过 1 页的使用说明（什么时候用、怎么用、出问题怎么办）。
3. 为该能力建立或更新 Skill 卡；如存在多个步骤或多人交接，同步填写工作流合约。

- 4. 将用例编号写入 Skill 卡、工作流合约、周度评测和后续变更记录。
- 5. 让至少一名非设计者按同一资产独立完成受控运行、审核和异常处理，记录其反馈与接棒证据。
- 6. 回到用例立项卡，基于质量、采用、效率、风险和维护负担决定进入限量试运行、继续迭代、缩小范围或停止。

三、常见失败点与应对方法

失败现象	可能原因	立即处理方式
输出经常漏关键信息	提示词未明确“必须包含”的字段	在规则中逐条列出必含内容
格式每次都不一样	输出格式约束不够严格	改用 JSON 或固定 Markdown 标题
检查通过但业务上不可用	质量标准定义太宽松	补充业务侧的具体判断条件
越用越不稳定	提示词不断追加规则导致冲突	回退到上一版可用模板，重新精简
同事用不起来	使用说明不清楚或步骤太碎	简化成“复制模板→粘贴输入→检查清单”三步

四、最小闭环成功的判断标准

同时满足以下条件，即可视为第一阶段成功：

- 1. 试点样本覆盖了用例立项卡定义的正常、边界和高风险或历史失败情形
- 2. 输出质量、人工审核负担、处理时效和采用情况已按预定义口径记录
- 3. 关键错误、信息不足、来源冲突、权限异常和工具故障能被识别、停止、转人工或回退
- 4. 至少一名非设计者能依据同一上下文包、Skill 卡和工作流合约独立完成受控运行
- 5. 用例立项卡中定义的价值、风险、维护与停止假设已有相称证据，并已记录下一次阶段决策达到标准后，再考虑扩大场景或增加自动化程度。未达到标准，继续在当前场景迭代，不要急于铺开。

五、本章行动清单

请立即执行：

- 1. 用「选择标准」选出 1 个最小场景，并填写附录 A 第 25 节的用例立项卡。
 - 2. 填写任务定义，明确范围、输入、输出、禁止事项和人工控制点。
 - 3. 建立最小上下文包，选择具有代表性的正常、边界和失败样本；如场景存在明显风险，先完成第 15 章的数据分级和相关审查。
 - 4. 写出第一版提示词模板、来源展示方式和检查清单。
 - 5. 用受控任务测试并记录输入范围、知识/工具版本、审核结果、异常和回退。
 - 6. 达到小范围共享条件后，建立 Skill 卡；涉及多步骤或多人协作时，补齐工作流合约。
- 完成本章行动后，你就拥有了一个可运行、可追溯并可进入下一次阶段决策的最小闭环。这是后续扩大范围和提升稳定性的基础。

第 7 章 员工工作方法：人机协作的日常实践

前面六章建立了框架：认知校准、工作流设计、数据地基、最小闭环。但一个真实的问题始终没有被直接回答：

明天早上打开电脑，我具体怎么和 AI 一起工作？

这一章回答的是微观层面的日常协作问题。它不讲提示词技巧，不讲模型原理，只讲一个普通员工在正常工作日里，如何把 AI 稳定地嵌入自己的工作节奏，既不过度依赖，也不浪费能力。

一、首先明确：哪些子任务该交给 AI，哪些自己做

最常见的误区有两种：把所有任务都扔给 AI，或者把 AI 只用来做最简单的格式转换。两种极端都浪费了 AI 的价值，也都会带来问题。

一个更实用的判断框架是**“任务性质四象限”**：

	规则明确	规则模糊
信息充分	✔ 最适合 AI：格式转换、模板填充、分类打标、结构化摘要	△ 可用 AI 起草，人工判断收尾：方案初稿、报告骨架
信息不足	△ 先补齐经批准的来源或受控查询结果，再由 AI 协助整理、分析或起草	✘ 不能在信息和授权缺失时直接委托：需补齐内部知识、利益判断、关系背景和责任边界；高影响判断仍由人负责

操作建议：在开始一个任务前，花 30 秒判断它属于哪个象限。右下角先补齐信息、来源和授权；右侧两列由人工保留关键判断；左上角可在已批准的工具、数据和行动范围内交由 AI 或受控 Agent 执行。

具体的“该/不该交给 AI”清单

适合交给 AI 的子任务：

- 把会议录音/笔记整理成结构化摘要
- 将已有信息填充进固定模板（周报、汇报格式等）
- 检查一段文本的格式、拼写、语气一致性
- 将一篇长文档压缩为要点列表
- 生成几个方向的初稿供选择
- 对已有内容做语言润色（保留原意，改善表达）
- 将数据转化为文字描述
- 对一组选项按指定标准进行分类

不适合直接交给 AI 的子任务：

- 涉及内部政治、利益权衡或关系判断的建议（即使提供部分背景，也不应把模型输出当作完整组织语境或正式判断）
- 没有已批准实时来源、受控检索或业务系统查询支撑的“当前状态”分析（基础模型内置知识并不等于当前业务事实）
- 最终的对外正式文件（需人工完整审核）
- 涉及个人情感判断的沟通（如处理团队冲突）
- 需要对结果负责的决策（AI 的输出不能作为责任依据）

二、多轮交互的工作节奏

很多人用 AI 的方式是“一次性写一个超长提示词，等待完美输出”，结果往往失望。更有效的方式是**分阶段迭代**：

标准的三段式工作节奏

第一段：定锚（1~2 轮）

目标是让 AI 理解任务的基本框架，不求完美，只求方向对。

示例流程：

1. 给出任务的核心要求和关键约束
2. 看 AI 的第一版输出，判断方向是否正确
3. 如果方向偏了，直接纠正方向（不要在细节上修改）

常见错误：一开始就给出所有细节要求，导致 AI 陷入细节而失去整体结构。

第二段：收紧（2~3 轮）

方向确认后，逐步补充具体要求和细约束。

示例流程：

1. 告诉 AI“结构不错，但第二部分需要更具体，加上数据/案例”
2. 对关键段落给出具体的改写方向
3. 要求 AI 按特定格式或风格调整

常见错误：同时要求改很多地方，导致 AI 顾此失彼。每轮聚焦 1~2 个改进点。

第三段：收尾（1 轮 + 人工检查）

AI 做最后的格式整理、措辞润色，然后人工完成最终审核。

重要原则：第三段的输出不能直接使用，必须经过人工对照验证清单检查。

知道什么时候停

多轮迭代中最容易犯的错误是**迭代过度**。以下信号提示你该停止了：

- 已经修改了 5 轮以上，但每次改动越来越小
- 修改的主要是语气和措辞，而不是实质内容
- 你已经花在改 AI 输出上的时间，超过了自己直接写的时间
- 输出已经“够用”，但你还在追求“完美”

停止标准：输出满足任务的核心要求，通过验证清单，就可以进入下一步。不需要追求完美。

三、“够用”而非“完美”：如何判断输出可以使用

这是一线员工最难掌握的技能之一。判断标准：

三个必须满足的条件：

1. **事实准确：**涉及的具体数据、日期、名称、规则等可以核实，且无明显错误
2. **结构完整：**任务要求的关键部分都有覆盖，没有明显遗漏
3. **符合格式：**输出格式符合使用场景的要求（报告格式、措辞风格等）

三个“不影响使用”的不完美：

1. 部分措辞不是你最理想的风格（可接受，自行微调）
2. 某些论述不够深入（可接受，你自行补充背景）
3. 结构比你预想的稍有不同（可接受，只要逻辑清晰）

判断方法：想象你把这份输出发给一个严格但公平的审核者。他会打回来吗？如果不会，就是“够用”。

四、AI 辅助与纯手工之间的切换策略

不是所有任务都应该用 AI。在以下场景，先用 AI 会反而效率更低：

切换回手工的信号：

- 你已经用 AI 生成了三版，但每次都需要大改（说明这个任务的核心信息 AI 不具备）
- 任务涉及高度内部化的判断（如特定业务背景下的策略决策）
- 对方是需要“感受到你的思考”的重要关系（有些沟通不适合 AI 语气）
- 任务体量很小，用 AI 的来回协调时间超过直接做的时间

切换到 AI 的信号：

- 你在重复做之前做过的事（可以用上次的提示词模板）
- 你面对空白文档不知从哪里开始（AI 给初稿，你来判断和补充）
- 你需要快速了解一个不熟悉的领域（先用 AI 搭框架）
- 你有明确的内容，但需要帮助整理成特定格式

原则： AI 可以在受控范围内起草、整理、检索、分析、调用工具或执行已批准步骤；它不是业务判断、正式授权或责任承担的替代者。

五、保持独立判断力的日常习惯

长期使用 AI 最大的隐性风险，是判断能力的悄悄让渡。以下是防止这种情况的具体习惯：

习惯 1：在看 AI 输出之前，先写下你自己的判断

对于重要任务，在把任务交给 AI 之前，先用 1~2 句话写下你自己对这个问题的判断或预期答案。然后再看 AI 的输出。这会帮你：

- 发现 AI 的输出和你的判断有什么差异
- 保持独立思考的习惯，而不是直接被 AI 的输出锚定

习惯 2：不接受无来源的数字和事实

AI 输出中的具体数字、引用、统计数据，不要不加核实地使用。养成习惯：只要输出中出现数字或事实陈述，就标注“待核实”，在最终使用前验证来源。

习惯 3：问“如果 AI 不存在，我会怎么做这件事”

每隔一段时间，对某类任务用纯手工方式做一次，保持自己的基础能力不退化。这不是否定 AI 的价值，而是确保你对 AI 的依赖是“可以选择的依赖”而非“不得不依赖”。

习惯 4：区分“AI 建议”和“我的决定”

在向他人传达时，明确区分：哪些是 AI 辅助生成的内容，哪些是你的判断和决定。不要把 AI 的输出当成你自己的分析原封不动呈现，需要你自己的判断为其背书。

习惯 5：记录 AI 的失误

每当 AI 给出错误输出，记录下来：什么任务、什么类型的错误、你是怎么发现的。这个习惯会快速帮你建立起对 AI 能力边界的准确认知，比读任何文档都有效。

六、个人层面的质量自检

在把 AI 输出用于正式场合之前，完成以下自检清单：

事实层

- [] 所有具体数字、日期、名称已核实
- [] 引用的政策、规则是当前有效版本
- [] 没有包含我不确定但看起来合理的内容（即“听起来对但没验证”）

逻辑层

- [] 结论和论据之间有合理的支撑关系
- [] 没有出现内部矛盾（前后说法不一致）
- [] 对结论的确定性程度表达是准确的（“可能”不写成“确定”）

场景层

- [] 内容符合这次使用场合的正式程度要求
 - [] 对受众来说语言是合适的
 - [] 如果传播出去，我愿意对内容负责
- 通过这三层自检后，输出才可以进入正式使用环节。

使用 Agent 时的额外检查

Agent 不只是“多轮聊天”。它可能会检索知识、读取系统、保存记忆、调用工具或提出下一步行动。员工不需要理解底层实现，但必须能判断它的任务边界、可见信息和拟执行动作是否仍在授权范围内。

时点	员工必须确认的事项	发现异常时
发起前	是否使用已批准的 Agent/Skill；任务、对象和范围是否清楚；是否可使用当前数据；是否理解该 Agent 不会做什么	缩小任务、改用固定 Skill 或转人工；不要用个人工具绕过正式边界
运行中	Agent 依据的来源、版本和工具结果是否与任务相关；是否出现超范围检索、敏感信息、未知来源、异常工具结果或未预期动作	停止或拒绝当前步骤；保留必要记录；按问题升级路径联系知识、技术或业务 Owner
审批前	是否能看懂其计划、关键依据、未确认项和拟执行动作；是否仍需人类判断或正式授权	修改、拒绝、转人工或终止；不得因“看起来合理”而机械批准
完成后	最终内容、行动记录、来源和版本是否可追溯；是否需要更新失误记录、知识反馈或试点证据	记录问题、更新反馈；对有影响的错误按 Runbook 升级

员工应把“Agent 提出计划”与“我批准执行”视为两个不同动作。只要依据不清、信息过期、权限不确定或影响超出自己的职责，就应停止并转人工。第 5 章说明如何识别最小上下文包；第 9 章和附录 A 第 48–51 节提供运行合约、上下文、记忆、工具和评测资产。

七、不同工作场景的具体协作模式

场景 1：写作类任务（报告、邮件、文案）

推荐流程：

1. 自己先列出核心要点（3~5 个）

2. 交给 AI 生成结构化初稿

3. 人工对照要点检查覆盖完整性

4. 修改关键判断和措辞

5. 对照自检清单做最终确认

注意：给 AI 的信息越具体，初稿质量越高。“写一份季度总结”的效果远不如“写一份 500 字的 Q3 运营总结，重点是用户增长从 5% 提升到 12% 的原因分析”。

场景 2：分析类任务（数据解读、方案评估）

推荐流程：

1. 把原始数据/材料整理好，提供给 AI
2. 让 AI 先做结构化整理（不要直接要结论）
3. 人工审核整理结果是否准确
4. 再让 AI 基于整理结果做初步分析
5. 人工补充内部背景知识，修正分析偏差
6. 形成最终判断（判断必须由人给出）

注意：分析类任务中，AI 负责信息整理和框架搭建，人工负责背景补充和最终判断。两者的分工不能倒置。

场景 3：沟通类任务（对外邮件、客户回复）

推荐流程：

1. 人工先确定沟通立场和核心信息
2. 交给 AI 起草具体措辞
3. 人工检查是否准确传达了立场
4. 调整语气使其符合关系性质
5. 发出前再读一遍，确认代表你自己

注意：沟通类任务的核心是立场和关系，这部分必须由人决定，不能交给 AI。

场景 4：研究类任务（了解新领域、竞品调研）

推荐流程：

1. 用 AI 快速搭建领域框架（主要概念、关键问题）
2. 将 AI 的框架作为问题清单，自行查阅可靠来源
3. 用 AI 辅助整理和归类收集到的信息
4. 人工提炼结论和判断

注意：研究类任务中，AI 输出只是起点，不是终点。AI 给你的知识框架可能是准确的，也可能包含过时或错误的内容，必须用可靠来源核实。

八、从个人习惯到团队能力：培训与变革如何运行

前面的内容主要解决“个人如何稳定协作”。但组织采纳不是个人习惯的简单相加：使用者需要知道如何安全完成任务，知识 Owner 需要维护规则，经理人需要选择场景与保护试点时间，Skill/流程 Owner 需要把经验封装为资产，技术 Owner 需要保障权限与运行控制。把所有人放进同一场通用培训，往往只能带来短暂热度。

1. 按角色学习，而不是按工具学习

建议按角色分配学习目标和实践任务。全员使用者重点练习任务判断、数据边界、人工核验和问题上报；业务 Owner 重点练习场景选择、基线、价值与暂停决策；知识 Owner 重点练习时效、冲突

和变更回归；Skill/流程 Owner 重点练习封装、评测和第三人复现；技术 Owner 重点练习权限、日志、熔断与接管；管理者重点练习资源、风险和组合决策。

完整的分角色能力地图和实践认证记录见附录 A 第 22 节。认证不以听课时长、登录次数或 Token 消耗为依据，而以真实或脱敏任务中的可复核证据为依据：是否遵守边界，是否完成角色关键动作，是否能解释何时停止、转人工或升级。

2. 经理人的核心任务是改变工作方式

团队经理不应把“使用 AI 次数”当作绩效指标，也不应要求所有成员使用同一工具。正确的做法是选择一个低风险、高频、可验证的任务；让成员在真实样本上共同练习；把 Skill、验证与人工确认嵌入 SOP；再根据质量、采用、耗时、失败和知识更新情况，决定扩大、改进或暂停。

特别重要的是，经理人应明确传递一条规则：**及时上报失败、知识过期、异常输出和控制缺口是有价值的改进行为；在不确定时转人工、暂停或拒绝发送，是被支持的专业判断。**隐瞒失败、绕过验证或用未经批准的工具处理敏感工作，则应进入相应的风险处理流程。附录 A 第 23 节提供 30 天启动节奏与经理人每周检查问题。

3. 让反馈产生可见的改进

员工只有在反馈被处理、处理结果被回告时，才会持续采用正式流程。团队应提供低门槛入口，允许成员报告输出错误、知识过期、工具限制、培训困惑、数据担忧或“这个场景根本不适合 AI”的判断。反馈应被分流到知识更新、Skill/流程改进、技术/权限处理、培训、风险升级或用例组合决策，而不是停留在群聊里。

附录 A 第 24 节提供采纳反馈与问题上报模板。每月汇总反馈类型和处理时效，可以帮助团队识别真正的培训盲区、知识缺口和流程障碍。

九、本章行动清单

立刻可以做的（本周）：

- [] 对你最常做的 3 类工作任务，用四象限框架判断哪部分适合 AI
- [] 选其中一类，设计一个三段式工作节奏，试跑一次
- [] 建立一个“AI 失误记录”文档，开始记录你遇到的输出问题
- [] 如团队正在试用 Agent，选择一个低风险任务，按“发起前—运行中—审批前—完成后”四个时点记录一次受控使用过程

建立习惯（一个月内稳定）：

- [] 对重要任务，在看 AI 输出前先写下自己的判断
- [] 所有正式输出在使用前完成三层自检清单；涉及 Agent 时额外完成来源、工具、审批和行动检查
- [] 每月至少用纯手工方式做一次你常用 AI 辅助的任务

团队层面（如果你是团队 Leader）：

- [] 组织一次“工作方法分享”：让用 AI 效果好的成员分享具体的任务拆分和协作节奏
- [] 把本章的“适合/不适合交给 AI 的子任务清单”根据你们的业务场景具体化
- [] 建立团队共享的“AI 失误案例库”，定期回顾
- [] 为使用者、业务 Owner、知识 Owner、上下文/工具 Owner 和 Skill/流程 Owner 分别选择一项真实实践任务，而不是只安排通用培训
- [] 建立一个可追踪的反馈入口，并在下次周度复盘中回告至少一项处理结果
- [] 用附录 A 第 23 节的 30 天节奏，决定一个试点场景是扩大、改进还是暂停

本章小结

稳定的人机协作不依赖天赋，依赖习惯。

关键是在任务开始前花 30 秒判断任务性质，在使用过程中保持三段式节奏，在输出完成后用清单检查，以及在长期使用中保持独立判断力的练习。
这些习惯单独看都很简单，但坚持执行是让个人 AI 使用从“偶尔有用”变成“持续稳定”的核心路径。

第 8 章 从 1 到 N：多场景扩展与优先级管理

第 6 章帮你跑通了第一个最小闭环。恭喜——这是最难的一步。
但接下来很多团队会陷入一个新的困境：第一个场景能稳定运行了，下一步扩展什么？是并行推进多个场景，还是深耕一个？怎么判断哪个场景值得投入？扩展过程中如何避免让已有的稳定闭环被破坏？
这一章回答“从 1 到 N”的问题。

一、为什么“从 1 到 N”比“跑通第 1 个”更难

跑通第一个闭环，成功的关键因素往往是：有一个愿意推动的负责人、场景足够简单、团队处于试点阶段因此容错空间较大。
扩展到多个场景时，情况完全不同：

- **没有了试点的宽容度**：第一个场景是探索，第二第三个场景开始被当成“正式的”，对稳定性要求更高
- **资源开始分散**：同时维护多个工作流，时间和注意力被分摊
- **依赖关系变复杂**：不同场景可能共用知识库、检索器、上下文模板、工具/连接器或记忆策略，一处改动可能影响多处
- **成功经验不能直接复制**：第一个场景的成功路径，在新场景中不一定适用

因此，扩展需要一个有意识的策略，而不是“第一个成了就赶快推第二个”。

二、扩展前的检查：第一个闭环是否真正稳定

在考虑扩展之前，先诚实回答以下问题：

检查项	判断标准	你的情况
一次通过率	连续 4 周，每周 $\geq 80\%$ （建议目标）	
实际采用率	最终被直接或小改后使用的比例 $\geq 70\%$	
维护负担	每周花在维护上的时间 ≤ 2 小时	
知识与上下文责任	有明确的人负责知识、上下文包、提示词、检索或工具描述的更新	
回退能力	出问题时能在 10 分钟内切回人工流程	
文档完整	新人可以凭文档独立操作，不需要原始搭建者讲解	

如果有两项以上不达标：不要扩展，先加固第一个闭环。一个真正稳定的闭环，比三个“勉强能用”的闭环更有价值。

三、场景优先级矩阵：下一个扩展什么

通过了上面的检查，可以开始评估候选场景。用以下三个维度进行评分（各 1~5 分）：

维度 1：业务价值（每周能节省多少时间/提升多少质量）

分数	标准
5	每周节省 5 小时以上，或直接影响收入/客户满意度
4	每周节省 3~5 小时，或显著提升高频工作的质量
3	每周节省 1~3 小时，或在特定场景改善质量
2	节省时间少于 1 小时，或价值难以量化
1	价值主要是便利性，对业务结果影响极小

维度 2：实施难度（任务定义是否清晰，知识是否就绪）

分数	标准
5（难度最低）	任务规则明确，知识材料完整，有现成模板可参考
4	规则基本清晰，知识材料需要小幅整理
3	规则有一定模糊性，需要设计验证机制
2	规则复杂或存在争议，知识材料需要大量准备
1（难度最高）	规则高度依赖人工判断，或需要大量定制化开发

维度 3：知识就绪度（所需知识是否已经整理完毕）

分数	标准
5	现有文档完整、准确、已有负责人
4	文档基本完整，需要小幅补充和整理
3	文档存在但需要较多整理和更新
2	知识主要存在人员脑海中，需要大量提炼
1	知识缺失严重，需要从头建立

优先级计算

综合得分 = 业务价值 × 0.5 + 实施难度 × 0.3 + 知识就绪度 × 0.2

得分越高，越应该优先扩展。

实用规则：

- 得分 ≥ 4：优先扩展，可以立即启动
- 得分 3~4：等当前场景更稳固后启动

- 得分 < 3：暂缓，重新评估是否值得投入

四、扩展节奏控制

同时进行不超过 2 个新场景

这是最容易被忽视的约束。同时推进太多场景的常见后果：

- 每个场景都没有足够的关注度，无法快速发现和解决问题
- 当问题出现时，无法判断是哪个场景的问题，排查困难
- 团队精力分散，维护负担在不知不觉中超出现承受能力

建议节奏：第一个闭环稳定运行满 4 周后，启动第二个。第二个进入稳定期后，再考虑第三个。不要在第二个还在磨合期时就启动第三个。

新旧场景的资源隔离

在新场景的前 3 周，应该将它和已有稳定场景的资源（知识库、负责人时间）做一定程度的隔离：

- 使用独立的知识库或知识库分区，避免新场景的调试影响旧场景
- 新场景有专门的负责人，不要让同一个人同时负责维护旧场景和搭建新场景
- 在新场景稳定前，明确标注它处于“试运行”状态，出错走手工回退

五、跨场景的知识与上下文复用策略

当有多个场景在运行时，知识的复用和隔离是最关键的架构决策。对于 Skill 和 Agent，还必须决定哪些上下文资产可以共享：权威知识、术语、检索器、上下文包模板、工具描述、连接器、记忆策略和评测集都可能成为组合级依赖。共享不等于默认开放；每个用例仍应通过自己的上下文包明确来源、权限、用途、版本和失效条件。

三类知识的处理方式

通用型知识（所有场景共用）

例如：公司基本信息、品牌声音和措辞风格、通用格式规范。

处理方式：放入“共享知识库”，所有场景的提示词直接引用。更新时所有场景同步更新（注意：这也意味着更新错误会影响所有场景，更新前必须充分测试）。

场景专属知识（仅某场景使用）

例如：客服场景的常见问题库、合同场景的审核规则。

处理方式：放入该场景的独立知识库，独立维护，不与其他场景混用。

半共用知识（部分场景共用）

例如：产品知识可能被客服场景和销售场景共用，但两个场景的使用方式不同。

处理方式：在共享知识库中维护核心事实，在各场景的提示词中加入“如何使用这些知识”的具体指令。避免在每个场景的知识库中各自维护一份，否则会出现内容不同步的问题。

共享上下文与工具资产的处理方式

共享上下文资产通常包括：统一术语与实体定义、检索索引、来源分级规则、上下文包模板、工具/MCP 描述、可复用的只读查询、记忆策略和 Golden Set。它们应被当作产品化的公共能力维护，而不是散落在各 Agent 的系统提示中。

资产	可共享的前提	不应共享的情形	最低控制
权威知识与术语	Owner、版本、生效范围和数据边界已明确	不同部门的规则含义、适用对象或保密级别不同	来源登记、版本、访问范围和变更回归
检索器与上下文模板	返回字段、过滤条件、权限与用途可配置	同一检索会暴露跨客户、跨区域或敏感资料	用例级上下文包、过滤、返回量与审计
工具/MCP/连接器	身份、最小权限、动作、错误处理和退出方式已验证	写入、发送、代码执行或外网访问风险不同	工具控制卡、环境隔离、审批、熔断与回退
记忆与工作笔记	明确对象、目的、保留期、隔离与删除规则	跨用户、跨客户或未经确认的推断	记忆合约、来源定位、纠错和失效
评测集与 Rubric	任务质量标准具有可比性	业务决策标准、数据权限或风险后果不同	样本分级、去标识化、用例级补充与版本管理

知识变更的影响评估

每次更新共享知识库时，先做影响评估：

1. 列出所有使用这部分知识、上下文包、检索器、工具/连接器或记忆的用例、Skill、工作流和 Agent。
 2. 根据变化风险选择回归样本：至少覆盖正常、边界和历史失败样本；对外、高影响或高自主性用例还应验证来源选择、转人工、回退、权限、工具异常和记忆行为。
 3. 更新版本号，记录变更内容、受影响资产、回归结果和发布决定。
 4. 如果有任何场景出现无法解释的退化、规则冲突或高影响风险，立即回退或限量运行，单独排查。
- 附录 A 第 15 节提供通用变更影响记录；客户沟通类知识变更可参照附录 A 第 17 节。

六、从多个场景到用例组合运营

当团队同时运行多个 Skill、工作流或 Agent 时，管理对象不再是“几个独立小项目”，而是一个共享资源、共享知识和共享风险的**用例组合**。此时，最危险的做法是只统计“做了多少个 Agent”或“有多少人使用工具”；真正应被经营的是每个用例的业务价值、控制状态、维护负担和下一步决策。

1. 用例组合的六种状态

建议为每个用例标记候选、试点、限量生产、受控生产、规模化或退役状态。状态不是成熟度竞赛，而是告诉组织该用例目前可以承担什么范围的工作、还缺哪些证据、何时需要再次决策。

状态	管理重点	常见误区
候选	问题是否真实、是否值得投入、谁愿意负责	从工具能力或高管灵感倒推场景

状态	管理重点	常见误区
试点	最小闭环能否稳定、失败是否可解释和可回退	Demo 成功一次就宣布上线
限量生产	在受控人群、范围或问题类型中验证真实价值	不记录人工审核、异常和维护成本
受控生产	责任、版本、知识、评测和回退是否持续有效	把“上线”误认为项目结束
规模化	跨团队复用后能否保持质量、共享依赖是否可控	复制 Prompt 却不复制责任和验证机制
退役	价值、风险、成本或替代方案是否仍支持继续运行	将低价值用例长期留在生产环境无人维护

完整进入条件、退出证据和决策卡见附录 A 第 20 节。任何用例都可以因风险、价值或维护问题从较高状态降级、暂停或退役；这不是失败，而是组合管理正常发挥作用。

2. 组合运营的三个最小资产

当正式或试运行用例达到 3 个以上，至少建立以下三项资产：

资产	解决的问题	最低使用方式
用例组合台账	现在运行什么、谁负责、依赖什么、处于什么状态	每个用例一行；阶段、Owner、关键指标和下一决策必须最新
阶段决策记录	为什么扩大、暂停、回退或退役	每次阶段变化、重大事件或高影响变更后更新
月度组合评审	有限资源优先投向哪里；哪些风险和共享依赖需要协调	用数据决定投入、修复、停止或延后，而不是汇报工具使用量
共享上下文与工具登记	哪些来源、检索、工具、连接器、记忆和评测资产被哪些用例复用	记录 Owner、范围、版本、权限、变更影响与退出方式

附录 A 第 18、20、21 节提供可直接复制的台账、决策卡和月度组合评审模板。

3. 规模化前必须问的四个问题

第一，业务价值是否已被验证，而不只是有人觉得好用？第二，知识、上下文包、检索、工具/连接器、记忆、权限、模型或平台变化时，是否知道影响哪些用例并能回归验证？第三，第二个团队能否在不依赖原始搭建者的情况下运行和维护？第四，停止或回退时，业务是否仍有可用的人工或替代流程？

若其中任一问题没有明确答案，就不应把“扩展到更多部门”视为当前优先事项；应先修复用例本身或共享资产的薄弱点。

七、跨部门场景的协调机制

当 AI workflow 扩展到多个部门时，往往会出现：各部门各自为政、重复建设、或者相互冲突的情况。以下是避免这些问题的实用机制：

建立场景登记制度

简单来说：任何部门启动新的 AI 场景时，需要在一个共享的文档中登记：

- 场景名称和负责人
- 使用的知识库、上下文包、检索器、工具/连接器和记忆（是否与其他场景共用）
- 当前状态（试运行/稳定运行）
- 主要的 Prompt、上下文包、工具和模型版本号

这个登记不是为了审批，而是为了让各部门能了解彼此在做什么，避免重复建设。

知识库责任人制度

对于跨部门共用的知识（如产品信息、政策文件），明确指定一个知识责任人（通常来自最依赖这份知识的部门），其他部门如需修改，通过该责任人协调。

季度场景健康检查

每季度做一次跨部门的场景健康检查：

- 各场景的一次通过率和采用率
- 哪些场景在退化，原因是什么
- 哪些知识库、上下文包、检索器、工具/连接器或记忆需要更新、限量或退役
- 下个季度计划新增哪些场景，是否有资源支撑

八、何时该停止扩展、回头加固

扩展不是目的，稳定才是。以下信号提示你应该暂停扩展、回头加固：

警示信号 1：维护时间超过使用时间 如果团队每周花在“修复 AI 问题”上的时间，超过了“使用 AI 节省的时间”，说明系统正在变成负担。

警示信号 2：知识债务积累 提示词越来越长，规则越来越多，新加的规则和旧规则开始冲突。这是知识债务积累的典型表现。需要停下来做一次“提示词重构”（精简、消除冲突、重新测试）。

警示信号 3：一次通过率持续下降 某个场景的一次通过率连续 3 周下降，且找不到明显原因（没有业务规则变化，没有提示词修改）。这通常是知识库过期或模型行为变化的信号，需要深入排查。

警示信号 4：团队失去对系统的掌控感 如果团队成员开始说“不知道为什么 AI 有时候这样输出，有时候那样输出”，说明系统已经超出了团队的可管理范围。不要继续扩展，先让系统变得可理解、可预测。

九、本章行动清单

启动扩展之前：

- [] 完成“第一个闭环是否真正稳定”的 6 项检查，确认全部达标
- [] 列出所有候选场景，用优先级矩阵评分
- [] 确认有足够的人力资源支撑新场景（不能全靠现有负责人兼顾）

扩展过程中：

- [] 同时在运行中的新场景不超过 2 个
- [] 新场景使用独立知识库，3 周稳定后再考虑知识共用

- [] 每周记录新场景的一次通过率，与第一个场景对比

跨部门协调：

- [] 建立场景登记文档，所有部门的 AI 场景统一登记
 - [] 对跨部门共用的知识库、上下文资产和工具/连接器，指定相应 Owner 与变更影响分析责任人
 - [] 计划第一次季度健康检查的时间
-

本章小结

从 1 到 N 的关键不在于扩得多快，而在于每一个新场景都能达到和第一个一样的稳定水平。

优先级矩阵帮你选择下一个扩展什么；节奏控制帮你避免资源分散；知识复用策略帮你减少重复建设；警示信号帮你在系统失控之前及时刹车。

最后要记住：5 个稳定运行的场景，比 15 个勉强能用的场景更有价值。

第 9 章 Agent 与自动化：决策框架与治理要点

随着大模型能力从“单次对话”演进到“工具调用与多步协作”，许多企业和团队开始尝试搭建 Agent（智能体）或复杂的自动化 workflows。

Agent 的能力上限确实很高：它能够理解复杂任务、结合中间结果选择下一步、调用外部工具，并在一定范围内推进任务。但对企业而言，真正的问题不是“能否做出一个 Agent”，而是“**在什么情况下提高自主性，才能带来超过额外风险与运营成本的业务价值**”。

本章不讲“怎么写一个 Agent 系统的代码”，而是站在决策与治理的角度，回答三个问题：

1. 这个业务场景到底需不需要 Agent？
2. 如果采用 Agent，它应如何调用经过验证的 Skill，而不是自由发挥？
3. 如何用上下文、权限、评测、熔断、人工接管和审计，让它保持安全、可控、长期稳定？

受控 Agent 的最小运行观：LLM 负责在限定状态下推理；上下文包决定它此刻允许依据什么；工具与连接器决定它能查询或执行什么；身份、审批、评测、日志和回退决定它的行为能否被企业接受。Agent 不是“模型加工具”的简单叠加，而是一套可运行、可限制、可恢复的控制系统。

一、先区分自动化、工作流、Skill 与 Agent

讨论 Agent 前，先避免一个常见误区：把“能调用大模型的自动化”都叫作 Agent。不同技术形态的控制方式和风险完全不同。

形态	下一步由谁决定	适合解决的问题	企业首选控制
传统自动化	预先写定的规则或流程	数据搬运、固定审批、确定性计算	规则测试、权限控制、异常分支
固定 AI 工作流	预先定义的步骤与状态	有 AI 参与但顺序明确的多步任务	验证节点、状态机、人工审批
Skill	对一类任务的受控能力封装	高频、可验证、可复用的单类任务	输入输出契约、Rubric、版本、Owner、回退
Agent	模型依据状态在受限范围内选择 Skill、上下文或工具	步骤不能完全预先固定的动态任务	上下文/动作白名单、最小权限、预算/步数限制、人工接管、审计

关键原则：Agent 不是更高级的 Prompt，也不应替代稳定的 Skill。企业级 Agent 应被理解为一个受控编排层：它只可以在预先允许的状态、Skill、上下文来源和工具之间选择；它不能自行扩张目标、读取未批准资料、获得新权限、绕开审批或把未经验证的内容直接写入真实世界。

推荐的建设顺序是：**先稳定 Prompt，再封装 Skill；先连接固定工作流，再评估是否需要 Agent。**如果固定规则、确定性自动化或人工决策足以完成任务，就不应为了“更智能”而增加自主性。

二、自主性的代价：为什么 Agent 更容易失控

在传统软件工程中，流程通常由确定规则控制。在单任务 AI 工作流中，虽然输出有波动性，但由于步骤单一，可以通过结构化 Prompt 和单步验证进行拦截。

在 Agent 场景中，系统被允许根据中间结果选择后续动作。自主性带来能力，也带来三类根本挑战。

1. 多步骤稳定性会快速衰减

如果一个流程包含多个必须成功的步骤，并且将每一步视为近似独立，其端到端成功率可粗略理解为各步骤成功率的乘积：

$$\text{整体成功率} \approx P_1 \times P_2 \times P_3 \times \dots \times P_n$$

(数学表达式： $P_{\text{total}} \approx \prod_{i=1}^n P_i$)

例如，五步流程中每一步都达到 90% 的成功率，端到端成功率约为 59%。这个公式不是对所有真实流程的精确预测——步骤之间往往存在相关性，检查与回退也会改变结果——但它清楚说明了一个事实：**单步看起来不错，并不意味着多步自主系统可以直接投入生产。**

因此，企业应同时记录每个关键 Skill 的通过率、Agent 的端到端任务成功率、人工接管率与错误动作率，而不能只展示某一个步骤的平均效果。

2. 错误会沿链路传播并被放大

在单步工作流中，如果输出错误，流程通常会立即中断或由人工修正。但在 Agent 循环中，早期错误可能成为后续决策的输入。例如，Agent 错认客户身份后继续检索、计算、拟稿或调用工具，后续动作会在错误上下文上继续“合理化”。

控制方法不是相信 Agent 会自我纠正，而是缩小它可造成影响的范围。这包括把高风险判断拆回人工、把写操作放在审批之后、把工具调用限制为白名单、把关键事实交给独立验证 Skill 或确定性规则检查。

3. 自主系统存在额外的运行风险

除内容质量外，Agent 还可能发生工具参数错误、权限越界、重复调用、循环、外部数据误导、成本失控、状态丢失或人工接管失败。它的评测必须覆盖这些运行风险，而不是只检查“最后生成的文字好不好”。

三、Agent 适用条件决策树

在决定为某个场景开发 Agent 之前，必须通过以下决策树进行评估。**不要因为技术时髦而选择复杂方案。**

开始评估：该不该用 Agent？

|

├─ 1. 能否用确定性规则、传统自动化或固定工作流完成？

| ├─ 能 —> 优先不用 Agent；选择复杂度更低、可控性更高的方案

| └─ 不能，下一步确实依赖中间结果动态选择 —> 进入下一步

|

├─ 2. 任务是否已被拆成可验证的 Skill？

| ├─ 否 —> 暂缓；先定义输入输出、质量标准、回退和责任人

| └─ 是 —> 进入下一步

|

├─ 3. 能否定义最小上下文包、来源白名单、权限和记忆边界？

| ├─ 否 —> 暂缓；先完成第 5 章的上下文资产与数据边界设计

|

- | └─ 是 —> 进入下一步
- |
- |─ 4. 是否涉及不可逆、高影响或需人类最终判断的动作？
- | └─ 是 —> 可做辅助或受限编排，但必须保留人工审批；不得全自主执行
- | └─ 否 —> 进入下一步
- |
- |─ 5. 团队能否建设并长期维护上下文、权限、评测、监控、熔断、审计与人工接管？
- | └─ 否 —> 暂缓；使用固定工作流或人机协作
- | └─ 是 —> 进入下一步
- |
- |─ 6. 动态编排的收益是否明显大于额外复杂度、成本与风险？
- | └─ 否 —> 使用固定工作流
- | └─ 是 —> 可以从受限 Agent 试运行开始

以下场景**不应采用全自主 Agent**：资金划拨、定价或折扣最终决定、对外正式承诺、医疗或法律结论、直接修改核心数据库、涉及敏感个人信息的外发、重大人事决策，以及其他错误后果不可逆或难以补救的场景。是否允许辅助使用，应由业务、风险、安全和法务按组织实际边界确认。

在评估任何 Agent 前，应先完成附录 A 第 34 节的用例级风险初筛；多数跨系统、可调用工具或具有较高自主性的 Agent 至少应按 R2 受控用例处理，并在试运行、阶段提升或重大变更前完成附录 A 第 35 节的 AI 影响评估。Agent 的自主等级不能高于其风险控制、审批、回退和证据治理能够支持的水平。

四、自主性的五个分级策略

不要把“全自动”当成唯一目标。根据场景风险、Skill 成熟度和治理能力，选择最合适的自主性级别。

级别	自主性程度	人机协作模式	典型形态	上线前提
L1：单步辅助	无自主性	人类手动发起并决定是否采用	单个 Prompt 或 Skill 输出草稿、提取结果	输出可验证；使用者完成基础培训
L2：受控流水线	极低自主性	步骤固定，关键节点有人审核	固定顺序调用多个 Skill	每个关键 Skill 有验证与回退；流程状态明确
L3：建议式编排	中等自主性	Agent 可提出计划、检索和建议，但关键动作须批准	调研、异常调查、复杂信息归纳	允许动作白名单、计划可见、每次工具调用可审查
L4：授权后执行	较高自主性	Agent 可在限定范围内执行低影响动作；写入、发送或关键	低风险内部工单处理、草稿准备、监控分流	端到端评测、权限隔离、预算/步数熔断、人工接管已验证

级别	自主性程度	人机协作模式	典型形态	上线前提
L5: 无人值守运行	完全自主	决定前仍需确认		
		无人工逐次干预, 仅例外处理	低风险内部监控、非生产数据维护、可逆的批处理	仅限低影响、可逆、可快速停止场景; 持续监控与定期复审

企业落地铁律：初始上线通常从 L1 或 L2 开始；只有当底层 Skill 稳定、端到端评测达标、没有未解决的高严重度事件，并且人工接管和回退经过真实演练后，才可申请提高自主性。对外部客户、财务、核心数据或敏感决策场景，禁止使用 L5；L3 或 L4 也应保留与风险相称的人工审批。

五、Agent 运行合约：让“能做什么、不能做什么”可执行

每个进入试运行的 Agent 都应有一份独立的**运行合约（Agent Runtime Contract）**。它不是技术设计文档的替代品，而是业务、技术与治理人员共同确认的最小控制面。

合约要素	必须写清楚的内容	目的
业务目标与边界	要完成什么；不承担什么决策；不可接受的结果	防止目标扩张和误用
自主等级	L1–L5；哪些动作必须人工批准	将口头承诺变成系统限制
可调用 Skill	Skill 名称、版本、输入输出契约、适用状态	Agent 只能编排已验证能力
上下文包与来源	任务上下文、权威知识、检索来源、排除来源、优先级、预算、版本与失效条件	限制错误、过期、无关或越权信息进入推理
可调用工具与连接器	工具/MCP/连接器白名单、允许参数、读写权限、数据范围、返回量、超时	限制破坏面、越权和工具结果污染
持久记忆	可读/可写记忆类别、事实与假设标记、保留期、租户隔离、删除与失效	避免错误记忆、跨用户混用和无控制累积
状态与路径	合法状态、允许转移、终止状态、重试条件	防止自由循环与状态迷失
预算与熔断	最大步骤数、最大工具调用数、最大时间、最大成本、并发上限	控制循环、资源和账单风险

合约要素	必须写清楚的内容	目的
验证与审批	哪些事实要独立检查；哪些动作必须批准	防止错误进入下游或真实世界
人工接管与回退	触发条件、接管人、降级方式、恢复所需证据	确保出错时业务仍可继续
责任与审计	业务 Owner、技术 Owner、知识 Owner、日志保留与复盘责任	保证有人对质量、运行和知识负责

1. 最小权限：先只读，后写入；先窄范围，后扩大

不要给 Agent 无限制的工具访问权限。优先级应是：只读查询优先于写入操作；沙箱优先于生产环境；限定资源范围优先于全库访问；短期凭证优先于长期高权限密钥。即使必须允许写入，也应尽可能采用“生成建议 → 人工确认 → 受控执行”的两阶段设计，并限制可写入的字段、对象和数量。Agent 能够调用某个工具，不等于它可以执行该工具的所有动作。

2. 上下文与连接器：信息面同样需要最小权限

Agent 能够看到什么，与它能够执行什么同样重要。上下文包应设定允许来源、排除来源、选择逻辑、返回量、版本和失效条件；工具、MCP 或其他连接器也应以独立清单记录其数据流、身份、读写范围、返回字段、超时、审计和退出方式。工具描述、参数和返回内容本身会进入模型上下文，因此职责重叠、字段模糊或默认返回过量的工具，会降低行为可预测性并增加成本与错误风险。¹对于长时任务，压缩摘要、工作笔记或持久记忆必须区分“已确认事实”“待核验假设”和“待办”，并能够定位原始来源、按权限隔离、失效和删除。不得把完整会话、全量工具输出或未经确认的推断直接写入长期记忆。

3. 人工看守：看守关键动作，而非机械点击

人工确认不应只是形式上的“一键通过”。系统应向审核者展示：Agent 的目标、所依据的上下文来源与版本、已调用的 Skill 与工具、工具结果摘要、拟执行动作、风险提示和可修改选项。审核者需要有足够信息做判断，也必须能够拒绝、修改、转人工或终止。

4. 状态机与动作白名单：限制轨道，而非要求模型更聪明

不要让 Agent 完全自由地决定下一步做什么。使用状态机或等价的受控流程，预先定义合法状态、状态转换和终止条件。模型只负责在当前状态下选择允许的下一步，而不能自行发明新步骤、接入新工具或扩大权限。

例如，一个异常工单调查 Agent 可以只在“读取工单—调用分类 Skill—检索知识—形成建议—请求审批—结束”之间跳转。遇到信息缺失、工具超时、置信不足或异常输入时，应进入“转人工”或“终止”状态，而不是无限重试。

六、Agent 评测：不仅测答案，还要测行为与恢复

进入试运行前，Agent 需要至少覆盖五类评测。样本数量和阈值应随风险等级、错误成本和业务场景调整，不应用单一数字替代判断。

评测层	要测试什么	代表性样本
上下文层	是否选择正确、有效、可定位且在权限内的来源；是否处理冲突、过期和信息不足	正常、冲突、过期、无来源、跨用户或超范围资料
Skill 层	每个被调用 Skill 的输入输出、事实、格式、边界	正常任务、缺字段、知识冲突、过期信息
任务层	Agent 能否完成端到端目标且不遗漏关键步骤	真实历史任务、长链路任务、边界案例
安全与权限层	是否尝试越权、误用工具、处理不当输入或工具结果	非法写入请求、提示注入、敏感数据、恶意或超长工具返回
运行与恢复层	是否循环、超预算、超时；人工接管是否可用	空结果、工具故障、重复任务、成本阈值触发、审批拒绝

上线前应至少形成一份包含正常、边界、失败和异常输入的评测集；每次修改 Skill、模型、工具、权限、知识或状态逻辑后，都应在受影响样本上重新评测。对高影响场景，评测结果必须由业务 Owner 与相应的风险/安全责任人共同审阅。

必看运行指标

- **端到端任务成功率**：任务真正完成且满足质量标准的比例。
 - **人工接管率与接管成功率**：系统把问题交回人类的频率，以及接管后能否顺利完成。
 - **错误动作率**：发生了不应发生的工具调用、写入尝试、错误路由或越权尝试的比例。
 - **平均步骤数、工具调用数、上下文量与单位任务成本**：识别循环、冗余、无效加载和成本飙升。
 - **来源可定位率与过期/冲突上下文拦截情况**：检查系统是否能说明依据，并在不应继续时停止。
 - **工具错误率与无效返回率**：识别参数、工具描述、返回结构或权限设计问题。
 - **熔断触发率与恢复时间**：判断控制是否在需要时生效。
- 一次通过率仍然重要，但不能单独代表 Agent 的可靠性。

七、Agent 的上线治理检查表

在允许一个 Agent 进入试运行前，必须通过以下检查。

- **[] 业务价值明确**：动态编排相对于固定工作流有可验证的额外价值，而不是为了追赶技术潮流。
- **[] 风险与影响已评估**：已完成用例级风险初筛；R2/R3 或发生重大变化的用例已完成 AI 影响评估，任何例外均有范围、补偿控制和到期日。
- **[] Skill 已就绪**：每个关键任务均已封装为有输入输出、验证、回退、Owner 和版本的 Skill。
- **[] 角色与责任人明确**：指定业务 Owner、技术 Owner、知识 Owner；明确谁有暂停、恢复和变更权限。
- **[] 自主等级受限**：定义 L1-L5 级别，并在系统上实现相应限制，而不只是写在文档里。
- **[] 上下文最小必要且可追溯**：上下文包、来源白名单、排除来源、版本、范围、权限、预算和失效条件均已验证。

- [] **工具、连接器与数据最小权限**：工具/MCP 白名单、参数范围、返回量、数据范围、读写权限、凭证有效期和退出方式均已验证。
 - [] **记忆与状态受控**：可读/可写记忆、事实/假设标记、保留期、隔离、删除和合法状态路径均已定义。
 - [] **状态、预算与熔断已配置**：最大步骤数、调用数、时间、成本、并发和合法状态路径均有硬限制。
 - [] **人工确认节点可用**：关键决策、对外发送、写入或高影响操作前，审核者可以看懂、修改、拒绝和转人工。
 - [] **评测集与回归机制就绪**：已覆盖正常、边界、异常和滥用情形；变更后会重新评测。
 - [] **人工接管与回退经过演练**：API 超时、格式错误、权限拒绝、熔断、审批拒绝等情形下，业务可以平滑降级。
 - [] **审计日志可追溯**：记录任务目标、状态转移、Skill/工具版本、输入输出摘要、审批、异常、熔断和最终结果；日志留存方式符合组织政策。
-

八、如何用一个受控示例开始

如果团队尚未运行过 Agent，不要从“自动处理客户请求”或“直接修改系统”开始。建议先使用附录 A 第 14 节的“异常工单调查助手”作为演练参考：它处于 L3 建议式编排，只读取已授权的内部工单、日志和 Runbook，最终只输出带来源标识的调查建议，由人工决定是否采取行动。

这个示例刻意保留了四个边界：第一，Agent 只编排已定义的 Skill，不直接把一条超级 Prompt 接到工具上；第二，它只读取已批准的工单、日志和 Runbook 片段，并保留来源标识，不加载整库资料或未批准历史；第三，它没有任何写入、发送、代码执行或外网访问权限；第四，空结果、工具超时、权限拒绝、敏感信息、上下文冲突或置信不足都会让它停止并转人工。读者应先按自己的组织数据边界替换上下文包、工具与责任人，再用已关闭的历史工单测试，而不是直接连接生产环境。评测时，除最终摘要质量外，还应使用附录 B 第六节记录人工接管、熔断、错误动作和运行证据完整性。若系统在异常时能够及时、可解释地停止并把工作交回人工，即使它没有“自动解决问题”，也已证明了最关键的控制机制。

九、本章行动清单

本周立即执行：

- [] 盘点团队正在开发或计划开发的 Agent 与复杂自动化项目。
- [] 用本章决策树逐一重评，识别可以降级为固定 workflow、单个 Skill 或传统自动化的项目。
- [] 为所有在研 Agent 指定自主等级，并列出其实际可调用的 Skill、上下文来源、工具/连接器、记忆和写入权限。

下个月内建立：

- [] 为每个试运行 Agent 建立运行合约、上下文包、记忆/工具控制记录、风险初筛/影响评估、评测集、预算/熔断与人工接管 Runbook。
 - [] 把已经稳定的高频任务整理成 Skill 卡，而不是继续堆叠在一个超级提示词中。
 - [] 做一次异常演练：模拟空结果、工具超时、审批拒绝或预算触发，确认系统会停止、通知并安全回退。
-

本章小结

Agent 不是魔法，而是一个在受控上下文、外部工具与状态之间进行有限编排的概率系统。它的价值来自动态任务处理能力，它的风险也来自同一份自主性。

企业应该坚持“能用确定性流程就不用 Agent；能用固定工作流就不增加动态决策；没有稳定 Skill 就不让 Agent 编排；没有最小必要上下文、身份权限、评测、熔断、接管和审计，就不上生产”的原则。把上下文、工具和动作的控制权设计进系统，而不是寄希望于模型临场表现，才是让 Agent 长期可靠的前提。

参考资料

第 10 章 能力专题：RAG、Agentic retrieval、记忆、微调与多模态的适用判断

当一个 AI workflow 稳定运行一段时间后，你可能会遇到“单个 Prompt + 检查清单”开始触及天花板的情况：

- 知识量太大，塞不进提示词
- 希望模型输出固定的语气和风格，但每次效果不稳定
- 任务需要处理图片、语音或视频，不只是文字
- 任务需要依据运行时状态逐步检索资料、调用受控工具或在多轮任务中保留已确认的进度

在进入 RAG、Agentic retrieval、记忆、微调和多模态之前，先确认是否已经把任务封装为第 4 章定义的 Skill。Skill 不是另一种模型技术，而是把 Prompt、上下文、知识、工具、验证、回退、责任和版本组织为可运营能力单元。许多所谓的“提示词能力不足”，实际是输入输出、上下文来源、知识维护、验证或责任边界没有被封装清楚；这时应先完善 Skill 和第 5 章的上下文包，而不是直接引入更重的技术架构。

本章不是技术实现手册，而是**决策指南**：帮你在正确的时机，选择正确的技术路线，避免过度工程化或选型错误。重点不是“哪种技术更先进”，而是“哪种机制能在既定业务、数据、权限和运营边界内提供最小必要上下文”。

一、什么时候不需要这些方案

在讨论 RAG、微调和多模态之前，先确认你是否真的需要它们。以下情况**通常不需要**复杂技术方案：

- 你的知识量仍可被压缩为少量稳定、可核验的任务规则与参考材料，无需引入运行时检索
- 你的任务只需要固定的格式，而不是固定的“风格”或“专业知识”
- 你处理的全是文字，没有图片/语音/视频
- 你还没有跑通第一个最小闭环（先跑通再考虑进阶）
- 你还没有把 Prompt、知识、验证、回退和责任人封装为可复用的 Skill

常见误判：很多团队在跑通第一个场景之前，就急着上 RAG 或微调，结果把本该用“知识材料 + Prompt + 验证”解决的问题，变成了一个复杂的工程项目，反而降低了稳定性。另一种常见误判是把 Skill 当作“更长的提示词”；真正需要补齐的是输入输出契约、知识责任、验证标准、版本和回退。

二、RAG（检索增强生成）：适用判断与选型要点

RAG 是什么

RAG 的核心思路：不把全部知识塞进提示词，而是在生成回答前，先从外部知识库中检索最相关的片段，再把这些片段连同用户问题一起送给模型。

适合 RAG 的信号：

- 知识量大，无法以稳定、可审核的方式在单次调用中提供（例如全量产品规格或合同条款库）
- 知识需要频繁更新（政策每月变、产品每周上新），用微调成本太高
- 不同任务需要的知识片段不同，预先全量输入会带来噪音
- 需要精确的来源可追溯性（可以告诉用户“这个答案来自第 3 号文档第 5 页”）

不适合 RAG 的信号：

- 知识量少且稳定（几百字的规则直接放提示词更简单）
- 你的问题不是“缺知识”，而是“任务定义不清晰”（RAG 解决不了这个问题）
- 检索质量难以保证（如知识库文档质量参差不齐，检索出来的片段反而带来噪音）

RAG 的关键决策点

如果你判断需要 RAG，以下是三个关键选型决策：

决策 1：知识库的分块策略（Chunking）

文档如何切分、保留元数据、建立父子结构或在运行时展开，都会影响检索质量。错误的切分会让关键条件、例外或上下文被拆散，继而影响回答或后续行动。不存在可跨模型、语种、文档类型和检索方式复用的固定字数；应从能够保留业务语义、权限和来源定位的最小结构起步，再用代表性问题验证。

知识类型	初始组织方式	必测问题
长篇文档（合同、报告）	按标题、章节和语义段落保留层级；必要时保留相邻或父级内容	关键定义、例外和限定条件是否仍与结论同时出现？
结构化条款（政策、规章）	按条款编号、生效日期、适用对象和版本组织	回答能否定位到正确条款、版本和适用范围？
产品信息（SKU 详情）	每个产品或配置项保持完整属性与状态	是否混淆相似产品、地区、版本或停售状态？
FAQ	保留问题、答案、来源、生效范围和升级条件	是否把某一问答错误外推到不适用情形？

决策 2：检索质量的验证

RAG 的关键失败模式之一在检索与来源治理：若没有检出关键片段、版本或限定条件，后续模型再强也缺少可靠依据。生成、引用、权限过滤、上下文组装和人工验证同样需要单独评测。

验证方法：准备覆盖正常、边界、历史失败、冲突和过期情形的代表性真实问题，对每个问题检查：

- 在当前模型、检索策略和返回量下，返回的来源是否包含回答这个问题所需的关键信息、版本与限定条件？
- 如果包含：检索没问题，生成可能有问题
- 如果不包含：说明检索层有问题（分块策略、索引方式、查询处理需要调整）

决策 3：知识库的维护机制

RAG 系统的长期可靠性，不取决于技术，取决于知识库是否保持更新。在上线前，必须明确：

- 由谁负责维护知识库？（不能是“大家都负责”）
- 知识更新的触发机制是什么？（业务规则变更时，多久之内必须更新知识库？）
- 有没有与知识变更频率、风险和用例健康信号相称的健康检查？（至少在规则变更、来源失效、异常发现或发布前触发复核）

三、Agentic retrieval、工具生成上下文与持久记忆

RAG 通常在生成前检索一次或少量次数；而当任务需要根据中间结果继续定位资料、查询受控系统或在长任务中维持进度时，团队可能考虑 Agentic retrieval、工具生成上下文或持久记忆。这些机制并不是“更高级的 RAG”，而是在运行中增加了状态、权限、成本和恢复要求。

1. 何时考虑 Agentic retrieval 或工具生成上下文

适合的信号包括：任务的下一步确实依赖上一轮发现；需要根据对象、时间、地区或权限逐步缩小检索范围；必须查询实时但受控的系统状态；或固定工作流会产生大量无效检索。开始前应先确认 Agent 具备第 9 章所述的上下文白名单、工具白名单、状态机、预算、审批和人工接管条件。

不适合的信号包括：任务顺序可以预先定义；查询条件稳定且一次 RAG 即可满足；来源、权限、工具参数或失败处理尚无法说明；或团队不能观察其检索路径和工具行为。此时应保留固定工作流或受控 RAG，而不是让 Agent 自由探索。

机制	解决的问题	最低控制	常见误用
固定 RAG	从大规模权威资料中取得与当前问题相关的片段	索引、来源、权限过滤、版本、检索评测	把检索命中误当作最终结论正确
Agentic retrieval	根据中间发现逐步检索或缩小范围	上下文包、来源路径、状态、步骤/成本限制、停止条件	让 Agent 从全库或外网无边界搜索
工具生成上下文	查询实时记录、计算或业务系统状态	工具控制卡、最小权限、参数/返回量、超时与审批	把工具返回默认当作权威事实，或返回整库内容
持久记忆/压缩	跨轮次保留已确认决定、进度和必要工作笔记	记忆合约、来源、事实/假设区分、隔离、失效与删除	将全量会话或未经确认推断写成长期记忆

公开工程实践建议将上下文视为有限资源：对长任务可采用少量预置规则、按需检索、结构化笔记或压缩摘要等组合，但每次加载仍应有来源、范围与失效控制。¹

2. 选择和验证方法

先从最简单可验证的机制开始。若固定 RAG 能取得正确、有效且可定位的片段，就不要为“看起来更智能”而增加 Agent 循环。若必须增加工具或记忆，则分别使用附录 A 的上下文包、工具/MCP 控制卡、记忆合约和上下文评测记录，测试正常、空结果、冲突、过期、越权、超时、异常返回和人工接管情形。检索、工具或记忆变更都应按第 5 章的影响分析和回归要求处理。

四、微调（Fine-tuning）：适用判断与注意事项

微调是什么

微调是在预训练模型的基础上，用经筛选的数据调整模型在特定任务上的行为模式、格式、风格或分类/调用倾向。它可以提升特定分布下的表现，但不应被当作可精确、可追溯、自动更新的业务知识库。

适合微调的信号：

- 你需要非常固定的输出风格，而提示词无法稳定实现（例如特定的客服话术风格、特定的文案语气）
- 你有足够覆盖正常、边界和高风险样本的高质量“输入—输出”示例，且已证明其代表真实任务
- 你已用基线测试证明：相较于提示词、结构化输出、检索或工作流改造，微调能以可接受的质量、延迟和全成本带来增益

- 你希望将反复验证过的行为模式固化为可版本化、可回归的候选能力，而不是把未核验规则交给模型猜测

不适合微调的信号：

- 你的主要问题是“知识不够”或需要可追溯的当前事实（微调不应承担实时、精确的知识更新；应比较受控 RAG、长上下文、工具查询或其他可定位的上下文机制）
- 你的数据覆盖、标注一致性、许可或评测证据不足，无法判断候选版本是在改进还是过拟合
- 你的业务规则、事实或产品状态变化频繁，且无法通过数据更新、重新训练、回归和发布流程持续维护
- 你还没有验证清楚输出的质量标准（如果你还不清楚“什么样的输出是好的”，微调会把坏的模式也固化进去）

微调的两个常见误区

误区 1：用微调代替知识库

团队把所有的业务文档和 FAQ 做成训练数据来微调模型，希望模型“记住”这些知识。问题是：微调学的是模式和分布，不是精确的知识记忆。业务规则一旦变更，模型不会自动更新——你需要重新准备数据、重新训练。而用 RAG + 知识库，只需要更新文档。

误区 2：用少量低质量数据微调

50 条由实习生随手写的示例，微调出来的模型会把不好的习惯也固化进去，反而比基础模型表现更差。微调的数据质量要求极高，每一条示例都应该是“你最希望模型输出的样子”。

五、多模态：何时纳入、能力边界在哪

多模态能力是指模型处理文字以外的内容：图像、语音、视频。

当前（2026 年）的能力校准

当前主流产品已可在一定条件下处理图文、语音、视频、生成/编辑图像，并让 Agent 依据视觉界面、文件或业务工具完成多步骤任务。^{2 3 4} 这并不意味着任何模型、输入质量、部署方式或任务都达到相同可靠性。以下表格不列“绝对不能做什么”，而是把可探索能力与必须在本组织样本上验证的边界分开。

模态或能力	可在受控试点中评估的能力	仍需按任务验证、不可直接外推的边界
图像理解与文档视觉	识别图中文字、表格/图表字段、对象、界面状态和常见视觉关系；支持图文联合问答	小字、密集版面、遮挡、精确测量/计数、空间定位、专业图纸和高影响事实不应只靠单次输出确认
图像生成与编辑	从文字或参考图生成、修改和多轮迭代视觉草稿；可作为设计、沟通和原型辅助	品牌规范、文字细节、身份/肖像、版权授权、工程尺寸和对外材料必须走专门审核，不能把“看起来像”当作已符合要求

模态或能力	可在受控试点中评估的能力	仍需按任务验证、不可直接外推的边界
语音与音频	多语种语音转写、摘要、分类、部分说话人或事件线索提取	噪声、重叠说话、方言、专有名词、关键数字、身份归属和合规录音边界应以实际音频与审核流程验证
视频理解	摘要、关键片段定位、字幕、按任务抽取事件或界面线索	长视频覆盖、细粒度时序、复杂动作、身份/地点判断、实时性与证据完整性需单独评测，不宜直接作为唯一事实依据
计算机使用与跨系统操作	在隔离环境中读取界面、填写字段、运行已批准步骤、验证部分结果	生产写入、外发、支付、权限变更、不可逆操作和异常恢复必须受最小权限、独立批准、日志与回退约束

纳入多模态的决策标准

判断维度	是/否	建议
任务是否真的需要处理图像/语音/视频，不能用文字替代？	是	考虑纳入多模态
模型在该模态上的能力是否足以支撑任务精度要求？	是	进行小批量测试验证
你是否已经为文字输出建立了稳定的验证机制？	是	先建立，再扩展到多模态
团队是否有能力为多模态输出设计验证标准？	是	多模态验证通常更复杂，需要专门设计

多模态的验证要点

多模态任务的验证通常比纯文字任务更复杂：

- **图像理解与视频理解：**使用覆盖正常、低清、密集、小字、遮挡、冲突和高风险情形的标注样本；除准确率外，还检查来源、定位、遗漏、误报和人工接管。
- **语音转文字与音频分析：**计算词错率（WER）或与任务相关的字段正确率，并对行业专词、关键数字、多人重叠、噪声和授权范围做专项测试。
- **图像生成与编辑：**依据视觉规范、品牌/法律授权、文字可读性、事实一致性和版本差异评审；对外使用前由适当角色批准。
- **计算机使用：**在隔离环境中测试任务完成、越权拒绝、异常界面、网络/工具失败、写入前确认、回退和审计日志，而不是只演示一次成功路径。

六、技术路线的选型决策树

你遇到了什么问题？

- |
 - ├─ 任务尚未有清晰的输入输出、验证、回退和责任人
 - | └─ → 回到第 4 章，先完善并验证 Skill
- |
 - ├─ 知识量太大，无法稳定提供给已定义的 Skill
 - | └─ → 先考虑固定 RAG，并验证来源、权限和检索质量
- |
 - ├─ 下一步是否必须依据中间结果动态检索或调用受控实时系统？
 - | └─ 否 → 保持固定 RAG 或固定工作流
 - | └─ 是 → 仅在上下文包、工具权限、状态、预算、审批与接管齐备后，评估 Agentic retrieval 或工具调用
- |
 - ├─ 是否需要跨轮次保留已确认进度或决定？
 - | └─ 否 → 使用任务内状态或短期摘要
 - | └─ 是 → 先建立记忆合约、来源定位、隔离、失效和删除机制
- |
 - ├─ 输出风格/语气不稳定，已优化 Skill 中的 Prompt 和示例后仍无法解决
 - | └─ 有覆盖真实任务、边界与风险样本的高质量数据，并已证明微调优于基线方案？
 - | └─ 是 → 考虑微调试验与回归评测
 - | └─ 否 → 先补齐样本、评测和基线；短期可用少样本提示或其他可验证方案
 - | └─ 知识需要频繁更新？
 - | └─ 是 → 选择可定位、可更新的上下文机制，再叠加风格提示词或候选微调
 - | └─ 否 → 以内部评测比较微调、提示词、结构化输出和工作流方案
- |
 - ├─ 任务涉及图片/语音/视频
 - | └─ → 评估多模态方案
- |
 - └─ 以上都不是
 - | └─ → 回到第 4 章和第 6 章，深化基础工作流与 Skill 设计

七、本章行动清单

评估是否需要进阶方案：

- [] 用本章决策树，判断你当前遇到的问题是否真的需要 RAG/微调/多模态
- [] 如果答案是“不需要”，记录下来，避免未来重复讨论这个问题

如果决定上 RAG：

- [] 整理知识库，确认数据质量和维护责任人
- [] 设计分块策略，用代表性任务验证检索质量、来源、权限、冲突和过期处理
- [] 建立知识库更新机制，明确触发条件、响应时限和受影响用例回归要求

如果决定采用 Agentic retrieval、工具生成上下文或持久记忆：

- [] 先确认固定 workflow 或固定 RAG 无法以可接受成本和质量完成任务
 - [] 分别建立上下文包、工具/MCP 控制卡、记忆合约和上下文评测记录
 - [] 在沙箱或受限范围测试来源选择、空结果、冲突、越权、超时、异常返回、回退和人工接管
- 如果决定上微调：**
- [] 确认训练数据的来源、许可、质量、覆盖与标注一致性，并用基线比较判断样本量是否足以支持试验
 - [] 明确微调的评估标准（什么样的输出算“好”）
 - [] 评估知识更新频率，判断微调的长期维护成本是否可承受
-

本章小结

进阶技术方案不是越复杂越好。

固定 RAG 解决的是“知识量超出可稳定提供范围”的问题；Agentic retrieval 与工具生成上下文解决的是“任务需要在受控状态下按需获得信息”的问题；持久记忆解决的是“已确认的进度或决定需要跨轮次延续”的问题；微调解决的是“风格模式固化”的问题；多模态解决的是“需要处理非文字内容”的问题。它们解决的是不同维度的问题，可以组合，但不能相互替代，也不应在问题还没有明确时就急着引入。

大多数企业 AI 稳定产出的问题，都可以在“Skill（Prompt + 最小上下文 + 知识 + 验证 + 回退 + 责任）”的框架内解决。只有当这个框架在知识规模、运行时信息、长任务状态、模式固化或内容模态上触碰到明确天花板时，才是引入进阶方案的正确时机。

参考资料

第 11 章 价值评估与评测体系：如何算清 AI 的账

“AI 到底给我们带来了什么？”

这是企业管理者最终必然会问的问题。而在 AI 稳定性这件事上，大多数团队没有一个令人信服的答案——他们有感受，有案例，有截图，但没有数字。

这不只是汇报的问题。更深层的原因是：**没有评测，就没有改进的方向**。你不知道哪个场景在退化，不知道某次提示词修改是进步还是退步，不知道投入的人力和成本是否值得。

本章分两部分：上半部分讲如何算清成本与 ROI（让你能回答“值不值得”）；下半部分讲如何建立评测体系（让你能回答“好不好”和“有没有在变好”）。

第一部分：算清 AI 的账

一、成本的全貌：不只是订阅费

企业在计算 AI 成本时，最常犯的错误是只算“工具订阅费”。但 AI 工作流的 **总拥有成本 (TCO, Total Cost of Ownership)** 至少应覆盖以下持续成本与按规则分摊的一次性成本：

成本类型	具体内容	容易被忽视的原因
直接工具成本	API Token 费用、SaaS 订阅费、模型调用费	账单上看得见，相对容易统计
人工验证成本	每次输出后人工检查、修改、审核所花的时间	没有单独计时，被算进“正常工作时间”
错误修复成本	AI 输出错误导致的返工、客户投诉处理、危机公关	偶发性，容易被当作“例外”处理
维护成本	Prompt 更新、知识库维护、人员培训、版本管理	分散在多人时间中，难以汇总
上下文与工具运营成本	检索/索引、上下文包、工具/MCP/连接器维护、记忆/状态、日志、评测和变更回归	常被隐藏在平台、工程、知识 Owner 和审核人的零散工作中
实施、共享与退出成本	集成、数据准备、迁移、一次性安全/合规审查、共享平台分摊、培训/变革、恢复演练与退役准备	常被错误归入其他项目，或只在线上前一次性记录

核算公式：

月度 AI 工作流总成本 = 直接工具成本 + 人工验证/接管成本 + 错误处理成本 + 维护成本 + 上下文/检索/工具/记忆与控制运营成本 + 一次性与共享成本的可追溯分摊 + 退出/恢复准备成本

注意：不要跳过“人工验证成本”和“上下文/工具运营成本”。前者包括人工核验、审批、接管和回退；后者包括让 Agent 取得正确上下文、维护连接器、限制工具返回、处理记忆失效、留存日志和运行回归的投入。具体占比必须依据本组织的任务量、风险和运行记录核算，不能仅用模型账单代表总成本。

二、价值的量化：三种可测量的维度

AI workflow 带来的价值，可以从三个维度量化：

维度 1：时间节省

最直接的价值，也最容易测量。

测量方法：

1. 在引入 AI 前，按任务类型、复杂度、人员经验、时间窗口和异常情形记录端到端基线 (T_{before})。对低风险、同质的探索性试点，可先从少量代表性样本起步；这不是用于财务结论的固定充分样本量。
2. 引入 AI 后，在相同或可比条件下记录端到端时间 (T_{after})，包括准备上下文、等待、AI/工具运行、人工验证、修改、审批、接管、返工和必要的回退。
3. 容量释放估计 = (T_{before} - T_{after}) × 可比期间的实际完成量。若要主张因果改善或做财务决策，应结合分阶段试点、对照组、A/B、前后趋势或其他能处理季节性、任务结构和采用率变化的设计。

常见错误：只计算 AI 生成时间，忘记计算人工验证时间；或把不同难度、不同人员和不同业务负荷下的平均值直接相减。真实企业现场研究确实使用每小时解决问题数、每周 Pull Request、审查时间、构建成功和错误率等端到端流程数据，但研究也会报告采用率、任务差异和统计局限。[1 2](#)

维度 2：质量提升

通常比时间节省更难量化，但对于很多场景（如客服回复质量、文档准确率）更重要。

测量方法（选一种）：

- 对比 AI 辅助前后，客户满意度评分的变化
- 对比人工审核发现错误的频率（错误率下降多少）
- 对比内部评审通过率（第一次提交通过的比例）

维度 3：容量释放

AI 可能让同样的人员在相同时间内处理更多工作，或释放部分容量用于服务、改进或其他任务；这自动等于可以减少一个岗位、预算或外包合同。

测量方法：

- 记录引入 AI 前后，同一团队处理的任务总量
- 或记录完成同等任务量，所需的人力变化

三、ROI 计算框架

月度投资回报率 (Monthly ROI)：

已实现财务 ROI = (已实现财务收益 - 可归属月度总成本) / 可归属月度总成本 × 100%

已实现财务收益 = 已验证的现金支出减少 + 已验证的增量贡献利润 + 经批准口径估算的已避免损失

容量价值代理 = 节省的端到端小时数 × 组织确认的容量价值系数

“节省小时数 × 平均时薪”可以作为容量价值代理，但自动等于已实现财务收益。只有当释放时间确实转化为减少加班、外包、招聘、闲置、现金支出，或带来可验证的处理量、收入、服务水平或风险损失变化时，才可按事先约定的归因规则纳入已实现财务 ROI。未货币化的容量、质量、体验、学习和风险控制应单列呈现，不应为了得出一个 ROI 百分比而强行折算。

向管理层汇报的简洁版本：

“本季度，我们在[场景 A]和[场景 B]上运行 AI 工作流。可归属全成本为 X 元；在可比范围内，端到端处理时间变化为 Y，质量/风险指标为 Z。已验证财务收益为 W 元，容量价值代理为 V 元，两者未合并计算。下一阶段是否扩大，取决于预先约定的质量、控制和业务结果闸门。”

这个表述的关键不是把所有收益压缩成单一数字，而是让成本、已实现收益、容量代理、质量和证据边界可以被复核。Klarna 等企业公开案例同时报告处理量、时长、客户体验、容量等价和预计财务影响，说明多维测量在实践中被使用；但其中数值属于当事方披露，不能外推为其他企业的目标或财务结论。³

第二部分：建立评测体系

四、核心指标体系：基础结果与 Agent 运行信号

以下五个指标来自附录 B，构成所有用例的基础结果视图。涉及检索、工具、记忆或 Agent 时，还应增加上下文、工具和接管信号；这些不是跨团队统一 KPI，而是帮助团队识别“最终文本看起来正常、运行控制却已失效”的早期迹象。

指标	定义	目标或触发条件如何设定	为什么重要
一次通过率	输出一次性通过验证清单的次数 / 总执行次数	依据基线、错误后果、审核能力和阶段门设定；高影响场景不应仅因平均值达标而放宽控制	衡量稳定性的核心指标
实际采用率	被直接或小改后使用的输出数 / 总输出数	结合任务覆盖、人工替代方式、用户选择和质量反馈设定；需区分“被接受”与“被迫使用”	衡量实际业务价值（通过了检查但没人用 = 质量标准脱离业务）
平均总耗时	从提交任务到获得可用输出的完整时间	与可比人工基线、服务等级、任务难度和审核负担比较，不设跨场景统一比例	衡量效率提升
失败类型分布	各类失败原因（幻觉/格式/遗漏/过期知识）的占比	—	指导改进方向
知识更新及时率	按时完成知识库更新的次数 / 应更新次数	由用例风险、变化速度和 Owner 能力确定	衡量知识维护质量

指标	定义	目标或触发条件如何设定	为什么重要
来源可定位与异常拦截（涉及上下文/Agent 时）	来源、版本、范围可定位，以及过期、冲突、越权或信息不足被正确停止/转人工的情况	由风险边界和 Golden Set 确定	衡量上下文是否可解释、可复核、可安全停止
工具/记忆运行信号（涉及工具/记忆时）	工具参数/返回异常、无效调用、记忆纠错与失效、接管和恢复情况	由运行合约和控制卡确定	衡量行动面和状态面是否仍受控

五、评分量表（Rubric）：让“好”变得可以测量

一次通过率需要一个前提：**明确定义什么样的输出算“通过”**。

验证清单给出的是“是/否”判断（格式是否正确、有没有事实错误）。但很多输出的质量是连续的，需要用评分量表（Rubric）来处理。

设计一个 Rubric 的四步法：

第 1 步：确定评测维度

根据任务类型选 3~5 个维度。例如客服回复场景：

- 准确性（信息是否正确）
- 完整性（是否覆盖了所有要点）
- 适当性（语气是否符合品牌调性）
- 简洁性（是否简洁，没有废话）

第 2 步：为每个维度定义评分等级

可从 3 级评分（合格/良好/优秀）开始，也可按任务使用二元、四级或其他可解释等级；等级数不是质量保证。

以“准确性”为例：

- **1 分（不合格）**：包含明显的事实错误，或使用了过期信息
- **2 分（合格）**：信息基本正确，但有一处模糊表述
- **3 分（优秀）**：所有信息准确，表述清晰无歧义

第 3 步：计算综合得分与通过阈值

例如 4 个维度各 3 分，总分 12 分，可以先用 9 分作为教学演示。正式通过阈值应由错误代价、关键维度的最低分、监管/合同要求、人工接管能力和历史样本分布共同确定；不能把 75% 作为通用质量门槛。

第 4 步：定期校验评分一致性

让两个或以上评审人分别对同一批样本评分，检查**评审者间一致性（Inter-rater Agreement）**与分歧类型。可按评分尺度和样本量选择原始一致率、Cohen’s kappa、加权 kappa、Krippendorff’s alpha 或组内相关系数（ICC）。不存在通用的 70% 通过线；若关键维度分歧会改变发布、对外沟通或高影响决定，应先澄清 Rubric、培训评审人并复测。

六、从人工检查到半自动化评测

纯人工评测在低频场景可行，但当任务量增大时，你需要把部分评测自动化。

可以自动化的评测项

检查类型	自动化方法
格式检查	用正则表达式检查输出是否符合预定格式(如JSON 结构、必须包含的字段)
禁止词检查	检查输出中是否包含禁止使用的词语或表述
长度检查	检查输出是否在规定的字数范围内
结构完整性	检查必须出现的章节标题、关键词是否存在

LLM-as-Judge：用 AI 评测 AI

对于“合理但难以用规则判断”的质量维度（如语气、逻辑连贯性），可以用另一个 LLM 作为评审。

LLM-as-Judge 的标准提示词结构：

你是一个专业评审员。请根据以下评分标准，对以下输出进行评分。

【任务描述】

[说明这个 AI 工作流的任务是什么]

【评分标准】

[粘贴你的 Rubric，含各维度定义和评分等级]

【待评测的输出】

[粘贴 AI 的输出内容]

请对每个维度给出分数（1/2/3）和一句理由，最后给出综合判断（通过/不通过）。

LLM-as-Judge 的注意事项：

- LLM 评审本身也有误差，置信度不等于正确性。应按风险分层抽取人工复核样本，并比较一致性、假通过、假拒绝、漂移和高风险样本覆盖；20% 只能作为某些探索性试点的起点，不是通用充分比例
- 不适合用于高风险决策的评测（如判断法律合规性）
- 建议定期用人工重新校验 LLM 的评审标准是否在漂移

七、评测数据的记录与使用

评测的价值，不在于当下的数字，而在于趋势。

最简单的评测记录表（按运行节奏填写）：

日期	场 景 / 版 本	执行范围	质量与采 用结论	主 要 失 败 / 风 险 信号	上 下 文 / 工 具 / 记 忆变化与 异常	本期改进 动作与证 据
----	--------------	------	-------------	------------------------	----------------------------------	-------------------

三个用评测数据做的最重要的决策：

- 1. **停止或限量**：出现不可接受错误、无法解释的质量退化、来源/权限异常、接管失效或证据不足时，考虑暂停扩大、转人工或回退。
- 2. **升级**：只有当业务价值、质量、人工审核负担、来源/工具控制、接管和运行证据均满足用例闸门时，才考虑扩大范围或提高自主性。
- 3. **改进**：当失败或运行信号呈现重复模式时，针对任务定义、上下文、知识、工具、记忆、验证或培训进行专项改进，并在变更后回归。

八、从单用例数据到组合决策

当只有一个用例时，计算该用例的 TCO、质量和采用率即可。当多个 Skill、工作流或 Agent 同时运行时，管理层还需要回答：哪些用例值得继续投资资源，哪些只是局部便利，哪些因为共享知识、共享平台或共享维护人而带来了组合风险。

1. 不要把所有“节省时间”直接相加为财务收益

不同用例的节省时间可能来自同一批员工，也可能只是把工作从一个环节转移到另一个环节。组合汇报时，应区分以下三类信息：一是各用例的**流程效率证据**，即端到端耗时、返工和处理量变化；二是可被验证的**业务结果证据**，如客户满意度、积压下降、收入周期、成本避免或风险损失减少；三是尚未货币化的**能力建设投入**，如知识整理、培训、平台与维护。因此，组合层面的 ROI 不应简单把每个用例的“节省工时×时薪”累加。只有当时间释放确实转化为可观察的处理量、成本减少、收入改善或风险避免时，才应谨慎作为财务价值汇报；其余可先作为流程和产能证据记录。

2. 组合评审应做四类决定

决定	应看什么证据	典型动作
加大投入	业务价值已验证；质量、采用和维护稳定；可复用资产明确	扩大问题类型、使用者或相邻团队；补充支持能力
继续改进	业务问题真实但质量、知识、成本或采纳仍有可修复缺口	限制范围，安排明确 Owner 与改进期限
暂停或降级	风险、维护负担或质量问题大于当前收益	回退人工流程或降为辅助使用，保留证据与复盘
退役	价值消失、被更优方案替代、维护不可承受或风险不可接受	停止权限与运行，归档资产，按政策处置数据与日志

用例组合台账、阶段闸门和月度评审模板见附录 A 第 18、20、21 节；第 8 章和第 12 章分别说明扩展节奏与组合治理机制。

3. 把评测结果接入发布与运行决策

一次通过率、Rubric 或单次回归结果本身不是终点。企业需要把“为什么做、怎样运行、如何测试、能否发布、发布后是否健康”连成一条可追溯的控制链：**用例立项卡定义业务假设与停止条件；工作流合约定义运行边界；上下文包、记忆合约和工具控制卡定义信息面、状态面与行动面；Golden Set**

定义应测哪些真实、边界和失败情形；回归报告比较新旧版本；发布登记限制范围并设观察期；用例健康卡持续判断扩大、维持、改进、暂停或退役。

资产	它回答的问题	使用时点
用例立项卡	这个业务问题是否值得做，成功或停止意味着什么	设计前与阶段变更前
workflow 合约	流程怎样运行，谁在何处验证、接管和回退	多人试点或正式运行前
上下文包、记忆合约与工具控制卡	此刻允许依据什么、可保存什么、可查询或执行什么，以及如何限制和回退	设计、试点、连接器接入或高影响变更前
Golden Set	什么样的正常、边界、失败和异常行为必须被验证	试点、变更和事件复盘前
回归报告	新版本相对稳定版本是否退化，是否可发布	变更、修复或阶段提升前
发布登记	允许谁在何范围使用，何时停止和如何回退	每次受控上线或范围扩大时
用例健康卡	当前业务价值、质量、成本、风险和维持是否仍支持继续运行	与用例运行频率、风险和变更节奏相称的运行会与组合评审

附录 A 第 25、26、29、30、31、32、48–51 节分别提供这些资产。它们不要求每个低风险内部试点都做成复杂项目：范围越小、风险越低，记录越轻；但涉及对外沟通、写入、权限扩大、敏感数据或高影响决策时，证据和审批也必须随之加强。

九、本章行动清单

本月建立基础：

- [] 计算你当前最主要 AI 场景的 **总拥有成本**（包含验证时间成本）
- [] 为该场景设计一个 3~5 维度的评分量表（Rubric）
- [] 从真实或脱敏历史任务中建立一个最小 Golden Set，至少覆盖正常、边界与历史失败样本
- [] 按用例运行频率、变更节奏和风险等级填写评测记录，直至覆盖足以支持阶段决策的正常、边界、失败和变更样本
- [] 为下一次 Prompt、上下文包、知识、记忆、模型、工具或连接器变更预先指定回归报告、发布登记和回退版本

建立向管理层汇报的能力：

- [] 用本章的 ROI 公式，计算你运行时间最长的那个 AI 场景的季度 ROI
- [] 准备一份不超过一页的 AI 价值汇报模板，包含：成本、价值、质量指标、下一步改进计划

当重复频率、人工评测负担或变更速度已使人工全量检查不可持续时：

- [] 为格式、禁止词、结构完整性等确定性要求建立自动化检查，并验证其漏报与误报
- [] 评估是否可以引入 LLM-as-Judge，并按风险分层设计人工校验、漂移监测和停止条件

本章小结

算清 AI 的账，需要同时看两个维度：成本的全貌（不只是订阅费）和价值的量化（不只是感受）。评测体系的建立，不需要一步到位。从按运行节奏填写一张简单的评测记录表开始，然后逐步引入 Rubric、自动化检查和 LLM-as-Judge。

最重要的一点：**评测数据是用来做决策的，不是用来证明 AI 的价值给领导看的。** 如果数据告诉你一个场景在退化，你就需要根据数据做出停止或改进的决策，而不是选择性地只汇报好看的数字。

参考资料

第 12 章 让结果长期可靠：评测、治理与组织协同

最小闭环跑通后，下一步是让它真实组织环境中持续稳定运行，而不是用一段时间后逐渐失效。本章提供可直接执行的方法，覆盖三个关键问题：如何持续评测效果、如何做基础治理、如何推动必要的组织协同。

一、建立简单有效的评测机制

没有评测，就无法判断工作流是否在变好还是在变差。

1. 必做的基础评测（每周一次，15-20 分钟）

针对已上线的最小闭环，固定记录以下数据：

评测项	记录内容	建议目标（基于实践经验）
通过率	本周总次数中，一次通过验证清单的比例	≥80%
平均总耗时	生成+人工检查的平均时间	比原方式下降≥30%
主要失败类型	本周最常见的 1-2 个问题	每周下降或保持稳定
实际采用率	最终被直接使用或小改后使用的比例	≥75%

用共享表格记录即可，不必上复杂系统。

2. 每月一次的深度回顾（30-45 分钟）

每月固定时间回答以下问题：

1. 本月通过率、耗时、采用率是否达到目标？
2. 失败案例中，哪些是 Prompt 问题，哪些是知识/数据问题，哪些是 Skill 定义、流程或 Agent 运行问题？
3. 是否需要更新 Prompt、Skill 卡、上下文包、检查清单、知识内容、记忆、状态逻辑、工具/连接器或权限配置？
4. 最近是否发生模型、工具、连接器、知识、上下文、记忆、权限或 Agent 运行逻辑变更；是否需要回归评测？

把结论写成简短记录，作为下月改进依据。

3. 评测结果的使用规则

- 通过率连续两周低于 70%：立即暂停扩大范围，先修复当前闭环。
- 耗时下降不明显：检查是否验证环节过重，或提示词产生了过多需要修改的内容。
- 采用率低：说明输出虽然“能过检查”，但业务上仍不好用，需要补充业务侧标准。

二、基础治理动作（必须落地的部分）

治理不需要一开始就做得很重，但以下五项必须明确并执行。

1. 版本管理

所有正式使用的 Prompt 模板、Skill 卡、上下文包、记忆合约、检查清单、知识参考材料、工作流定义、工具/连接器控制卡和 Agent 运行合约，必须有版本号和更新日期。版本号应对应可定位的变更记录；一项关键组件发生变化时，应明确哪些 Skill、工作流或 Agent 会受影响。

命名示例：

- 会议纪要提示词_v1.2_20260819

- 会议纪要提取 Skill_v1.0_20260819
 - 待办检查清单_v1.1_20260815
 - 异常工单 Agent 运行合约_v1.0_20260819
- 每次修改后，旧版本保留至少 30 天，方便回退。

2. 权限与使用范围

明确回答三个问题并形成书面记录：

- 谁可以使用这个工作流、Skill 或 Agent？
- 谁有权修改 Prompt、Skill 卡、检查清单、知识材料、状态逻辑或权限配置？
- Agent 可以调用哪些 Skill、上下文来源、记忆、工具/连接器、数据范围和读写动作？
- 工具返回量、保存范围、外发和持久记忆如何受到限制？
- 输出结果可以用于哪些场景，不可以用于哪些场景？
- 谁拥有暂停、恢复、升级自主等级和退役的决策权？

3. 知识、上下文与工具 Owner

每个被 AI 调用的核心知识内容应指定知识 Owner；每个正式上下文包、持久记忆和工具/MCP/连接器还应指定相应的上下文、记忆或技术 Owner。一个人可以兼任多个角色，但不能让“大家都负责”替代明确责任。

Owner	最低职责
知识 Owner	确认权威来源、业务规则、生效范围、冲突和失效；业务规则变化后完成更新与影响说明。
上下文/记忆 Owner	维护来源白名单、选择逻辑、排除来源、记忆类别、隔离、保留期、失效和纠错规则。
工具/连接器 Owner	维护用途、接口、参数、返回量、身份权限、日志、异常、禁用和退出方式。
用例/Skill/Agent Owner	确保上述资产与业务边界、评测、审批、回退和发布决策保持一致。

4. 变更与回归责任

规则、上下文包、检索、记忆、工具/连接器、模型、权限或状态逻辑发生变化时，应由对应 Owner 发起影响分析；用例 Owner 确认业务边界；技术与风险角色按影响参与评测、审批、发布或回退。低风险内部改动可以轻量记录，高影响或跨系统变化必须使用附录 A 的上下文、工具和回归资产。

5. 问题升级路径

当出现以下情况时，必须升级处理：

- 连续出现同类严重错误
- 输出可能影响客户或正式决策
- 有人绕过验证清单直接使用结果

升级对象和建议处理时限提前写清楚。

三、组织协同的具体推进方法

美团的经验也印证了这一点：从无序全员尝试，到事业部成立 AI 组织、赛马梳理方法，再到流程中真正跑通，用了约半年时间，最终确认必须把业务、组织、技术同步推进，而不能只寄望于产研团队。稳定产出最终需要跨角色配合。以下是可执行的推进步骤。

步骤 1：找到最小支持联盟（1 周内完成）

识别三类人并获得明确支持：

- 1. 业务侧使用者（真正跑任务的人）——至少 1 名
 - 2. 内容/知识责任人（能更新相关材料的人）——至少 1 名
 - 3. 有资源决策权的人（能支持时间或工具的人）——至少 1 名
- 与他们分别沟通一次，确认他们愿意在当前最小闭环上投入时间。

步骤 2：用数据而不是感受推动

每周把评测表格的关键数字同步给支持联盟。只同步数字和主要问题，不扩展讨论。当数据连续表现稳定时，再提出下一步（增加场景或减少人工检查比例）。

步骤 3：明确各方的具体责任

用一页纸写清楚：

角色	每周固定动作	出问题时应做的事
使用者	按模板或 Skill 卡执行并完成检查	记录失败案例，必要时转人工
知识责任人	响应知识更新请求	在约定时间内完成更新，并确认影响范围
上下文/记忆责任人	维护来源、选择逻辑、隔离、失效和纠错	处理过期、冲突、越权、污染或状态异常
Skill/流程责任人	查看质量、采用、耗时与变更记录	决定修复、回退或暂停当前能力
技术/工具责任人（如适用）	维护工具、连接器、权限、日志、熔断与运行状态	处理运行异常，验证人工接管与恢复
支持决策人	查看周度数据和重要风险	决定是否扩大、提高自主等级或调整资源

步骤 4：控制推进节奏

- 当前闭环通过率稳定在 80% 以上，再增加第 2 个场景。
- 同一时间只推进 1-2 个闭环，避免同时铺开多个导致无法兼顾。
- 任何新场景都必须先完成第 6 章的最小闭环步骤，再进入本章的评测与治理。

四、从单个闭环到多个用例的最小组合治理

当团队只有一个最小闭环时，周度记录、明确责任人与问题升级路径已经足够。当正式或试运行用例达到 3 个以上，治理对象会从“某一个提示词是否好用”变成“有限的人、知识、工具和风险预算应该支持哪些用例”。这时不需要立刻建立重型委员会，但至少要建立用例组合台账、阶段决策记录和月度组合评审。

1. 用例组合台账

每个用例在台账中占一行，记录业务目标、当前阶段、业务 Owner、关键 Skill/Agent、知识、上下文、记忆与技术依赖、健康指标、维护负担和下一决策。它的重点是业务用例，而不是工具账号或模型清单。模板见附录 A 第 18 节。

2. 责任与决策权

多人协作时，最容易出现的不是“没人做事”，而是“大家做了事、没有人对业务结果拍板”。每个用例必须有业务 Owner；每个共享知识资产必须有知识 Owner；正式上下文包、持久记忆和检索策略必须有相应 Owner；涉及工具、连接器、权限、日志、熔断或自动化运行的用例必须有技术 Owner。扩大、暂停、恢复或退役由谁决定，应在用例立项时写明。附录 A 第 19 节提供最小 RACI 模板。

3. 阶段闸门与月度评审

用例应在候选、试点、限量生产、受控生产、规模化和退役状态之间有意识地推进，而不是“一上线就默认永久存在”。阶段提升应同时检查业务价值、质量和采用、知识/数据、责任、回退及运行控制证据；退役同样需要保证人工或替代流程可用。完整的阶段闸门和决策卡见附录 A 第 20 节。建议每月用 45–60 分钟做一次组合评审，集中决定：哪些用例应该修复、扩大、暂停或退役；共享知识、工具和人员依赖是否产生风险；下月真正有能力启动哪些新场景。会议应以台账、指标、风险和阶段决策为输入，而不是以工具登录次数或 Token 消耗作为主要内容。模板见附录 A 第 21 节。

五、FDE / AI COE：把交付做成客户可接管的能力

FDE（Forward Deployed Engineer）或内部 AI COE 的价值，不是替业务团队长期“代运营 AI”，也不只是把一个 Demo 搭起来。其真正作用是把业务问题、技术实现、风险控制、评测与变革动作压缩到同一个短周期中，并在交付结束时让业务团队能够独立运行、修改、升级和停止该能力。

交付底线：外部顾问、FDE 或 AI COE 可以设计、辅导、搭建和加速，但不能长期替代客户方的业务 Owner、知识 Owner、审批人或日常使用者。没有客户方接棒责任的项目，不应宣称已完成“企业落地”。

1. 六阶段共创交付循环

阶段	关键问题	FDE / AI COE 主要动作	客户/业务团队 主要动作	最低产出与决策门
发现	值得解决的业务问题是什么？	访谈、观察、量化基线、识别候选用例和风险	提供真实任务、现有流程、约束与 Owner	用例立项卡、初始风险筛查；决定设计/暂缓/不做。
共创设计	怎样以最低必要复杂度解决？	协助拆任务、定义 Skill/工作流、上下文包、工具控制和验证/回退	确认业务边界、知识与上下文来源、人工控制和成功/停止条件	工作流合约、上下文/知识/权限边界、工具控制卡、Golden Set 设计；决定开始试点。
试运行	在真实但受控的范围内是否可用？	搭建、调试、收集失败样本、辅导使用者	使用真实任务、完成核验、记录采用、来源/工具行为与异常	Skill/Agent 资产、上下文/记忆/工具控制记录、周度记录、回归与风险控制

阶段	关键问题	FDE / AI COE 主要动作	客户/业务团队 主要动作	最低产出与决策门
				制证据；决定修复/限量运行/停止。
验收	是否达到约定的业务、质量与控制标准？	汇总证据、演示边界与回退、组织第二人复现	业务 Owner 核验结果，明确是否接收与后续范围	验收记录、发布登记、健康卡初版；决定接收/附条件接收/拒收。
移交	客户方能否不依赖交付者运行？	交接资产、权限、操作 SOP、培训与支持窗口	指定接棒 Owner，完成独立运行、变更和回退演练	移交清单、实践认证、接棒确认；决定进入客户运营或延长辅导。
退出/扩展	何时结束当前交付，何时开始下一个用例？	复盘、归档、移交遗留问题、提供组合建议	接管运营、决定扩大/暂停/退役/启动下一用例	退出/扩展记录、证据索引更新、下一阶段计划。

模板见附录 A 第 39–43 节。项目不必机械经历所有阶段或追求复杂文档；但不能跳过业务 Owner、风险边界、真实验证、验收或接棒能力。

2. 角色边界与共同责任

角色	应承担的责任	不应承担的责任
业务 Owner	定义业务问题、成功/停止条件、范围、优先级和最终业务决定	把业务判断、数据责任或风险接受永久外包给交付团队。
知识 Owner	确认权威来源、更新时效、冲突处理与知识变更影响	让 FDE 自行解释企业规则或在缺少授权时决定口径。
上下文/记忆 Owner	确认允许来源、选择逻辑、记忆目的、隔离、失效与纠错	把全量资料、完整会话或未经确认的推断默认为可复用记忆。
FDE / AI COE	共创工作流、资产化经验、搭建评测与控制、辅导第二人复现	在没有客户授权或接棒条件时把原型直接推入生产。
技术/工具 Owner	管理集成、连接器、权限、数据流、配置、日志、熔断、运行与回退	代替业务 Owner 决定业务范围、对外承诺或价值判断。

角色	应承担的责任	不应承担的责任
风险/安全/法务等适用角色	对高影响数据、动作、对象和例外提供适用的审查与约束	为业务目标或模型选择作无边界的“全盘背书”。

3. 验收不是演示成功

演示中一次顺利运行不等于可以验收。验收应同时检查五类证据：业务问题与范围是否仍成立；Golden Set、回归和真实试运行是否达到约定的质量/采用/效率标准；上下文来源、记忆、工具/连接器、数据和权限是否受控且可追溯；人工接管和回退是否已验证；客户方是否完成第二人复现、能定位资产并独立处理基础变更和异常。

如果质量达标但接棒角色未准备好，应视为**附条件接收**，保留限量范围和支持窗口；如果业务 Owner、知识 Owner 或回退流程缺失，则不应通过正式移交。

4. 移交与退出的可验证标准

交付团队应以“客户能够做什么”而非“已交付多少文档”判断是否可以退出。最低标准包括：客户能定位用例立项卡、风险/影响评估、工作流合约、Skill/Agent 资产、上下文包、记忆合约、工具/连接器控制卡、事实卡、Golden Set、回归/发布记录和证据索引；指定 Owner 已完成实际任务、回退和基础变更的演练；客户能在不依赖交付团队口头解释的情况下完成一次运行与一次异常升级；遗留问题、支持边界和退出后联系机制已经书面说明。

六、本章行动清单

请在本周内完成以下动作：

1. 为已跑通的最小闭环建立周度评测表格，并开始记录。
2. 给正式使用的 Prompt、Skill 卡、上下文包、记忆合约、工具/连接器控制卡、检查清单和知识材料加上版本号。
3. 明确该闭环的使用者、业务/Skill 责任人、修改权限人、知识 Owner、上下文/记忆 Owner 和技术/工具 Owner；如含 Agent，再明确暂停/恢复权限人。
4. 找到至少一名业务使用者和一名支持决策人，同步当前数据和下一步计划。
5. 写出问题升级路径（什么情况找谁，多长时间内响应），并为 Agent 补齐来源冲突、工具异常、记忆错误、熔断与人工接管的回退说明。
6. 当正式或试运行用例达到 3 个以上时，建立用例组合台账，并为每个用例记录业务 Owner、当前阶段和下一次决策日期。
7. 约定第一次月度组合评审：使用质量、采用、成本、风险和共享依赖信息，决定扩大、修复、暂停或退役。

完成以上动作后，最小闭环才具备长期运行的基础条件；多个用例也开始具备可持续经营的基础。

七、本章小结

长期可靠依赖三件事的同步到位：持续评测、基础治理、必要的组织协同。评测提供客观依据，治理防止过程失控，组织协同确保问题和改进有人承接。先把当前闭环做稳，再考虑扩大范围。

第 13 章 人机协同与组织生产方式：从对话辅助到目标受托

前面的章节讨论了如何把 Prompt 沉淀为 Skill、工作流和受控 Agent，也讨论了员工怎样使用 AI、组织怎样治理用例。本章进一步回答一个更长期的问题：当 AI 不再只生成一次回答，而能够在有边界的环境中检索资料、调用工具、执行多步骤任务并依据反馈迭代时，企业的生产方式会怎样变化？答案不应被简化为“人被替代”或“所有工作都会变成 Agent”。更接近现实的变化是：**工作单元、人的职责、组织知识和反馈机制正在被重新组合**。人类仍然定义业务目的、提供不可替代的情境判断、承担授权与责任；AI 则可在明确边界内承担更多信息处理、初步实现、验证、协调和执行工作。企业的关键能力将不再只是采购模型，而是把这种协作设计成可复核、可维护、可暂停的系统。

本章是一张协作形态地图，不是技术发展史、组织重组方案或岗位替代预测。同一企业、同一部门甚至同一流程中的不同子任务，都可能长期采用不同形态。复杂度只有在带来经验证的业务增益时才值得增加。

一、从“使用工具”到“重新组织工作单元”

早期的生成式 AI 使用，常以一次问答、初稿或资料整理为单位。用户输入问题，模型给出结果，用户自行修改或放弃。Prompt 工程使个人经验开始显性化；Skill 使可重复的程序性知识、示例、脚本和资源得以共享；工作流将稳定的步骤、验证和回退固定下来；受控 Agent 则在目标、权限和停止条件明确时，承担路径无法预先完全写死的多步骤任务。

变化的重点不是把所有工作都交给 AI，而是把“完成一项工作”拆成更清晰的单元：谁定义目标，谁提供上下文，谁执行可验证步骤，谁审核例外，谁记录反馈，谁对结果负责。OpenAI 的公开工程文章将这种转变概括为：随着 Agent 承担更多执行，工程师的高价值工作转向设计环境、表达意图、建立反馈循环和编码质量约束。¹ 这一观察适用于工程之外的很多场景，但不应被误读为所有岗位都采用同样的节奏或自动化比例。

过去常见的工作方式	正在出现的协作方式	企业需要补齐的能力
个人向工具提问，靠经验判断结果	人将任务、边界和验收标准交给可复用的协作单元	任务契约、示例、Rubric 与个人自检
知识分散在聊天记录、邮件和人员记忆中	知识被整理为可发现、可定位、可更新的上下文与 Skill	知识 Owner、来源/版本、渐进披露与变更机制
专家亲自处理每个实施步骤	Agent 在批准工具和环境承担准备、实现、测试或整理	工具说明、权限、日志、异常处理与人工接管
问题通过临时沟通解决	失败、评审意见和例外被转化为测试、规则、文档或 Skill 改进	反馈闭环、回归评测、复盘与资产维护
经理管理投入的人数和任务量	经理同时管理目标、容量、质量、风险、上下文资产和人机分工	阶段闸门、价值证据、RACI 与组合治理

因此，企业应把注意力从“谁在使用哪个工具”转向“哪个工作单元已具备可委托、可复核和可恢复的条件”。这也是本手册始终强调用例、证据和运行控制，而不以模型名或调用量作为成果的原因。

二、六种可以并存的人机协作形态

以下六种形态不是线性成熟度等级。企业不必从左到右升级；某些任务应永久停留在对话辅助、共同创作或固定工作流。是否升级，取决于任务结构、风险、数据、验证能力和组织准备度。

协作形态	主要工作单元	人的主要贡献	应沉淀的资产	适合升级的信号	不应升级的信号
对话辅助	一次问题、初稿或资料整理	提问、核验、修改与采用判断	Prompt、参考材料、检查清单	同类任务反复出现	每次任务高度独特，且没有复用价值
共同创作	可迭代的文档、分析或设计	设定方向、比较方案、给出反馈	示例、Rubric、版本记录	反馈模式稳定，质量可讨论	事实无法核验，或业务责任不清
可复用 Skill	重复出现的子任务	提炼程序性知识、维护适用边界	Skill 卡、指令、脚本、资源与评测	可跨人员、跨任务复用	规则不稳定、Owner 缺失或数据不具备
受控工作流	预定义的多步骤流程	设计输入输出、例外和回退	工作流合约、测试、Runbook 与发布记录	步骤稳定、验证可程序化	异常路径无法说明，或回退不可行
目标受托 Agent	开放但有边界的多步骤任务	定义目标、授权、验收、升级	目标契约、上下文包、状态、工具与证据	路径难预先穷尽，但结果可验证	权限、停止条件、人工 Owner 或回退不清
Agent 协作网络	可并行的高价值探索或生产任务	设计分工、努力预算、冲突处理与整合	编排规则、上下文隔离/共享、追踪与恢复	任务可并行，价值足以覆盖协调成本	任务强依赖、低价值，或团队无法观察协调过程

Anthropic 对 Agentic 系统的公开说明也区分了预定义代码路径的工作流与由模型动态决定步骤和工具的 Agent，并建议从最简单、可验证的方案开始，只在复杂性确有收益时增加自主性。²这与第 4 章和第 9 章的原则一致：能力强并不是扩大自主性的充分理由。

三、人的工作从“亲自执行”转向“委托、复核与拥有”

当 AI 能承担更多实现和执行时，人类并没有退出流程，而是更集中地承担三类不可空缺的责任：**委托 (Delegate)、复核 (Review) 与拥有 (Own)**。OpenAI 在其面向 AI 原生工程团队的公开指南中，使用了类似的划分：Agent 可完成有边界的初步分析、实现、测试或文档；团队复核准确性、完整性和适配性；组织仍拥有优先级、长期取舍和最终发布责任。³

责任层	人应负责什么	AI 可在受控范围内承担什么	不应混淆的边界
委托	明确问题、目标、范围、约束、可用资料和验收方式	拆解已授权任务、提出计划、准备候选方案	AI 提出计划不等于已获得执行授权
复核	核验事实、判断例外、评估风险、确认质量与影响	执行规则检查、测试、交叉比对、整理证据	自动通过不等于业务、法律或安全批准
拥有	决定优先级、资源、权限、对外承诺、停止与恢复	提供选项、模拟影响、汇总运行信号	AI 不能成为业务 Owner、审批人或责任主体

这种分工会改变不同角色的日常工作。员工需要更擅长描述问题、识别可用上下文、判断依据和停止条件；专业人员需要将经验转化为可验证的规则、示例和例外路径；管理者需要同时管理业务目标、容量、质量、风险和共享资产；技术团队则需要让知识、工具、日志、测试和环境对 Agent 可理解、可使用且可限制。

这并不意味着每个人都要成为程序员。Anthropic 公开的跨团队使用案例显示，设计、数据、营销、法务和工程团队都可将 Agent 用于理解、原型、测试、文档或自动化；其共同前提是由人定义问题、提供反馈并复核结果。⁴ 对企业而言，真正需要普及的不是某个产品界面，而是目标表达、上下文判断、质量评估、例外升级和反馈沉淀等协作能力。

四、目标契约：让 Agent 为目标工作，而不是自行决定目标

“Agent Goal”容易被误解为让 AI 自主选择组织目标。企业需要的不是目标自治，而是**目标契约**：由具有业务授权的人，将可委托任务的目标、边界、证据和停止条件明确下来，再允许 Agent 在契约内规划与执行。

目标受托不等于目标自治。Agent 可以决定下一步如何在授权工具中完成任务；改变业务目标、扩大范围、连接新系统、提高权限、接受不可逆后果或对外作出承诺，必须由有权的人决定。

目标契约字段	必须回答的问题	与既有资产的连接
业务目标与成功证据	要改善什么业务结果，怎样证明完成？	用例立项卡、价值评估与阶段闸门
范围与非目标	处理哪些对象、时段和问题，明确不处理什么？	工作流/Agent 运行合约
最小必要上下文	可以依据哪些来源、版本、范围和实时状态？	上下文包、知识责任与动态事实卡
工具与权限	可以读取、查询、修改或发送什么；哪些动作必须批准？	工具/MCP/连接器控制卡与最小权限设计

目标契约字段	必须回答的问题	与既有资产的连接
时间、成本与并发预算	最多允许运行多久、调用多少工具、消耗多少资源？	运行合约、健康卡与成本记录
验证与审批点	哪些结果可自动检查，哪些必须由人判断或确认？	Golden Set、Rubric、发布登记与审批矩阵
停止、升级与回退	出现什么信号必须停止、转人工、回退或升级？	Runbook、人工备用与事件分级
人工 Owner 与记录	谁拥有目标，谁维护上下文/工具，哪些证据需要保留？	RACI、审计证据索引与移交资产

目标契约不是新增的一套繁重表格。低风险的内部试点可以用简短卡片记录；涉及对外沟通、敏感数据、写入操作、权限扩大或高影响决定时，则必须与第 9、14、15 章和附录 A 的运行、风险与安全资产一起使用。

五、公开实践观察窗：可以借鉴的机制，而不是可复制的组织蓝图

前沿 AI 公司公开的工程文章和产品资料，为理解协作方向提供了有价值的观察窗。但这些材料反映的是特定团队、模型、基础设施、人员能力和产品目标下的实践，不能被转写为其他企业的效率承诺或组织模板。

1. 让工作环境对 Agent 可理解

OpenAI 的“Agent-first 工程”公开文章描述了一种做法：使用短而稳定的入口文件引导 Agent，再由版本化、结构化的仓库知识库提供更深层的上下文；通过测试、结构约束、日志、指标和持续清理，让 Agent 能够找到信息、验证结果并将反馈转化为下一轮改进。¹

这个案例的可借鉴点不是“让 Agent 写所有代码”，而是**将组织知识从分散的聊天、个人记忆和临时文档，转化为可发现、可定位、可更新和可验证的工作资产**。第 5 章的最小上下文包、附录 A 的 Skill 卡和第 12 章的知识 Owner 机制，正是企业版的基础做法。

不可外推之处在于：该公开实践依赖特定仓库、工具链、可观察性和工程团队投入。普通企业不应因看到其吞吐或自主性描述，而跳过自身的上下文治理、测试、权限和发布控制。

2. 将“委托—复核—拥有”嵌入生命周期

OpenAI 的 AI 原生工程团队指南按计划、设计、构建、测试、审查、文档、部署和维护拆解协作，并在每个阶段区分可交给 Agent 的工作、需要团队复核的工作以及人必须拥有的责任。³

这提示企业：人机协同不应只出现在“生成内容”这一个节点，而应设计在完整的业务生命周期中。例如，客服团队可以让 AI 整理证据和起草回复，由员工核验适用规则并批准发送；运营团队可以让 Agent 汇总异常、准备处置选项和运行记录，由 Owner 决定优先级、授权动作并评估后果；工程团队可以让 Coding Agent 准备实现、测试和文档，由工程师拥有架构、迁移和上线责任。

3. 将成功做法封装为可共享的 Skill

Anthropic 将 Agent Skills 描述为包含指令、脚本和资源的可发现文件夹，并强调渐进披露：Agent 先看到何时可用的元信息，再按任务需要加载详细指令或运行确定性脚本。其建议从评测中发现能力缺口，在真实使用中观察 Agent 如何读取和使用资产，再逐步改进。⁵

对企业而言，Skill 的价值不在于某种文件格式，而在于把“某位同事会做”的经验转化为可共享的程序性知识包。每个 Skill 都应有任务范围、输入输出、来源、脚本/工具、验证、Owner、变更和退役

条件。知识一旦更新、实例一旦失败、规则一旦发现歧义，就应回写到对应资产中，而不是只在个别聊天窗口里修正。

4. 多 Agent 只在分工清楚、价值足够时使用

Anthropic 对其研究系统的公开说明采用编排者—工作者模式：主 Agent 规划并分配任务，子 Agent 在相对独立的上下文中检索和分析，结果再被整合、引用和评测。文章同时说明，多 Agent 会增加协调复杂度、工具调用和成本；任务高度依赖、难以并行或价值不足时，并不适合采用这种结构。⁶ 因此，多 Agent 的企业问题不是“能否创建更多 Agent”，而是：哪些子任务真正独立？各自能看见什么？谁定义分工和努力预算？如何避免重复、冲突和信息污染？谁在异常时停止、恢复或转人工？如果无法回答这些问题，固定工作流、单 Agent 或人工协作往往是更可靠的选择。

六、组织如何开始：先重构一个工作单元，而不是重画组织架构

组织生产方式的变化通常从一个真实工作单元开始，而非从新的部门名称、岗位调整或全员工具推广开始。建议按以下路径推进。

1. **选择一个高频、可验证且人工备用可行的工作单元。**例如整理工单证据、准备技术变更说明、编写内部知识摘要或定位重复异常。避免一开始选择高影响决策、跨系统写入或责任边界模糊的任务。
2. **画出当前的人机分工。**明确哪些步骤由人定义、哪些可由 AI 协助、哪些必须复核、哪些动作只能由有权角色批准。不要以“是否使用 AI”替代流程设计。
3. **建立最小目标契约与上下文资产。**先定义目标、完成证据、范围、来源、权限、停止条件和 Owner；再建立必要的 Prompt、Skill、工作流或 Agent 合约，而不是把所有背景一次性塞进系统提示词。
4. **用真实结果更新协作系统。**将失败、评审意见、工具异常和高质量样本转化为 Golden Set、Skill 更新、工具说明、测试、Runbook 或培训材料。只有反馈能持续回写，局部提效才会成为组织能力。管理者应特别避免以调用量、Prompt 数量、Agent 数量或自动化率作为主要绩效。更值得奖励的是可验证的业务改进、知识更新、质量提升、风险信号被及时拦截，以及能被其他团队安全复用的协作资产。

七、三种常见误读

误读一：把公开公司实践当作通用蓝图。公开文章能说明当事团队采用了什么机制，却无法说明其他企业应使用同一模型、架构、人员比例或自主性。企业必须先用自身任务、数据、风险和证据验证。

误读二：把多步骤执行等同于业务自主。Agent 能够规划、调用工具并完成一段任务，不等于它能确定组织优先级、解释价值冲突、承担法律责任或接受不可逆后果。目标契约、审批、回退和 Owner 不能被省略。

误读三：把更多 Agent、更多上下文或更多工具等同于更高生产率。更长的运行链路会带来成本、协调、权限、状态和错误传播问题。只有当复杂性在内部评测和实际运行中带来可验证增益时，才应扩大。

八、本章行动清单

- [] 选择一个可在两周内观察到端到端结果的人机协作工作单元。
- [] 用“委托—复核—拥有”标出每个关键步骤的人类责任与可委托边界。
- [] 为该工作单元填写最小目标契约，并关联现有用例立项卡、上下文包和工作流/Agent 合约。
- [] 识别一项应从个人经验沉淀为 Skill、示例、脚本、Rubric 或 Runbook 的做法，并指定 Owner。
- [] 为一次异常、错误或高质量反馈设计回写路径，确认它会进入评测、知识、工具或培训资产之一。
- [] 在扩大到更多人员、工具或自主性前，复核业务价值、质量、权限、人工接管、运行证据和恢复能力。

本章小结

AI 时代的人机协同不取决于是否拥有最强模型，而取决于组织能否把目标、上下文、程序性知识、工具、反馈、权限和责任组织成可运行的协作系统。对话辅助、共同创作、Skill、工作流和 Agent 会长期共存；正确的选择是与任务和控制条件相称的选择。

人的角色并没有被取消，而是在更多场景中转向定义目的、判断边界、复核结果、承担责任和把反馈沉淀为资产。企业应先让一个工作单元变得可描述、可验证、可回退，再逐步扩大协作范围。下一章将讨论当组织对模型、上下文、工具和自动化形成更深依赖后，如何保持韧性与运营准备度。

参考资料

第 14 章 AI 依赖、韧性与运营准备度

稳定运行不等于从不出错。模型、工具、网络、知识、权限、数据、配置、人员和业务规则都会变化；真正可靠的组织不是假设 AI 永远可用，而是知道**什么时候应暂停、谁来决策、怎样转人工、如何恢复，以及怎样把事故教训变成下一次更强的控制。**

本章将韧性从抽象的“多模型备份”扩展为一套可运行的准备度体系：关键业务的人工底座、依赖可见性、事件分级、运行手册、恢复演练、复盘与持续改进。它适用于固定工作流、Skill、Agent 及其所依赖的模型、上下文包、知识、检索、记忆、工具与连接器。

韧性的目标不是承诺零中断或任意时限恢复。目标是在组织已定义的业务优先级、数据与风险边界内，能安全地停止错误动作、保持必要服务、恢复到已验证状态，并留下可学习的证据。

一、先定义什么必须在 AI 不可用时继续

AI 用例不是都具有相同关键性。应先由业务 Owner 识别关键业务结果、允许的降级方式和人工备用流程，而不是事后才问“AI 停了怎么办”。

业务关键性	典型特征	人工备用要求	建议准备度证据
低	个人效率辅助；不采用输出不会阻断服务	使用者可自行暂停或回到原有方式	用例立项卡中的原流程说明与使用边界。
中	高频团队流程；中断会造成延迟、返工或内部协作问题	有可定位的手工模板、队列或替代流程；指定负责人	工作流合约、人工备用卡、最近一次演练/检查记录。
高	面向客户、关键运营、重要决策支持或具有较高外部影响	有明确停用权、优先级、人工接管队列、沟通和恢复条件	运行手册、事件分级、演练记录、健康卡、风险/AIA 与发布限制。

人工备用不是要求员工永远重复做所有工作，也不是以惩罚性“禁用 AI 时长”替代能力建设。它要求关键角色在必要时能理解任务、核验结果、使用基础工具或模板完成最低服务，并知道何时应升级求助。具体能力基线应由业务风险和岗位责任决定，并纳入附录 A 第 47 节的人工备用与能力基线卡。

二、依赖可见性与可切换设计

AI 工作流的关键依赖不仅包括模型供应商，还包括模型/端点与项目配置、网关、编排平台、上下文包、知识库与索引、检索策略、持久记忆、外部工具/连接器、身份权限、网络、关键人员和业务规则。任何一项不可用、过期、错误写入或配置变化，都可能让“模型仍在线”的工作流实际失效。

1. 为每个关键用例画出最小依赖图

至少记录：业务用例和优先级、模型/工具事实卡、上下文包与数据/知识来源、检索与记忆策略、读写或发送动作、身份与密钥、运行环境、人工备用路径、责任人和恢复证据。模型与工具事实卡可帮助识别版本、端点、数据处理和退出限制，但不替代本用例的内部配置和运行测试。

依赖类别	需要回答的问题	可能的降级或切换方式
模型/API	哪个端点、版本、项目或区域失效会影响用例？	切换到经验证的候选方案；缩小功能；转人工。
工具与集成	哪个检索、文件、浏览器、数据库、消息或写入工具不可用？	关闭可选步骤；使用只读/人工流程；暂停写入。
上下文、知识与检索	权威来源、上下文包、索引、过滤、权限或更新链路失效时怎么办？	回到已验证版本；只处理可确认范围；转知识/上下文 Owner。
记忆与状态	任务状态丢失、摘要错误、记忆污染或跨用户混用时怎么办？	停止读取/写入受影响记忆；隔离、纠错或清理；回到任务记录和人工流程。
身份与配置	密钥、权限、路由、预算、策略或日志失效时怎么办？	停止自动动作；按批准流程恢复最小权限；启用人工处理。
人员与决策	Owner、审核者或关键操作人员不在时怎么办？	指定替补人、值守角色和升级路径；不能满足时暂停扩大范围。

2. 切换前先验证，不在事件中“临时换模型”

备用模型、工具或人工流程只有在以下条件满足时才是有效备份：已经在批准环境中完成适用范围和数据条件核验；使用同一 Golden Set 或受影响样本完成比较；已写入 workflow/Agent 合约；人工审核、成本、格式和回退条件明确；切换过程已通过演练。未验证的候选方案应视为研究选项，而不是事件中的直接替代品。

三、分级事件管理：先止损，再恢复，再学习

日常问题、计划变更和运行事件应区分处理。计划变更走回归与发布流程；事件是已经或可能已经造成实际错误、越权、数据/安全风险、严重服务中断、异常成本或人工接管失败的情形。

1. 事件分级参考

级别	典型情形	首要动作	决策与沟通
E0 观察/近失	被验证或监控拦截，未造成实际采用/影响；重复趋势值得关注	记录信号、保留样本、排查是否需要小修复	Skill/流程 Owner 在日常运营中处理；必要时更新健康卡。
E1 用例异常	质量显著下降、知识/上下文失效、记忆异常、工具/连接器失败、成本异常或人工	暂停扩大范围；必要时隔离受影响资产、回退稳定版本或转人工	业务/技术 Owner 处理，记录事件与恢复条件。

级别	典型情形	首要动作	决策与沟通
E2 严重事件	接管增加，但影响范围受控 错误内容被对外采用、越权尝试/动作、关键业务流程受阻、敏感数据或控制风险需要立即评估	停止受影响动作，启动人工备用，保全证据并按组织路径升级	业务 Owner 与适用技术/安全/风险角色共同决定恢复、通知与复盘。
E3 重大事件	影响范围广、可能造成重大权益/安全/合规/业务后果，或无法在已批准控制下安全运行	紧急停用或隔离，按组织事件响应/合规流程处置	由授权管理层和适用专项团队指挥；本手册的常规流程不足以单独处理。

不确定时按更高等级处理。事件等级不是为了追责个人，而是为了让停止、升级、沟通和恢复与影响相匹配。

2. 最小事件响应循环

发现/报警

↓

确认范围、级别与是否立即停止动作

↓

保全事实：上下文/知识/记忆/工具版本、输入/输出、来源、日志、配置、时间线与已采取措施

↓

转人工、回退稳定版本或隔离受影响依赖

↓

按等级通知业务/技术/风险等角色并进行恢复判断

↓

验证恢复：受影响样本、权限、知识、功能与人工备用

↓

完成复盘，更新资产、演练、风险/发布与证据索引

细化的事件运行手册、事件记录和复盘模板见附录 A 第 44–45 节。任何涉及敏感数据、外部影响、重大越权或疑似合规问题的事件，应优先遵循组织既有的安全、隐私、法务或行业事件流程。

四、运行手册与人工备用流程

运行手册 (Runbook) 是让接棒人员能在压力下采取正确动作的操作资产。它不应堆砌长篇技术说明，而应为每个关键用例回答：系统健康如何观察、哪些信号会触发暂停、谁有停用/恢复权、如何转人工、怎样回退、应保留什么证据、恢复前要验证什么。

Runbook 部分	最小内容	对应资产
用例与业务影响	用例编号、服务对象、关键性、不可接受后果、人工备用流程	用例立项卡、风险初筛/AIA。
依赖与健康信号	模型、上下文/知识/记忆、工具/连接器、权限依赖、健康阈值、预算/熔断与异常信号	事实卡、上下文包、记忆合约、工具控制卡、健康卡、Agent 或工作流合约。
暂停与升级	何时停止生成、发送、写入或自动动作；通知谁；谁决定恢复	风险等级、RACI、事件分级。
回退与恢复	上一稳定版本、人工模板、切换前提、恢复验证样本	发布登记、回归报告、人工备用卡。
记录与复盘	应保存的版本、样本、日志、时间线和改进项	事件记录、证据索引、Failure Casebook。

对低影响用例，Runbook 可以是一张短卡；对 R2/R3、外部沟通、Agent、写入或高关键性用例，应成为完整、可演练且可移交的运行资产。

五、恢复演练：验证“能切换”而不是假设“有备份”

演练应覆盖真实的故障模式和业务动作，而不是只做文档走读。优先场景包括：模型/API 不可用或明显退化、工具/连接器或知识源失败、上下文包或检索配置错误、记忆污染/丢失/隔离失败、权限/密钥失效、异常成本或循环、知识规则紧急变更、人工审核/接管不足，以及需要暂停对外或写入动作的情形。

每次演练至少验证四件事：能否发现异常并正确分级；有权人员能否停止动作并通知正确角色；人工或备用路径能否维持约定的最低服务；恢复后能否用受影响样本验证质量、权限和数据边界。演练不要求追求某个通用分钟数，而应记录本组织的实际发现、决策、切换、恢复和人工接管耗时，作为后续改进基线。

附录 A 第 46 节提供演练计划与记录模板。高关键性、R3 或依赖频繁变化的用例应在阶段提升、重大变更、移交前或健康信号恶化时优先演练；其他活跃用例可纳入月度或季度运营节奏。

六、复盘与持续改进

复盘的目标是改进系统，不是寻找替罪羊。应优先分析：任务/边界是否不清、上下文是否过量/过期/冲突/越权、知识是否过期或冲突、记忆是否错误写入或未隔离、Prompt/Skill/工作流是否存在缺口、模型或工具/连接器事实与配置是否变化、权限或预算是否过宽、人工审核是否被绕过、报警是否失效、以及备用路径是否真正可用。

复盘完成后，应明确每一项改进要更新哪些资产：风险初筛/AIA、事实卡、工作流或 Agent 合约、Golden Set、回归报告、发布登记、健康卡、Runbook、培训/接棒清单、组合台账或 Failure Casebook。没有 Owner、到期日和验证方式的“改进建议”不应被视为复盘闭环。

附录 G 用于沉淀去标识化、可复用的失败模式；附录 A 第 45 节用于保存具体事件的受控复盘记录。两者共同避免同类事故在不同团队中反复发生。

七、韧性 & 运营准备度复核

不建议用单一“总分”宣布组织安全。更有效的做法是每个关键用例定期回答以下问题，并将结论记录在健康卡、组合评审和证据索引中：

- 是否有经过验证的人工备用流程，并由能接棒的人员掌握？
- 关键模型、上下文/知识/记忆、工具/连接器、权限和人员依赖是否可见，是否有失效或变更信号？
- 上下文包、记忆和工具控制记录能否定位上一稳定版本，并支持隔离、回退、清理或恢复？
- 是否能在不扩大风险的前提下暂停、回退、切换或降级？
- 最近一次事件或演练暴露了什么问题，是否已按期关闭？
- 发布、移交或阶段提升后，Runbook、事实卡、评测和责任人是否仍与实际运行一致？

当关键问题无法回答、人工备用不可用、停止权不清、证据缺失或演练失败未关闭时，应暂停扩大范围，优先恢复控制能力。

八、本章行动清单

本周内完成：

- [] 为一个活跃用例指定业务关键性、人工备用流程、停用/恢复权和替补人。
- [] 为该用例填写附录 A 第 44 节运行手册，至少覆盖一个模型、上下文/知识/记忆或工具/连接器失效情形。
- [] 把最新依赖、事实卡、上下文包、记忆/工具控制记录、发布版本、健康信号和证据位置关联起来。

下一个运营周期内完成：

- [] 选择一个现实场景完成一次恢复演练，并记录实际发现、转人工、恢复与待改进项。
- [] 对一次真实事件或近失完成附录 A 第 45 节复盘；匿名化后沉淀到附录 G。
- [] 在 FDE/AI COE 移交或用例阶段提升前，验证接棒 Owner 能执行 Runbook、转人工和基础回退。

九、本章小结

成熟的 AI 运营不是追求最大自动化率，而是维持对关键业务、数据、决策和依赖的控制权。组织需要把人工能力、模型/工具替代、知识与权限、事件响应、恢复演练和复盘当成产品的一部分，而不是在故障发生后临时补救。

当团队能够安全停止、清楚升级、维持最低服务、验证恢复并把经验转化为更好的资产时，AI 才能从脆弱的效率工具变成可靠的企业能力。

第 15 章 安全与合规：企业 AI 不可回避的问题

前面章节聚焦“如何让 AI 稳定产出”，但企业场景中还有一个前置约束：安全与合规。工作流即使在技术上表现稳定，若其数据处理、上下文来源、记忆、工具/连接器权限、输出或运行方式不符合组织制度、合同或适用要求，也不应进入相应用例范围。

本章提供用于内部控制设计的安全与合规框架，帮助团队在设计最小闭环时同步识别相关问题，而不是在事件发生后才补救。它不替代法律、隐私、信息安全、采购、合同或行业专业意见。

一、数据敏感度分级

在设计任何 AI 工作流之前，先对涉及的数据做敏感度分级。这一步决定了后续所有安全决策的基础。

级别	定义	典型数据	能否输入 AI	处理要求
L1 公开	已对外公开，或经确认无保密要求	产品手册、公开公告、新闻稿	视来源、许可和组织政策而定	确认使用范围；需要时保留来源与版本。
L2 内部	仅限内部使用，非公开且影响相对有限	内部流程文档、团队周报、未发布产品计划	经评估后可在批准范围内处理	确认用途、访问、留存、工具/端点与数据流。
L3 机密	泄露可能造成业务、合同或声誉损害	合同条款、定价策略、客户名单	需在受控条件下逐案判断	最小必要、脱敏/替代、批准环境、权限、留存和风险评估。
L4 高敏感或高度受限	泄露可能造成重大法律、商业或个人影响	核心源代码、并购计划、未公开财务数据	默认不进入未获专门批准的外部处理环境	由适用安全、法务、隐私和业务角色决定是否可处理及所需控制。

分级操作步骤

1. 列出数据清单：列出工作流涉及的每类输入数据
2. 逐项标注级别：按组织数据分类制度并由适用的业务、安全、隐私或法务角色确认；无法判断时，暂按较高风险处理并缩小范围。
3. 确定处理方式：根据级别决定能否使用、如何脱敏、用什么部署方式
4. 记录留档：将分级结果写入工作流文档，作为安全审查依据

关键原则

- 不确定级别时，先按较高风险处理，或暂停该数据进入工作流。
- L3 数据进入 AI 工作流前，应依据具体数据、用途和环境落实最小必要、脱敏/替代、访问与留存控制；脱敏并不自动消除所有风险。
- L4 或同等高度受限数据是否可处理，应由适用角色依据实际环境、合同、权限和控制作出专门决定；“私有化部署”本身不等于自动获批。

- 同一 workflow 混合不同级别数据时，应以最高风险数据的控制要求为基线，并核验数据之间的关联风险。

二、PII（个人身份信息）处理

PII 常被用作个人信息或可识别信息的简称，但其法律定义和处理要求取决于适用地区、业务关系与数据类型。以下内容用于帮助团队识别常见字段和控制问题，不构成完整的法律分类或处理结论。

需要脱敏的常见 PII 字段

字段类型	脱敏方法	示例
姓名	替换为角色/编号	张三→用户 A/用户_001
手机号	保留前 3 后 4，中间掩码	13812345678→138****5678
身份证号	保留前 6 后 4，中间掩码	110101199001011234→110101*****1234
邮箱	保留@后域名，前缀掩码	zhangsan@company.com→z@company.com
地址	模糊化到城市/区级	北京市朝阳区 XX 路 XX 号→ 北京市朝阳区
银行卡号	保留后 4 位，其余掩码	6222021234567890→7890

脱敏操作的两条原则

1. **在处理链路进入模型或工具前完成保护。**不应仅依赖模型自行判断哪些信息需要保护；具体方法应由数据类型、业务目的和已批准环境决定。
2. **区分可逆与不可逆处理。**只有在确有业务必要和适当授权时才保留映射关系；映射表、密钥和重识别能力应按组织分类、访问和留存规则单独保护。

常见误区

- 只脱敏姓名：忽略了手机号、地址、邮箱等同样可识别个人的字段
- 脱敏后不映射：输出中出现了“用户 A”但无法对应回真实用户，导致结果不可用
- 仅在提示词中写脱敏规则：模型可能遗漏或处理不一致。应优先在进入模型或工具前采用经批准的处理和审核机制。

三、模型与工具的数据处理条件

使用外部模型、API、托管平台、文件/状态化功能、第三方工具或连接器时，一个关键问题是：**在这个具体版本、端点、项目配置、地区、合同和功能组合下，哪些数据会被传输、留存、用于服务运行或交由第三方处理？**这类条件不能从模型名、产品版别或“API/私有部署”等标签直接推断。

三类处理安排的判断方式

处理安排	需要核验的内容	控制含义
未核验或条件不清	端点、功能、文件/状态数据、日志、训练使用、地区、子处理者和删除条件均未能确认	不应承载正式或敏感用例；先建立事实卡并缩小到可控范围。
有条件的数据控制	供应商政策、合同、项目配置或功能资格明确，但仅在特定范围内适用	将适用前提写入事实卡、风险初筛、AIA 和工作流合约；

处理安排	需要核验的内容	控制含义
		不得外推至其他功能或第三方集成。
组织可控的处理环境	组织对部署、存储、访问、日志、备份和删除有更强控制	仍需评估供应链、运维权限、模型/工具依赖、日志和人工误用；“自建/私有”不自动等于低风险。

检查清单

在正式使用任何模型、工具、端点或集成前，确认以下事项：

- [] 已在动态事实卡中记录官方数据处理资料、适用版本/端点/功能、核验日期和限制。
- [] 已核验实际项目配置、合同或批准范围，而不只查看公共产品页面。
- [] 已识别提示、上下文包、检索结果、工具返回、记忆、响应、文件、状态、日志、缓存、工具调用和第三方集成的相关数据流。
- [] 已确认数据留存、训练使用、地区、访问、删除和子处理者条件与组织制度相符。
- [] 已与适用的安全、法务、隐私或行业角色确认处理方式；不确定时按更高风险处理。
- [] 已记录所使用的模型、端点、工具和配置版本，并在变更时复核。

注意事项

- 个人界面、消费者产品、API、企业项目、托管云、文件功能、浏览器插件、远程工具和第三方集成可能适用不同的数据处理条件，应逐项核验。
- 模型、端点、功能、项目设置或合同变化时，已有数据处理结论可能失效；应更新事实卡并判断是否需要重新做风险初筛、AIA、回归和发布登记。
- 处理条件符合要求并不等于该用例自动获批；仍需满足业务边界、质量、权限、人工控制和回退要求。

四、法规合规要点

不同行业和地区有不同的法规要求，以下是企业 AI 使用中最常涉及三类：

1. 数据保护法规

法规	适用范围	核心要求	对 AI 工作流的影响
中国个人信息保护相关要求	处理与中国相关的个人信息时可能适用	处理目的、合法基础、最小必要、告知、权利响应和安全义务等需结合具体情形判断	在设计数据流、留存、授权、跨境、委托处理和权利响应前，应取得适用专业意见。
GDPR 及相关欧洲数据保护要求	处理与欧洲经济区相关的个人数据时可能适用	合法基础、透明度、数据主体权利、处理者安排、跨境和安全义务等需结合具体情形判断	数据生命周期、删除/更正请求、供应商安排和自动化决策影响进入适用审查。

法规	适用范围	核心要求	对 AI 工作流的影响
行业、合同与组织要求	金融、医疗、教育、公共服务或特定客户合同等场景可能适用	数据分类、保密、留存、审计、地点、人员资质或审批要求各不相同	不应以“行业数据”作统一技术处理结论；应按实际规则、合同和控制环境确定。

2. 输出合规

AI 生成的内容可能涉及以下合规风险：

风险类型	典型场景	防范方法
虚假宣传	AI 生成的营销文案含不实承诺	人工审核后发布，禁止直接对外
版权、商标或其他知识产权问题	输出与既有作品、品牌、素材或受限内容存在相似、引用或使用边界问题	按组织内容、来源、许可与法务复核流程审查；保留必要的来源、版本和审核记录。
歧视性或不当差别影响	输出用于分类、推荐、筛选或判断时可能产生不公平结果	明确用途边界，进行适当的人工审查、样本测试和影响评估。
不当专业建议	输出可能被理解为医疗、法律、财务或其他专业意见	不将免责声明作为唯一控制；应限制用途、设置人工专业审核和适当的升级路径。

3. 上下文、工具与记忆的安全边界

Agent、检索和连接器会把外部内容带入模型上下文，也可能让模型提出或执行工具动作。企业不应把“来自内部系统”或“由工具返回”自动视为可信指令。文档、网页、邮件、工单、检索片段和工具返回都可能包含与任务无关、误导性或试图改变行为边界的内容；它们应被当作数据处理，而不是比系统规则、审批或状态机更高的指令。

风险面	典型问题	最低控制
不可信上下文与提示注入	外部文本诱导模型忽略规则、泄露资料或调用不应使用的工具	指令与数据分离；来源白名单；不将检索/工具返回当作可执行指令；异常内容停止或转人工
过量与越权加载	检索或工具返回整库、跨用户或超出任务范围的资料	上下文包、字段/返回量限制、过滤、最小权限和审计
持久记忆	将假设、敏感原文或跨用户信息写入长期状态	记忆合约、事实/假设标记、隔离、保留期、删除、纠错和回归

风险面	典型问题	最低控制
工具/连接器	参数越界、写入/外发、凭证滥用、恶意或异常返回影响后续步骤	工具控制卡、动作白名单、审批、超时/预算/熔断、沙箱和日志

4. 审计与追溯

企业正式使用的 AI 工作流应满足审计要求：

- [] 可追溯输入数据、上下文来源、检索/工具返回和记忆的来源、范围与版本
- [] 可追溯使用的 Prompt、上下文包、工具/连接器、模型与状态版本
- [] 可追溯输出结果、拟执行或已执行动作及是否被采用/批准
- [] 可追溯人工检查、接管、停止、回退和纠错记录
- [] 输出、审核、版本和相关记录的留存范围与期限已按组织政策、合同和适用要求确定

五、从数据分级到用例风险治理

数据分级回答“数据能否、如何被处理”，但企业还必须回答“该用例会影响谁、是否有写入或对外动作、出错后能否回退、现有控制是否足够”。因此，安全合规不应只在上线前做一次勾选，而应进入用例立项、工作流设计、变更、发布和运行复核的控制链。

1. 用例级风险初筛：先确定控制强度

在填写用例立项卡后，先使用附录 A 第 34 节完成风险初筛。初筛不以复杂打分代替判断，而是从七个问题判断控制强度：业务影响是否高、是否含敏感或不可信数据、是否面对外部或影响个人权益、上下文来源与记忆是否可控、是否读写系统或调用工具/连接器、是否提高自主性、是否具备可验证的人工接管和回退。

初始等级	适用方向	最低动作
R1 基础	低影响内部辅助、人工最终采用、无写入/外发	明确边界、Owner、质量验证、版本与人工回退。
R2 受控	外部草稿、跨系统读取、L2/L3 数据、固定多步骤工作流	影响评估、知识版本、Golden Set、回归、发布观察、最小权限和人工审核。
R3 高影响	高敏感数据、写入/发送、重要权益或业务影响、复杂 Agent	适用角色审查、严格权限与审批、异常/接管演练、审计证据与更严格发布门。
R4 暂缓或转专项治理	目的、Owner、数据边界、回退或基础控制不清	暂停标准路径的设计/发布，先解决阻塞项或走组织专项流程。

等级应按最严重的影响因素确定；当数据、影响、权限或恢复能力存在不确定性时，应上调等级或缩小范围。附录 A 第 34 节给出了完整初筛表和风险—控制等级参考。

2. AI 影响评估：说明残余风险为何可接受

R2、R3 用例，以及范围、数据、模型、工具、权限、自主性或业务影响发生重大变化的用例，应使用附录 A 第 35 节完成 AI 影响评估（AIA）。它要求业务、流程、知识和技术责任人共同说明：受影

响对象、数据流与知识来源、可能的不利影响、控制 Owner、所需证据、人工接管与恢复方式，以及发布后仍需承担的残余风险。

AIA 的目标不是追求“零风险”。它的目标是避免用“模型表现不错”替代业务判断：组织应清楚哪些风险被减少、哪些风险被保留、谁有权接受这些残余风险，以及何时必须重新评估。

3. 风险—控制—证据必须连在一起

一个控制如果没有 Owner、没有运行证据或无法在异常时被执行，就只是文字承诺。附录 A 第 35 节的风险—控制矩阵把数据、上下文/知识/记忆、输出、对外影响、工具/连接器权限、运营韧性和审计记录分别连接到控制和证据；附录 A 第 37 节的审计证据索引则让授权人员能够定位立项、评测、发布、例外、运行和回退记录。

建议采用以下最小路径：**用例立项卡 → 风险初筛 →（需要时）AIA → workflow/Agent 合约 + 上下文包/记忆合约/工具控制卡 → Golden Set 与回归 → 发布登记与观察期 → 健康卡与阶段复核**。当任一环节发生重大变化或出现事件时，应回到风险初筛或 AIA，而不是仅修改提示词后继续运行。

4. 例外不是绕过治理

确有业务必要但暂时无法满足某项内部控制时，可使用附录 A 第 36 节提出有范围、有补偿控制、有到期日的例外申请。例外不应用于豁免法律、监管、安全基本要求或不可接受风险；无法通过缩小范围、人工审核、权限限制、监控与回退控制的情形，应暂停或转组织专项治理。任何例外都应进入发布登记、健康卡和证据索引，并在到期前关闭、补齐控制、续期或退役。

六、安全合规自检清单

在每个 AI 工作流正式上线前，使用此清单做一次安全合规检查：

数据敏感度分级

- [] 已列出相关输入数据并标注敏感度级别（L1–L4）
- [] 对 L3 及以上数据已落实与实际环境相称的最小必要、保护、访问、留存和审批控制
- [] 分级结果已由适用角色确认；无法确认时已缩小范围、暂停处理或按较高风险处理

用例风险与影响

- [] 已完成附录 A 第 34 节的用例风险初筛，并记录控制等级与理由
- [] R2/R3 或发生重大变化的用例已完成附录 A 第 35 节的 AI 影响评估
- [] 已明确业务影响、人工保留决定、写入/外发边界、停止与回退条件
- [] 如有例外，已限定范围、补偿控制和到期日；不以例外替代基础合规要求

PII 处理

- [] 已识别输入中相关的个人信息或可识别字段
- [] 在进入 AI 或相关工具前，已按批准方案完成最小必要、保护或替代处理
- [] 如保留映射表或重识别能力，已按组织规则单独保护

数据留存与 Agent 运行状态

- [] 已确认 AI 服务、上下文/检索、工具/连接器和持久记忆的数据留存策略
- [] 对 L3 及以上数据，留存、删除、访问、地点和处理环境已按批准条件配置并记录
- [] 模型版本、服务配置、上下文包、记忆和工具/连接器版本已记录

上下文、工具与行动边界

- [] 已定义允许来源、排除来源、来源优先级、返回量和信息不足/冲突时的停止或转人工条件
- [] 已对不可信文档、网页、邮件、检索片段和工具返回设置数据处理边界，不将其自动视为可执行指令
- [] 工具/MCP/连接器的动作、参数、读写范围、审批、超时、熔断、日志和退出方式已按风险确认
- [] 持久记忆（如使用）的写入、隔离、失效、删除与人工纠错方式已确认

输出合规

- [] 输出经人工审核后发布（不直接对外）
- [] 涉及专业领域（如医疗、法律、金融）的输出已按适用范围设置限制、审核与升级路径
- [] 输出留存策略已确定

审计追溯

- [] Prompt、上下文包、输入数据、来源/检索/工具返回和记忆版本可追溯
- [] 输出结果、拟执行/已执行动作及人工检查/审批记录可追溯
- [] 回归报告、发布登记、审批/例外、异常与回退记录可定位
- [] 已更新附录 A 第 37 节的审计证据索引，并按组织政策设置留存期限

七、本章使用建议

1. 在设计最小闭环时就识别数据、权限和输出边界，避免在后期返工或扩大后才发现基础限制。
 2. 不用“合规”作为笼统的停止或推进理由：先明确实际处理的数据、目的、环境、合同和控制条件，再决定是否继续、缩小或转专项审查。
 3. 与安全、隐私、法务和业务角色共同设计控制：尽早提供数据分级、数据流、脱敏/替代方案和用例边界，便于形成可执行结论。
 4. 定期复查：模型版本、法规、合同、工具配置或业务范围变化时，都应判断是否需要重新检查安全与合规条件。
-

第 16 章 公开案例、教学情景与完整案例集

本章使用两类材料。**公开案例**来自可追溯的裁决、机构公开信息或媒体报道，用于说明控制问题为何真实存在；**教学情景**则用于演练任务定义、风险、评测、发布和回退资产。两类材料不能混用。

证据边界：公开案例只支持其来源所记载的特定事实，且必须说明其时间、辖区、来源等级和不可外推事项。除非明确链接到可复核来源或受控运行证据，教学情景中的组织、任务、时间、比例、成本和结果均为去标识化或抽象化设定，不构成任何企业的效果承诺、行业基准或生产验收结论。真实项目应使用 evidence/ 目录和附录 A、B 的资产记录实际样本、审核、风险、发布和运行证据。

读者应借鉴控制逻辑而非复制数字：先明确任务和责任，再按自身业务、数据、专业风险和制度进行验证、回退与决策。案例来源等级、完整事实边界和复核规则见附录 D。

一、公开案例：为什么控制链不可省略

案例	已核验的有限事实	对手册的控制启示	不可外推事项
Air Canada 聊天机器人信息错误	加拿大卑诗省民事纠纷仲裁处在特定纠纷中认定，航空公司应对其网站聊天机器人提供的错误丧亲票价信息负责。 1	对外回复需管理权威知识、版本/生效范围、承诺边界、人工升级和纠错证据。	不是全球通用的法律规则。
纽约市 MyCity 商业信息聊天机器人	调查报道发现该机器人给出与纽约市规则不一致的劳动、住房和现金支付信息；后续报道记录纽约市长承认系统存在问题，且网站强化了“不得作为法律或专业建议使用”的提示。 2 3	高影响问答不能仅依赖免责声明；应设定来源定位、拒答/转人工、风险样本、发布门和事件闭环。	不是对所有公共服务系统的质量结论。
三星公共工具数据边界事件	CNBC 报道称三星确认出现误用后，暂时限制员工在公司个人电脑上使用相关生成式 AI；具体敏感数据输入来自其他媒体的转述。 4	Shadow AI 治理应同时提供数据分类、批准路径、受控替代方案、培训和事件响应。	不证明数据被训练或向其他用户泄露。

案例	已核验的有限事实	对手册的控制启示	不可外推事项
Morgan Stanley 内部知识助理	官方公告称其研究助手支持带链接的检索、综合和邮件草稿，供员工修改后分享；共同案例描述了评测与人工审核机制。 ^{5 6}	从检索、摘要和草稿等可限定任务起步；将评测、引用和人工定稿视为产品能力。	当事方自述的采用率或效率不能作为一般企业目标。
GSA 与美国劳工部用例库存	官方库存区分预部署、试点和已部署的 AI 用例及其用途。 ^{7 8}	用例台账应区分项目意图、试点、部署与已验证价值。	政府分类和公开义务不自动适用于私营组织。
PocketOS AI 编码 Agent 事故报道	Guardian 根据创始人陈述报道其生产数据和备份被删除；报道说明厂商未立即回应置评。 ⁹	破坏性动作应依靠最小权限、隔离、独立授权、异地备份和恢复演练控制，而非提示词禁止语。	未公开完整独立技术复盘，不能推导特定工具或模型的一般行为。

二、教学情景一：周会纪要与待办提取（个人/小团队起步场景，非实际运行记录）

1. 背景

某产品团队每周五召开例会，时长 60–90 分钟。会后由产品经理整理纪要和待办，平均耗时 40 分钟。常见问题包括：决议遗漏、待办描述模糊、负责人或截止日期缺失、格式不统一。

2. 目标

- 以当前人工流程为基线，观察端到端整理与核验时间是否改善。
- 确保关键决议、待办、责任人和截止时间可由会议参与者核验。
- 输出遵循固定结构，并能在人工确认后进入协作文档。

3. 具体执行步骤

步骤 1：任务定义

- 触发：周会结束后
- 输入：完整会议转写文本
- 输出：结构化纪要+待办列表（负责人、行动、截止日期）
- 质量标准：无关键决议遗漏、待办可直接执行、格式统一

步骤 2：准备材料 收集了近 4 次会议的人工纪要作为示例，并整理了一页「必须包含的字段」和「禁止把讨论建议写成决议」的规则。 步骤 3：提示词模板（最终版核心部分）

角色：产品团队会议纪要助手

任务：根据提供的会议转写，生成结构化纪要和待办列表。

规则：

- 只记录明确达成的决议；讨论中的建议不写入决议。

- 每条待办应包含负责人、具体行动和截止日期；信息未明确时标记为“待确认”。
- 按以下格式输出；不要增加未定义章节。

输出格式：

- 会议基本信息：日期、参会角色。
- 关键决议：编号列表。
- 待办事项：

待办事项	负责人	行动描述	截止日期
---	---	---	---

步骤 4：验证清单

- [] 所有明确决议已记录
- [] 待办均有负责人
- [] 行动描述具体可执行
- [] 无把建议误写为决议
- [] 格式完全符合模板

步骤 5：测试与迭代 在情景化试运行中，团队先用少量历史会议材料测试，发现模型会把“建议”误写为决议。随后补充反例与验证规则，并以相同口径的样本重新比较。真实项目应记录样本范围、版本、审核结论、端到端耗时和未通过原因，而不应直接套用本案例中的数字。

4. 结果

在该情景的扩大前，团队需要先在单一会议类型中积累足以判断的样本与审核记录，并确认格式、关键字段、人工负担和回退流程可接受。不同会议类型的参会角色、决策结构和敏感边界可能不同；扩展到新会议前应重新评估并回归受影响样本。

5. 可复制要点

规则中明确“什么不能写”比只说“写什么”更有效；验证清单必须包含业务侧易错点；先在单一会议类型跑稳，再扩展。

6. 从 workflow 升级为 Skill 资产

当该场景已连续稳定运行后，团队不应只保留一段 Prompt 和一张检查清单，而应先以 UC-PROD-001 作为用例主键记录业务问题、基线、边界、Owner 与下一次决策，再将它升级为“产品周会纪要提取与核验 Skill”。附录 A 第 13 节的已填写 Skill 卡和第 28 节的产品周会纪要 workflow 合约分别固化了能力与流程层的适用边界、输入输出、受控组件、验证、人工控制、回退、责任人、指标和变更记录。这一升级带来三个实际收益。第一，第二位同事可以依据同一张卡独立运行，不再依赖原作者口头交接。第二，团队可以在规则、示例、模型或知识变化后，知道应该回归哪些历史会议样本。第三，若后续把纪要生成、待办检查和发布前确认连接为自动化流程，系统也只能调用这张已验证的 Skill，而不是重新使用未经治理的自由 Prompt。

本案例不需要 Agent：会议纪要、待办提取与人工确认的顺序明确，使用固定 workflow 即可获得更高可控性。若仅为“更自主”而加入动态规划，通常难以证明其额外价值足以覆盖新增的治理成本。只有在固定步骤无法满足业务需要，且额外收益、权限、验证、回退和运行证据都已明确时，才应评估是否引入更高自主性。

• •

三、教学情景二：客户咨询标准回复起草（业务团队场景，非实际运行记录）

1. 背景

客服与销售支持团队每天处理大量重复性咨询（物流、退换货、活动规则等）。平均每次回复耗时 8–15 分钟，存在口径不统一、遗漏关键提示的问题。

2. 目标

- 以当前人工回复流程为基线，观察端到端处理时间和审核负担是否改善。
- 使草稿可定位到当前适用的规则、版本和生效范围。
- 保留人工对采用、修改、转人工和发送的最终决定。

3. 具体执行步骤

步骤 1：场景选择与范围控制 只选择高频、规则清晰的 6 类问题作为第一期，明确排除涉及补偿决策和投诉升级的内容。步骤 2：知识准备 由业务负责人整理《当前标准答复要点》（按问题类型分类，每类不超过 300 字），并标注生效日期。过时内容全部移除。步骤 3：工作流设计

1. 使用者粘贴客户原话+选择问题类型
2. 模型根据对应要点生成回复草稿
3. 人工对照检查清单确认后发送

步骤 4：提示词关键结构

- 强制引用对应问题类型的标准要点
- 要求回复中必须包含指定的关键提示语
- 输出分为“回复正文”和“使用的要点来源”两部分，便于检查

步骤 5：验证清单（部分）

- [] 使用了正确问题类型的最新要点
- [] 包含必须提示的关键信息
- [] 无额外承诺
- [] 语气符合团队规范

4. 结果

在情景化试运行中，团队会将限定类别的草稿、审核、修改、转人工和知识版本记录在同一证据链中。是否扩大到更多类别，应由实际的 Golden Set、知识时效、人工审核能力、风险控制和观察期证据决定；不应以本案例的时间或比例作为通用门槛。

5. 可复制要点

严格控制第一期范围，只用规则最清晰的问题；知识必须有责任人和生效日期；输出中要求模型自报“使用了哪些要点”，方便快速验证。

6. 从回复草稿升级为业务类 Skill

当这六类问题已经稳定运行后，团队应先填写 UC-CS-001 用例立项卡，确认外部沟通边界、知识时效风险、人工保留决策和停止条件，再将其升级为“客户咨询标准回复草拟与核验 Skill”。附录 A 第 27 节提供已填写的用例立项卡，第 16 节提供关联 Skill 卡：两者共同补齐了适用边界、禁止事项、知识版本、来源展示、自动与人工验证、异常转人工、回退、责任人和运行指标。

这一类 Skill 与会议纪要 Skill 的关键差异在于：它面向外部客户，业务规则具有时效性，且错误可能被理解为承诺。因此，生成结果只能是草稿，必须由经培训人员核对问题类型、知识来源、版本、生效日期、关键提示和禁止承诺后，才可发送。即使一次通过率较高，也不应因为追求效率而跳过发送前确认。

7. 知识变更到限量发布的闭环

在一次知识规则变更情景中，活动规则发生更新。团队没有直接替换知识库内容，而是先由活动运营负责人确认新规则的权威来源和生效时间；知识责任人将活动规则条目升级为新版本，并标注旧版本失效范围；Skill 责任人据此列出受影响的问题类型、Prompt、正确示例、错误示例和验证字段。随后，团队选择正常咨询、活动已结束、不符合参与条件、曾遗漏截止日期的历史失败样本，以及要求例外补偿的转人工样本进行回归。回归不仅检查回复正文是否流畅，还检查是否引用最新要点、是否正确展示截止日期、是否会把例外请求转人工。通过后，团队仅向已培训的小范围使用者开放活动类咨询，并维持每条草稿的人工确认；观察期内一旦发现日期、适用商品或承诺口径错误，立即回退到上一稳定知识版本和人工回复流程。

这个闭环的价值不在于增加流程，而在于让团队清楚知道“规则变了以后，究竟影响了什么、如何证明修复有效、出问题后如何停止”。对应的 Skill 卡、变更记录与发布安排见附录 A 第 16 节和第 17 节；附录 A 第 33 节给出了应覆盖正常、边界、历史失败和转人工情形的 Golden Set 示例，实际比较结果应记录在第 31 节的回归报告中，并通过第 32 节的发布登记限定观察范围。附录 A 第 38 节进一步示范了此类对外沟通用例如何完成 R2 风险初筛、影响评估与控制证据连接。第 5 章第六节提供了按知识变更风险分层的通用方法。

四、教学情景三：周报初稿生成与数据异常标记（运营场景，非实际运行记录）

1. 背景

运营团队每周一需提交周报，包含核心指标、异常说明和下周计划。人工从多个表格取数、写描述，平均耗时 70 分钟。异常经常被遗漏或描述不准确。

2. 目标

- 以当前人工周报流程为基线，观察端到端准备与核验时间。
- 确保由规则命中的异常可追溯，并由人工确认原因。
- 记录数据来源、版本和异常判断依据。

3. 具体执行步骤

步骤 1：输入标准化 要求所有数据源在周五下班前按固定模板更新到指定表格（指标名称、本周值、上周值、目标值）。步骤 2：工作流拆分

1. 数据汇总与异常自动标记（模型处理）
2. 异常原因初稿生成（模型处理）
3. 人工确认数据与补充原因
4. 生成完整周报结构

步骤 3：异常判断规则（写入提示词）

- 波动超过 $\pm 15\%$ 且绝对值超过设定阈值→标记为需说明
- 连续两周朝同一方向偏离目标→标记为需说明

步骤 4：验证重点

- 数据与原始表格一致
- 所有被规则命中的异常均有说明
- 无编造未提供的原因

4. 结果

在情景化试运行中，团队应先核验输入表结构和异常规则，再比较人工流程与候选工作流的端到端耗时、异常发现、误报、漏报和人工修改。确认规则在目标范围内可用后，再将其沉淀为共享标准，并为规则变化保留回归机制。

5. 可复制要点

- 先统一输入格式，再让模型处理。
- 用可解释的异常规则降低主观性，并定期检查规则是否仍适用。
- 将“数据一致性检查”放在验证清单的优先位置。

五、教学情景四：合同条款风险审查（选错场景的典型，非实际运行记录）

1. 背景

设想一个法务团队希望用 AI 自动标记合同风险条款。团队若因“AI 能读合同”的演示而直接启动项目，却未先评估漏检后果、验证成本和专业责任，就可能面临范围选择错误。

2. 目标

- 协助识别合同中可能需要进一步审查的条款，例如自动续约、责任限制或单方解除限制。
- 在不降低法务专业审查责任的前提下，评估该辅助是否减少可验证的重复工作。

3. 执行过程

第一阶段（第 1-2 周）：提示词与测试 模型确实能“识别”风险条款——输出格式工整，每条都标注了风险等级和依据。团队一度非常乐观。第二阶段（第 3-4 周）：问题浮现 在情景化复核中，资深法务可能发现：

- AI 标记了约 40% 的条款为“有风险”，其中大量是标准商业条款（法务称“每份合同都有，不需要标记”）
- 真正的高风险条款（如隐藏的自动续约条款），AI 时有遗漏——第 4 周测试的 8 份合同中有 2 份漏掉了关键条款
- 更麻烦的是，AI 给出的“风险依据”看起来专业且合理，但经常是对条款含义的误读。这迫使法务必须逐条重读原文，而无法只看 AI 摘要

第三阶段（第 5-6 周）：尝试修复 团队按本书第 3、5 章的方法迭代了三轮提示词，增加了大量正反面。标记准确率有提升，但漏检率始终无法降到可接受水平——法务的结论是：“只要还可能漏，我就必须全文重读，那 AI 就没帮我省任何时间。”

4. 回退决策

第 6 周末，项目停止。判断依据非常清晰：

判断项	实际情况	是否满足第 5 章场景标准
失败成本可控	漏检高风险条款可能导致重大法律损失	不满足
输出可验证	验证需要完整法律专业能力，无法快速检查	不满足
单次任务耗时 15-90 分钟	合同审阅平均 90 分钟以上，且不可分割	边缘不满足

若在真实评估中出现上述组合情形，团队应暂停将其作为自动标记优先场景，并重新界定可辅助的低风险子任务；这不等于 AI 不能参与合同工作，而是说明当前任务边界、验证与责任设计不适合直接扩大。

5. 教训

- “AI 能做”不等于“这个场景应当这样做”。即使模型能生成看似专业的分析，团队仍需根据漏检后果、专业责任和回退能力决定参与边界。

- 验证成本可能抵消生成收益。若人工仍需以接近原流程的成本完成完整审查，团队应重新评估价值假设和可辅助的子任务。
- 当出现持续的依据误读、关键漏检或无法解释的差异时，应回到用例选择、风险和验证设计，而不是只在提示词上反复加规则。

六、教学情景五：跨系统自动周报（过早追求全自动的典型，非实际运行记录）

1. 背景

设想一个运营团队在周报场景中跑通了单任务闭环后，决定一步到位升级为“全自动”：让 AI Agent 登录多个内部系统拉取数据、生成图表、撰写分析并发送邮件，且不设置人工确认。该情景用于说明多步骤自动化新增的依赖、权限和错误传播风险。

2. 目标

- 在明确范围内减少重复的数据整理与初稿撰写工作。
- 仅在数据、异常、权限、发送边界和人工接管均可验证后，评估是否提高自动化程度。

3. 执行过程

第一阶段（第 1-3 周）：搭建多步流程 搭建了“登录系统 A 拉数据→登录系统 B 拉数据→汇总计算→生成图表→撰写分析→发送邮件”的六步自动化链路。第二阶段（第 4-6 周）：错误沿链条放大问题很快暴露：

- 系统 B 的页面改版导致数据拉取失败，流程在第二步中断，但周一的邮件已经按“空数据”发出了两期——收件人看到了一份指标全部为零的“正常格式”周报
 - 某次系统返回了错误数据（数据端重算未完成），Agent 如实汇总，生成了一份数字全错但格式完美的周报，团队基于这份周报做了错误决策
 - 定位一次失败原因平均需要 60-90 分钟：问题可能在六个环节中的任何一处，且没有环节级的日志
- 第三阶段（第 7-8 周）：尝试加固 给流程加了数据校验节点和失败重试，失败率下降，但每加一层防护，维护成本就上升一截。团队两个人的维护时间，已经超过了原本每周 70 分钟的人工周报耗时。

4. 回退决策

第 8 周，团队放弃全自动方案，回退为两段式结构：

1. 数据拉取：退回使用各系统自带的定时导出（系统原生功能，零维护成本）
 2. 分析撰写：保留已跑通的 AI 单任务闭环（案例三模式），人工确认后发送
- 回退后的两段式方案保留数据准备与人工确认，将 AI 限定在已验证的分析撰写步骤。真实团队应比较端到端耗时、维护、错误发现、人工接管和业务影响，而不应以“零人工”或单一时间节省作为唯一目标。

5. 教训

- 单任务表现不等于多步骤链路表现。每增加一个依赖、状态转换或动作，都需要重新评估错误传播、观测和回退；链路可靠性不能只由单步骤通过率简单推算。
- 上游数据、工具或权限异常可能被后续格式化掩盖，因此应在关键节点设置数据验证、停止条件和可定位日志。
- “零人工”不是唯一目标。对外发送、关键数据或高影响决定通常需要与风险相称的人工确认和接管能力。
- 在引入 AI 或 Agent 前，先评估系统已有的导出、规则、校验和人工流程是否已能以更低复杂度解决问题。
- 自动化的价值应计入维护、审核、事件、回退和人员成本，并与业务结果一起判断。

七、使用建议

1. 选择一个与自身边界、数据和风险相近的情景，先补齐任务定义、规则、验证、回退和证据，再决定是否试运行。
2. 重点借鉴“任务定义 → 规则与清单 → 样本测试 → 迭代与决策”的过程，而不是只复制提示词或数值。
3. 验证清单、人工审核和失败处理方式应按业务影响调整；高风险场景还需接入风险初筛、AIA、发布和 Runbook。
4. 启动新场景前，先用风险初筛、用例立项卡和工作流合约判断范围；计划做多步自动化前，先验证固定工作流和系统原生能力是否已满足业务需要。

本章中的教学情景用于说明常见模式与控制链，公开案例则说明为何需要这些控制。读者应按同一结构记录本组织的真实闭环过程，包括未通过、回退和修复过程，并在受控位置保存相应证据；不得将教学情景中的时间、比例、成本或结果转写为真实项目结论。

参考资料

后记 从个人提效到企业级稳定产出

全书从问题诊断走到具体执行，最终要回答的是一个实际问题：如何把个人使用 AI 获得的效率提升，转化为企业层面可重复、可验证、可长期运行的结果。

个人任务可能较快出现效率改善，例如更快形成初稿、摘要或结构化材料；但这种改善是否能迁移为组织能力，取决于任务边界、知识、审核、责任、风险和运行条件。企业需要的不是单次速度，而是一类工作能否在已定义范围内持续产出可复核、可维护的结果。

这种差距主要体现在三个地方：

1. **可复现性**。个人可以依靠经验和临时提示完成任务；组织需要不同人员在明确边界内执行相同资产，并得到可解释、可验证的结果。
2. **可验证性**。个人可能凭经验判断输出是否可用；正式用例需要明确的检查标准、证据来源、采用边界和人工责任。
3. **可持续性**。个人可随时更换工具；组织用例需要管理知识、版本、权限、变化、异常、回退和责任承接。

前面章节提供的方法，正是为了填补这些差距：用能力边界校准预期，用 workflow 固化过程，用数据和知识打地基，用最小闭环验证可行性，用评测与治理保证长期运行，用组织协同解决责任承接。企业级稳定产出不是向所有人发放 AI 工具，而是将上述控制设计进日常工作，并用实际证据持续检验。个人提效可以是起点，但不能自动推导出组织级结果。

行动建议

下一步宜选择一个低风险、高频、可验证且人工备用可行的场景，按第 6 章和附录 A 的用例立项卡、工作流合约设计第一轮闭环。应先在有限范围内积累样本、审核、风险和运行证据，再由阶段闸门决定是否扩大。

执行时，至少应做到以下三点：

- 按用例风险和行动影响设计验证清单、人工确认与转人工路径；
- 用简明记录保存质量、采用、端到端耗时、失败类型、变化和证据位置；
- 对 Prompt、检查清单、知识、工作流、模型/工具配置和发布资产实施版本与影响管理。

这些做法不能保证所有场景都产生收益，但能让团队将个人经验转化为可测试、可交接、可改进的组织资产。

写在最后

AI 工具和服务条件会持续变化；如何在变化中定义边界、保留人工责任、维护证据和运营用例，仍需要由每个组织结合自身情境持续处理。本书的方法与事实资产也应依据实践反馈和可复核资料更新。

希望本书能成为真实工作中的参考，并促使团队把假设、边界、结果和不足记录下来。

从个人提效到企业级稳定产出，关键在于以清晰边界、可复核证据和持续运营支撑设计与执行。

Jace 2026 年 8 月

附录 A 可直接复用的清单与模板

本附录汇总全书中提到的核心清单与模板，可直接复制使用。建议根据自身场景微调后，保存为团队共享文件。

1. 最小场景选择标准清单

在启动任何 AI 工作流前，用此清单快速判断场景是否适合作为最小闭环。必须同时满足：

- ☐ 任务每周至少重复出现 2 次以上
- ☐ 输入信息完整且可稳定获取
- ☐ 输出有明确的对错或好坏判断标准
- ☐ 单次人工耗时在 15-90 分钟之间
- ☐ 失败后可以人工纠正，不会造成严重业务损失或不可逆后果
- ☐ 不涉及最终决策权或对外正式承诺

结果判断：

- 全部勾选→可进入最小闭环设计
- 有任何一项不满足→暂缓，或拆成更小的子任务

2. 任务定义模板

复制后填写，作为工作流的起点。

任务名称：触发条件：（什么情况下启动）输入：

- 需要哪些信息
- 从哪里获取
- 格式要求输出：
- 最终交付物是什么
- 格式要求（Markdown/表格/JSON 等）质量标准：（怎样算合格，尽量具体）当前人工平均耗时：目标耗时：（含人工检查）禁止事项：（明确不能做什么）

3. 通用提示词模板

适用于大多数生成类任务。使用时只替换【】中的内容。

角色：你是【具体角色】，负责【具体任务】。任务目标：【用一句话说清楚要完成什么】输入信息：【在此处粘贴完整输入】必须遵守的规则：

- 【规则 1】- 【规则 2】- 【规则 3】- ...输出格式（严格按此格式返回，不得增加其他内容）：【明确的结构，推荐使用 Markdown 标题或表格】参考示例：【放 1 个简短正确示例，可选】现在开始处理。

4. 通用验证检查清单（基础版）

每次模型输出后，必须逐项检查。全部通过才可进入使用环节。

- ☐ 输出格式完全符合预设模板
- ☐ 所有必含字段/内容均已出现
- ☐ 无新增未要求的内容
- ☐ 无明显事实错误（对照输入或已知信息）
- ☐ 无把讨论/建议误写为结论或承诺

- [] 关键数字、日期、名称与输入一致
 - [] 语气/风格符合规定要求
- 使用规则：任何一项不通过，返回修改或转人工处理。

5. 会议纪要专用验证清单

- [] 所有明确决议均已记录
- [] 待办包含负责人
- [] 待办包含具体可执行的行动描述
- [] 待办包含截止日期（未明确则标注“待定”）
- [] 无把讨论中的建议写成决议
- [] 格式与模板完全一致
- [] 无明显事实错误

6. 客户回复起草专用验证清单

- [] 使用了正确问题类型的最新标准要点
- [] 包含规定的必须提示信息
- [] 无额外承诺或超出口径的内容
- [] 语气符合团队规范
- [] 关键政策/规则与现行版本一致
- [] 格式符合发送要求

7. 周度评测记录表

建议用在线表格记录，每周更新一次。

周次	总执行 次数	一次通过 次数	通过率	平均总 耗时(分 钟)	主要失 败类型	实际采 用率	备注
第 1 周	第 2 周	...					

目标参考（基于实践经验）：

- 通过率 $\geq 80\%$
- 平均总耗时比原方式下降 $\geq 30\%$
- 实际采用率 $\geq 75\%$

8. 版本命名规范

正式使用的文件统一按以下格式命名：内容名称_v 主版本.次版本_年月日 示例：

- 会议纪要提示词_v1.3_20260819
- 客户回复草拟 Skill_v1.0_20260819
- 待办检查清单_v1.1_20260815
- 标准答复要点_v2.0_20260801
- 异常工单 Agent 运行合约_v1.0_20260819

规则：

- 小幅修改规则或示例→次版本+1
- 结构性调整或适用范围变化→主版本+1
- 旧版本保留至少 30 天

9. 问题升级路径模板

提前填写并告知相关人员。

Skill/ workflow/ Agent 名称：日常使用者：业务责任人：提示词、Skill 定义或检查清单修改权限人：知识内容责任人：技术责任人（如适用）：升级触发条件：

- 连续出现同类严重错误
- 输出可能影响客户或正式决策
- 有人绕过验证清单直接使用结果
- 其他：【补充】升级对象与响应时限：
- 一级：【姓名/角色】，【X 小时内响应】 - 二级：【姓名/角色】，【X 小时内响应】

10. 最小闭环成功判断标准

同时满足以下条件，视为第一阶段成功，可考虑扩大范围：

- [] 连续 5 次真实任务中，至少 4 次通过验证清单
- [] 单次总耗时（生成+检查）比原人工方式降低 30% 以上
- [] 输出可被直接使用或只需要少量修改
- [] 至少 1 名其他同事能独立按同样方法完成

未全部满足前，继续在当前场景迭代，不急于增加新场景。

11. Skill 卡模板

用于把一个已验证的高频任务封装为团队可发现、可调用、可测试、可版本化和可退役的能力单元。

Skill 不是一段更长的提示词；它应同时包含业务边界、输入输出、知识、验证、责任和回退。

Skill 名称：

Skill 版本：

关联用例编号：

关联 workflow 编号（如适用）：

当前阶段：候选 / 试点 / 限量生产 / 受控生产 / 规模化 / 退役

业务目的：

适用范围：

禁止使用的情形：

触发条件：

输入契约：

- 必填输入：
- 输入来源：
- 格式/数据质量要求：
- 不可接受的输入：

输出契约：

- 输出对象：
- 输出格式：
- 质量标准/Rubric：

受控组件：

- Prompt 模板及版本：
- 知识来源及版本：
- 可调用工具及权限：
- 模型/平台及版本（如适用）：

验证与人工控制：

- 自动检查：
- 人工检查节点：
- 必须转人工的条件：

失败与回退：

- 缺少输入时：
- 验证不通过时：
- 工具/知识异常时：
- 回退路径：

责任与运行：

- 业务责任人：
- 知识责任人：
- 修改权限人：
- 日常使用者：
- 评测指标及频率：
- 变更记录：

Skill 进入正式使用前的最低检查：

- ☐ 已有清晰的输入与输出契约
- ☐ 已有可执行的验证标准与回退路径
- ☐ 已指定业务、知识与修改责任人
- ☐ 已用真实样本验证，并保留成功与失败样本
- ☐ 其他同事能依据 Skill 卡独立完成一次任务

12. Agent 运行合约模板

仅当固定工作流无法满足任务、且动态编排确有额外价值时使用。Agent 应只编排已验证的 Skill、最小必要上下文和受限工具，不应拥有无限的目标、资料、工具、记忆或权限。

Agent 名称：

Agent 版本：

关联用例编号：

关联工作流编号（如适用）：

当前阶段：候选 / 试点 / 限量生产 / 受控生产 / 规模化 / 退役

业务目标：

不承担的决策/禁止事项：

自主等级：L1 / L2 / L3 / L4 / L5

可调用 Skill：

- Skill 名称、版本、允许使用的状态：

上下文包与来源：

- 上下文包编号、版本与适用任务：
- 允许来源、来源优先级与排除来源：
- 预置内容与按需检索/加载逻辑：
- 来源版本、生效日期、适用范围与失效条件：
- 数据分级、可读取范围、内容/返回量预算：

可调用工具、MCP 与连接器：

- 工具/MCP/连接器名称、版本与 Owner：
- 允许动作与参数范围：
- 数据范围、返回字段与返回量限制：
- 读/写权限、凭证与身份范围：
- 超时、错误、审计和退出/禁用方式：

持久记忆（如适用）：

- 允许读取/写入的记忆类别：
- 事实、假设、待办的标记方式：
- 租户/用户隔离、保留期、删除和失效方式：
- 重新读取时的来源定位和人工纠错方式：

状态与路径：

- 合法状态：
- 合法状态转移：
- 终止状态：
- 信息缺失/异常输入时的状态：

预算与熔断：

- 最大步骤数：
- 最大工具调用数：
- 最大运行时长：
- 单任务最大成本：
- 并发上限：

验证与审批：

- 需要独立验证的事实：
- 需要人工审批的动作：
- 审批人/替补人：

接管与回退：

- 触发条件：
- 接管人：
- 降级方式：
- 恢复上线所需证据：

责任与审计：

- 业务责任人：
- 技术责任人：
- 知识责任人：
- 上下文/记忆 Owner（如与知识 Owner 不同）：
- 工具/MCP/连接器 Owner：
- 日志内容与留存方式（任务、状态、来源、Skill/工具/记忆版本、审批、异常）：
- 变更与回归评测要求：

Agent 进入试运行前的最低检查：

- [] 每个关键任务都已封装为有验证和回退的 Skill
- [] 上下文包、来源白名单、排除来源、版本、范围、预算和失效条件已验证
- [] 可调用工具、MCP/连接器、数据范围、返回量、读写权限和凭证均遵循最小权限原则
- [] 持久记忆（如使用）的写入、隔离、失效、删除与人工纠错已验证
- [] 已设置步骤、调用、时间、成本与并发熔断
- [] 已覆盖正常、边界、异常、上下文冲突/过期/越权和人工接管的评测样本
- [] 已演练工具超时、审批拒绝、空结果或熔断触发后的回退
- [] 已明确暂停、恢复和变更的责任人与权限

以上清单与模板可直接复制到团队文档中使用。建议每跑通一个新闭环，就同步更新对应的 Skill 卡、检查清单和版本记录。

13. 已填写示例：产品周会纪要提取 Skill

以下示例基于第 16 章“周会纪要与待办提取”案例。它的目的不是提供唯一正确的写法，而是展示一张 Skill 卡如何把 Prompt、知识、验证、责任和回退放在同一处管理。使用前，应替换团队名称、具体工具、数据边界和责任角色。

Skill 名称：产品周会纪要提取与核验

Skill 标识：SK-PROD-MINUTES

Skill 版本：v1.0

关联用例编号：UC-PROD-001

关联工作流编号：WF-PROD-MINUTES-001

当前阶段：试点

业务目的：

将产品周会转写整理为可直接贴入协作文档的结构化纪要和待办列表，减少产品经理整理时间，并降低决议与待办遗漏。

适用范围：

- 产品团队内部周会和双周战略会
- 已获得会议参与者授权、且可在批准工具内处理的会议转写
- 仅用于生成草稿，由会议主持人或指定记录人确认后发布

禁止使用的情形：

- 会议转写不完整、来源不明或含有不应上传至当前工具的数据
- 要求系统自行判断尚未达成的决议、人员绩效结论或对外承诺
- 无人能够核对决议、负责人和截止日期

触发条件：

会议结束后，主持人或指定记录人提供完整转写及会议日期、参会人信息。

输入契约：

- 必填输入：会议日期、参会人、完整会议转写
- 输入来源：批准的会议转写工具或人工整理文本
- 格式要求：保留说话轮次或时间戳（如可获得）；不得混入其他会议内容
- 不可接受的输入：只含摘要、缺少主要讨论段落、无权处理的敏感信息

输出契约：

- 输出对象：会议主持人或指定记录人
- 输出格式：会议基本信息；关键决议列表；待办表（待办事项、负责人、行动描述、截止日期）
- 质量标准：只记录明确达成的决议；每项待办均可执行；未明确的负责人或日期必须标为“待定”

受控组件：

- Prompt 模板：会议纪要提取 Prompt_v1.0
- 知识材料：团队待办字段规范_v1.0；历史正确/错误示例各 2 份
- 可调工具：无；如使用转写工具，仅接收其导出的文本
- 模型/平台：按组织批准的平台与模型版本填写

验证与人工控制：

- 自动检查：待办表字段齐全；输出格式符合模板；“待定”字段格式统一
- 人工检查：主持人核对所有关键决议；确认负责人、行动描述和截止日期；检查未把讨论建议写成决议
- 必须转人工的条件：转写缺失；决议存在争议；出现人员评价、预算承诺或对外事项

失败与回退：

- 缺少输入时：提示补充会议日期、参会人或完整转写，不生成正式纪要
- 验证不通过时：带着具体失败项重新生成一次；仍不通过则由记录人按原流程人工整理
- 知识异常时：停用当前版本，回退到已验证的上一版本或纯人工模板
- 回退路径：人工会议记录模板 + 主持人确认后发布

责任与运行：

- 业务责任人：产品负责人
- 知识责任人：产品运营/项目管理角色

- 修改权限人：指定的产品运营与 AI workflow 维护人
- 日常使用者：会议主持人、项目经理或指定记录人
- 评测指标：一次通过率、平均总耗时、决议/待办完整率、采用率
- 评测频率：前 4 周每周；稳定后每月
- 当前变更记录：v1.0 为试运行基线，任何规则或示例变更需记录并用历史样本回归检查

首轮演练建议：从最近 5 次真实会议中选取转写，先不接入自动发布。每次由同一位业务审核人依据附录 A 第 5 节检查，记录遗漏、误判、人工修改时间和是否被采用。只有在第二位使用者能够独立运行、并且回退路径已实际走通后，才将其视为可共享的正式 Skill。

14. 已填写示例：异常工单调查 Agent 运行合约

以下是一个 L3 **建议式编排** 的示例。它只读取已授权的内部信息，输出调查建议，不发送对外消息、不修改工单、不执行恢复操作。该示例的重点是说明：Agent 的价值在于受限状态下编排已验证的 Skill，而不是获得无限制的自主权。

Agent 名称：异常工单调查助手

Agent 标识：AG-OPS-TRIAGE

Agent 版本：v1.0

关联用例编号：UC-OPS-TRIAGE-001

关联工作流编号：WF-OPS-TRIAGE-001

当前阶段：试点

业务目标：

对内部低风险异常工单进行初步信息归集，输出“已知事实、缺失信息、建议下一步”，帮助人工值班人员更快完成调查。

不承担的决策/禁止事项：

- 不直接修改工单状态、优先级、负责人或标签
- 不执行服务重启、配置修改、数据删除或任何写操作
- 不向客户、供应商或外部系统发送信息
- 不对根因、影响范围或修复方案作未经人工确认的结论

自主等级：L3（建议式编排）

可调用 Skill：

- 工单字段规范化 Skill v1.0：只提取并校验工单已存在的字段
- 异常类别初筛 Skill v1.0：基于预定义类别输出候选分类及依据
- 运行知识检索 Skill v1.0：从已批准的内部 Runbook 中检索相关操作说明
- 调查摘要生成 Skill v1.0：生成“事实/证据/不确定项/建议下一步”四段式摘要

可调用工具与权限：

- 工单读取工具：仅读取当前工单及其关联的已授权记录
- 日志查询工具：只读；时间范围限制为工单发生前后 24 小时；返回结果条数限制为 200 条
- 知识库检索工具：只读；仅检索已批准的内部 Runbook 集合

- 不配置写入工具、消息工具、代码执行工具或外部网页访问工具

合法状态与路径：

1. 接收工单 → 2. 校验输入 → 3. 初筛分类 → 4. 查询允许范围内的日志/知识 → 5. 生成调查建议 → 6. 人工审阅 → 7. 结束

- 信息缺失、工具异常、权限拒绝、置信不足或检测到敏感信息时：进入“转人工”状态并停止后续调用
- 不允许从任何状态跳回前一状态反复循环；不允许发明新工具、新 Skill 或新目标

预算与熔断：

- 最大状态转移数：6
- 最大工具调用数：4
- 最大运行时长：90 秒
- 单任务最大模型调用数：5
- 单任务成本上限：由组织按平台预算填写
- 任一上限触发：立即停止，记录原因，并转人工

验证与审批：

- 调查摘要必须区分“已验证事实”“推测”“缺失信息”
- 任何日志、知识或工单字段引用均须显示来源标识
- 人工值班人员审阅后，才可将摘要复制到工单或据此采取行动

接管与回退：

- 触发条件：输入不完整、工具超时、返回异常、熔断、敏感数据、审批人拒绝或审核人无法理解摘要
- 接管人：当班运营/技术支持人员
- 降级方式：按既有工单调查 Runbook 人工检索与记录
- 恢复上线所需证据：异常原因已修复；相关 Skill 和工具样本回归通过；责任人批准恢复

责任与审计：

- 业务责任人：运营支持负责人
- 技术责任人：平台/自动化维护人
- 知识责任人：Runbook 维护人
- 日志内容：任务标识、时间、状态转移、调用的 Skill 与版本、工具与参数摘要、来源标识、熔断/异常、人工审阅结果
- 变更要求：任何 Skill、权限、状态逻辑、工具或模型变更均须完成受影响样本的回归评测

首轮演练建议：使用 10 个已经关闭的历史工单，其中至少包含 3 个信息缺失、2 个日志查询为空、1 个权限拒绝或工具超时的模拟情形。测试目标不是让 Agent “猜中根因”，而是确认它会在允许范围内检索、明确表达不确定性、在异常时停止并把任务平滑交回人工。

15. 变更影响与回归评测记录模板

任何正式 Skill、工作流或 Agent 的 Prompt、知识、模型、工具、权限、状态逻辑或验证规则发生变化时，使用本模板判断影响范围并记录回归结果。小改动也可能改变质量、成本或风险；不要只凭主观感觉直接覆盖生产版本。

变更编号：

变更日期：

变更发起人：

受影响资产：

- Skill/工作流/Agent 名称及当前版本：
- 受影响的下游资产：

变更类型（可多选）：

- ☐ Prompt 或示例
- ☐ 知识内容/检索配置
- ☐ 模型或平台版本
- ☐ 工具、接口或数据源
- ☐ 权限、读写范围或凭证
- ☐ 状态逻辑、预算或熔断
- ☐ 验证规则/Rubric
- ☐ 其他：

变更目的与预期收益：

不变的业务边界与禁止事项：

潜在风险：

回退版本与回退负责人：

回归样本：

- 正常样本数量：
- 边界/异常样本数量：
- 必须覆盖的历史失败样本：

回归结果：

- 质量/Rubric：
- 一次通过率：
- 端到端耗时：
- 采用率或人工修改负担：
- Agent 工具行为/权限验证（如适用）：
- 熔断与人工接管演练（如适用）：

发布决策：通过 / 限量试运行 / 退回修改 / 不发布

审批人：

上线后观察期与指标：

最终结论与后续动作：

最低发布规则：变更不得扩大既定业务边界或权限；如质量显著下降、出现新的高严重度风险、熔断/接管失效或回归结果无法解释，应保持或回退到上一稳定版本。对 Agent 的权限、工具或状态逻辑变更，应视为高影响变更，不应只测试最终文本输出。

16. 已填写示例：客户咨询标准回复草拟与核验 Skill

以下示例基于第 16 章“客户咨询标准回复起草”案例。它面向外部沟通，因此比会议纪要 Skill 多了一层知识时效、来源展示和发送前人工确认控制。示例只覆盖物流、退换货、活动规则等口径清晰的高频问题；补偿、投诉升级、价格例外、合约承诺和敏感个人信息相关问题必须转人工。

Skill 名称：客户咨询标准回复草拟与核验

Skill 标识：SK-CS-STANDARD-REPLY

Skill 版本：v1.0

关联用例编号：UC-CS-001

关联工作流编号：WF-CS-REPLY-001

当前阶段：试点

业务目的：

在不改变人工最终决定权的前提下，为已定义的高频咨询生成与当前政策一致的回复草稿，缩短起草时间并减少口径遗漏。

适用范围：

- 已批准的高频问题类型：物流进度、退换货条件、活动规则、基础产品信息等
- 使用者能够选择或确认问题类型
- 当前标准答复要点已标注来源、生效日期、适用范围和知识责任人

禁止使用的情形：

- 补偿、退款金额、价格例外、投诉升级、法律/合同解释或对外承诺
- 无法确定问题类型，或当前标准答复要点缺失、过期、冲突
- 客户消息包含不应输入当前工具的敏感个人信息
- 使用者意图绕过人工确认直接发送

触发条件：

客服或销售支持人员收到属于已批准问题类型的客户咨询，并在批准工具中选择问题类型后发起草拟。

输入契约：

- 必填输入：客户原话、问题类型、当前标准答复要点标识及版本
- 可选输入：客户已知订单状态、适用活动标识、已批准的个性化背景
- 输入来源：批准的客服系统、知识库或人工粘贴的已脱敏文本
- 不可接受的输入：无问题类型、知识来源不明、含未获授权的敏感信息、要求作出例外承诺的内容

输出契约：

- 输出对象：客服或销售支持人员，不直接发送给客户
- 输出格式：回复正文；使用的要点来源（文档标识、版本、生效日期）；待人工确认项
- 质量标准：准确对应问题类型；包含必须提示；不添加知识库之外的承诺；语气符合团队规范；不确定时明确提示转人工

受控组件：

- Prompt 模板：客户标准回复草拟 Prompt_v1.0

- 知识材料：标准答复要点库；每条要点均标记问题类型、政策版本、生效日期、适用范围、知识责任人
- 示例材料：每个问题类型至少保留一个正确示例和一个典型错误示例
- 可调用工具：仅允许读取批准知识库；不连接发送、退款、定价、订单修改或客户账户写入工具
- 模型/平台：按组织批准的平台与模型版本填写

验证与人工控制：

- 自动检查：输出含来源标识；使用的要点版本未过期；关键提示字段齐全；禁止承诺词未出现
- 人工检查：确认问题类型正确；核对来源要点；确认没有额外承诺；补充必要的个性化信息；决定是否发送
- 必须转人工的条件：政策版本不明确、知识冲突、客户要求例外处理、客户投诉升级、涉及敏感信息或审核人无法确认

失败与回退：

- 缺少输入时：要求补充问题类型或当前政策来源，不生成可发送草稿
- 知识过期/冲突时：停止草拟，展示“知识待确认”，由知识责任人处理后恢复
- 验证不通过时：根据具体失败项重新生成一次；仍不通过则使用人工标准回复模板
- 工具异常时：按人工检索知识库 + 人工草拟流程处理
- 回退路径：人工标准回复模板；必要时升级至业务负责人或投诉处理流程

责任与运行：

- 业务责任人：客服/销售支持负责人
- 知识责任人：各问题类型对应的政策或运营负责人
- 修改权限人：客户沟通规范维护人及 AI 工作流维护人
- 日常使用者：经培训的客服与销售支持人员
- 评测指标：一次通过率、采用率、平均总耗时、知识过期拦截次数、人工转交率、口径相关投诉/纠错信号
- 评测频率：试运行前两周每周；稳定后每月
- 当前变更记录：任何标准答复要点、Prompt、模型、知识检索、验证规则或权限变更均需走附录 A 第 15 节的变更记录

试运行与限量发布安排

该 Skill 不应因为离客户“只差一步发送”就直接全量启用。建议采用四个阶段：先用历史咨询离线回归；再由小范围、已培训人员使用并对每一条草稿做 100% 人工审核；确认质量、知识时效和回退稳定后，才逐步扩大到更多问题类型或更多使用者；在任何阶段出现口径错误、知识冲突、异常转人工或无法解释的质量下降时，立即回退到人工标准回复流程。

阶段	使用范围	人工控制	必须证明的事实	不满足时的动作
离线回归	已关闭的历史咨询	不接触真实客户	每类问题均能引用正确、有效的要点；异常案例会转人工	修复知识、Prompt 或验证规则

阶段	使用范围	人工控制	必须证明的事实	不满足时的动作
小范围试运行	少量已培训使用者、少量问题类型	每条草稿 100% 审核	审核人能理解来源；人工修改负担可接受；回退可用	保持试运行，不扩大范围
限量发布	已验证的问题类型与班组	每条仍由人工发送；按日复核异常与抽样质量	质量、采用、时效与转人工信号稳定	降级到小范围试运行或暂停
稳定运行	已批准范围内的常规使用	维持发送前人工确认；按月回顾	知识更新和变更回归持续执行	进入变更/问题处理流程

17. 知识变更→影响分析→回归评测→限量发布模板

客户沟通类 Skill 最常见的风险不是模型突然“变笨”，而是业务规则、活动条件、产品状态或话术口径已经变化，而知识、Prompt、示例和验证规则没有同步更新。以下模板将一次知识更新变成可追溯的运营闭环。

阶段	责任角色	最低动作	必须留下的证据	不通过时
1.触发与登记	业务/知识责任人	记录变化来源、生效时间、适用范围和紧急程度	变更编号、原始来源、拟生效日期	暂不进入生产知识库
2.知识更新	知识责任人	更新权威知识条目；标记新旧版本、适用范围和失效内容	知识版本、更新说明、责任人	退回核对业务规则
3.影响分析	Skill/流程责任人	列出受影响的问题类型、Skill、Prompt、示例、验证规则、工具和在运行任务	影响清单与风险判断	将受影响资产置为“待确认”或暂停使用
4.回归设计	Skill/流程责任人 + 业务审核人	选择正常、边界、历史失败和新规则样本；明	回归样本清单、Rubric、预期结果	补充样本或明确规则

阶段	责任角色	最低动作	必须留下的证据	不通过时
		确人工判定标准		
5.回归与审核	使用者 + 业务审核人	运行新版本并核对内容、来源、禁止承诺、转人工与回退行为	回归结果、失败项、修复记录	修复后重新回归；保留上一稳定版本
6.发布决策	业务责任人	决定不发布、限量试运行或正式恢复；明确观察期	决策记录、批准人、回退版本	不发布或回退
7.限量观察	使用者 + Skill 责任人	在受限范围运行，密切查看质量、过期拦截、人工转交和投诉/纠错信号	观察期周报、异常记录	缩小范围、暂停或回退
8.资产沉淀	知识/Skill 责任人	将新规则、成功样本、失败样本和复盘写回知识与 Skill 资产	更新后的 Skill 卡、示例、失败案例	继续保留观察状态

客户回复知识变更记录示例

以下记录展示“活动规则变更”如何影响一个客户回复 Skill。内容为演练示例，实际企业应替换为自身政策和审批角色。

变更编号：KB-CS-2026-001

变化来源：活动运营负责人发布的已批准规则更新

生效时间：2026-09-01 00:00

变化范围：活动问题类型中的参与条件、适用商品与截止日期

受影响资产：

- 标准答复要点库：活动规则条目 v2.3 → v2.4
- 客户咨询标准回复草拟与核验 Skill：SK-CS-STANDARD-REPLY v1.0
- Prompt：客户标准回复草拟 Prompt_v1.0
- 示例：活动规则正确示例 2 条、历史错误示例 1 条
- 验证：活动截止日期、适用商品、例外承诺禁止项

风险判断：

若旧规则继续被引用，可能造成客户误解、错误承诺或投诉；属于“对外口径/知识时效”高优先级变更。

回归样本：

- 2 条正常活动咨询
- 2 条边界咨询（不符合参与条件、活动已结束）
- 1 条历史失败样本（模型曾遗漏截止日期）
- 1 条要求例外补偿的咨询，预期必须转人工

发布决策：

先在离线回归中验证；通过后，仅允许已培训人员在活动问题类型中使用，所有草稿继续人工确认。观察期内若出现错误日期、错误商品范围、未转人工的例外承诺，立即回退至活动规则条目 v2.3 与人工回复流程。

这个闭环的目的不是放慢业务变化，而是让组织能回答四个关键问题：**规则何时变了？影响了什么？新版本如何被证明可用？出问题时空退到哪里？**

18. AI 用例组合台账模板

当团队拥有多个 Skill、工作流或 Agent 后，不能只分别保存若干 Prompt、文档和评测表。应建立一张面向业务结果的**用例组合台账**：每行代表一个业务用例，而不是一个工具账号或技术组件；Skill、工作流和 Agent 是该用例所依赖的能力资产。

台账的目的不是增加审批手续，而是让管理者和交付团队能在同一张表中回答：正在运行什么、谁对业务结果负责、处于什么阶段、值不值得继续投入、有什么共用依赖、下一个决策是什么。

字段	填写说明
用例编号与名称	采用稳定编号，例如 UC-CS-001；名称使用业务语言，如“高频客户咨询回复草拟”
业务问题与目标	说明要改善的流程问题、目标用户和预期业务结果，不写成“建设一个 Agent”
当前阶段	候选 / 试点 / 限量生产 / 受控生产 / 规模化 / 退役；定义见第 8 章第八节
业务价值假设	期望节省的端到端时间、质量/风险改善、容量释放或其他业务指标，以及当前证据等级
风险等级与边界	低/中/高；是否对外、是否含敏感数据、是否有写入或自动行动、不可接受的错误
业务责任人	对业务结果、范围和继续/暂停建议负责的角色
Skill/流程/Agent 资产	关联的 Skill 标识及版本、工作流版本、Agent 运行合约及自主等级
知识与数据依赖	知识库/数据源、知识责任人、最近更新日期、是否被其他用例共用
技术与权限依赖	模型/平台、工具、读写权限、关键系统依赖和技术责任人

字段	填写说明
运行健康度	通过率、采用率、总耗时、主要失败、接管/熔断（如适用）、上次评测日期
成本与维护负担	工具成本、人工验证/维护投入、单位任务成本或 TCO 估算
当前决策与下一闸门	继续试点/限量发布/扩大/暂停/退役；下一次需要提交的证据和日期
关联风险与依赖	与其他用例的共享知识、共享工具、共享责任人、未解决事件或待办

最小台账示例

用例	阶段	业务责任人	关键资产	当前证据	下一决策
【状态示例】 产品周会纪要与待办提取	受控生产	产品负责人	SK-PROD-MINUTES v1.0	示例：已取得 6 周稳定运行与人工确认使用证据	示例：评估是否复用到双周战略会
【状态示例】 高频客户咨询回复草拟	限量生产	客服支持负责人	SK-CS-STANDARD REPLY v1.0	示例：已完成历史样本回归；发送前 100% 人工确认	示例：完成活动规则变更观察期后决定是否扩大问题类型
异常工单调查建议	试点	运营支持负责人	AG-OPS-TRIAGE v1.0, L3	仅历史工单演练；无写入权限	验证人工接管与工具异常回退后决定是否进入限量试运行

使用规则：新用例在正式投入人力或采购工具前必须登记；每次阶段变更、重大事件、知识/权限高影响变更或退役决定后更新；台账只记录关键决策信息，详细 Prompt、样本和日志仍留在对应的 Skill 卡、Agent 运行合约与事件记录中。

19. 用例责任矩阵（企业最小 RACI）

单个 Skill 可以由一名业务人员维护；但多个用例共同运行后，必须区分“谁做事”和“谁拍板”。下表是轻量级 RACI，可按组织岗位名称调整。每项活动只能有一个最终负责的 A（Accountable），避免出现“大家都参与、没有人对结果负责”。

R（Responsible）：实际执行工作；**A（Accountable）：**对结果拍板并承担最终责任；**C（Consulted）：**必须被征询；**I（Informed）：**需要知会。

活动/决策	业务赞助人	用例 Owner	Skill/流程 Owner	知识 Owner	技术 / 平台 Owner	安全/风险代表	使用者/审核人
用例立项、业务目标与风险边界	A	R	C	C	C	C	C
Skill、工作流程和验证设计	I	A	R	C	C	C	C
知识更新与失效处理	I	A	C	R	I	C	I
模型、工具、权限或状态逻辑变更	I	A	R	C	R	C	I
离线回归、限量发布与观察期	I	A	R	C	C	C	R
日常运行、人工审核与问题上报	I	A	R	C	C	I	R
重大异常的暂停、回退与恢复	I	A	R	C	R	C	I
阶段提升、规模化、资源投入或退役	A	R	C	I	C	C	I

最低责任规则：每个正式用例必须有业务 Owner；每个可变更的知识资产必须有知识 Owner；每个含工具、权限、日志或自动化运行的用例必须有技术 Owner；涉及高风险数据、外部影响或高自主性的用例，应有相应的安全/风险代表参与关键决策。外部顾问、FDE 或 AI COE 可以承担设计和辅导工作，但不能长期替代客户方的业务 Owner 和知识 Owner。

20. 用例阶段闸门与组合决策卡

阶段不是“成熟度打分比赛”，而是为了避免尚未证明稳定、价值或控制能力的用例被过早扩大。每次阶段提升或退役都应在用例组合台账中留下一个简短决策记录。

阶段	用例状态	进入该阶段的最低条件	升级/退出所需证据	可做的管理决定
G0：候选	已识别问题，尚未启动正式试验	业务问题、目标用户和当前人工基线可描述；存在潜在 Owner	用例立项卡、初步风险判断、是否值得投入的理由	启动设计 / 暂缓 / 合并到已有用例
G1：试点	正在验证最小闭环	有 工 作 流 或 Skill 卡草案、真实样本、人工回退、责任人	在小范围真实任务中证明可用；失败可解释且可修复；第二人可复现	进入限量生产 / 延长试点 / 停止
G2：限量生产	在受控范围内处理真实工作	质量、采用、成本和知识更新已开始记录；人工审核与异常升级可用	观察期稳定；变更能回归；风险边界被遵守	进入受控生产 / 保持限量 / 回退试点
G3：受控生产	被正式团队持续使用	版本、责任、评测、回退、运行节奏稳定；关键依赖可追溯	连续稳定运行；业务价值假设获得证据；维护负担可承受	复制到相邻场景 / 保持运行 / 优化 / 退役评估
G4：规模化	已跨团队或跨场景复制	共享知识、平台、支持与培训机制就绪；组合层面有资源与风险管理	复用后仍能保持质量；共享依赖变更可控；Owner 覆盖充分	扩大投资 / 限制扩张 / 拆分资产 / 退役低价值用例
G5：退役	不再适合继续运行	价值消失、维护成本过高、风险不可接受、被更优方案替代或业务流程取消	业务 Owner 批准；人工/替代流程可用；数据、权限、资产	停止运行 / 归档资产 / 移交替代方案

阶段	用例状态	进入该阶段的最低条件	升级/退出所需证据	可做的管理决定
			和日志按政策处置	

阶段决策记录模板

用例编号与名称：

当前阶段 → 申请阶段：

本次决策类型：进入 / 保持 / 扩大 / 降级 / 暂停 / 退役

业务证据：

- 当前基线与目标：
- 质量、采用、效率、成本或业务结果：
- 主要未解决问题：

控制证据：

- 责任人是否齐全：
- 知识/数据是否处于受控状态：
- 回退、接管、权限与审计（如适用）是否已验证：
- 最近重大变更和回归结果：

组合影响：

- 共享知识/工具/人员依赖：
- 是否挤占或重复其他用例：
- 所需新增资源和预算：

决策：

决策理由：

下一次复核日期：

业务 Owner：

业务赞助人/授权人：

阶段闸门使用原则：不要因为一个用例“看起来很受欢迎”就跳过质量、知识、权限或回退验证；也不要因为未达到某一条统一数字而机械停止。应同时看业务价值、错误后果、证据完整度和维护能力。高风险或高自主性用例需要更强的控制证据；低风险内部辅助用例可以采用更轻的节奏。

21. 月度用例组合评审模板

当正式或试运行用例达到 3 个以上时，建议每月举行一次 45-60 分钟的组合评审。会议不是逐个汇报工具使用次数，而是做资源、风险和阶段决策。

议题	会前输入	会议需要决定什么	输出
组合总览	最新用例组合台账	哪些用例处于试点、限量、生产、规模化或退役	更新后的阶段与 Owner
健康与风险	质量、采用、成本、异常、知识变更、接管/熔断数据	哪些需要修复、降级、暂停或升级	优先级行动清单
价值与资源	业务结果、TCO、维护负担、共享依赖	资源应投向哪里；哪些不再值得投入	投入、停止或延后决定
共享资产	知识库、平台、工具权限、培训和共用 Skill	哪些资产可以复用；哪些变更需要协调	资产 Owner 与变更计划
下月试验	候选用例及立项卡	只启动能力与资源允许的新用例	新用例、试点范围和复核日期

会议结束后，至少更新三项内容：用例组合台账、阶段决策记录和有明确 Owner 与截止日期的行动项。若没有任何阶段、资源或风险决定需要作出，则可用异步审阅替代会议，避免制造无效治理负担。

22. 分角色能力地图与实践认证模板

企业 AI 培训不应以“所有人上一门相同的提示词课”为终点。不同角色承担的工作、风险和决策权不同，因此应学习不同能力，并以真实工作产出而不是听课时长作为验证依据。

角色	最低应具备的能力	必做实践任务	可接受的认证证据
全员使用者/审核人	判断任务是否适合 AI；遵守数据边界；使用批准的 Skill；完成三层自检；发现问题时停止并上报	用一个低风险真实任务完成“输入—输出—人工核验—问题记录”	已填写自检记录；能说明何时转人工；无绕过控制行为
团队经理/业务 Owner	选择有业务价值的场景；定义基线与成功标准；保护试点时间；解释何时不该用 AI；依据证据决定扩大或暂停	完成一张用例立项卡，并主持一次基于真实数据的周度复盘	用例目标、边界、Owner、基线和下一决策清晰；复盘形成行动项
知识 Owner	识别权威来源；维护时效、版本和适用范围；处理冲突；完成影响分析	完成一次知识变更→回归→限量发布演练	更新记录、受影响资产、回归样本与发布/回退决定完整

角色	最低应具备的能力	必做实践任务	可接受的认证证据
Skill/流程 Owner、FDE 或 AI COE	设计输入输出契约、验证、回退、指标和变更机制；辅导第二人复现	将一个高频任务封装成 Skill 卡，并带领第二人独立复现	Skill 卡、成功/失败样本、回归记录、第二人复现结果
技术/平台 Owner	落实权限、日志、版本、可用性、成本与异常恢复；验证 Agent 运行控制	为一个含工具调用的流程完成权限审查、熔断/接管演练	权限矩阵、运行日志样例、演练记录与整改项
业务赞助人/高管	理解价值证据、风险边界和组合决策；避免用错误指标驱动采用	审阅一个用例组合台账并就投入、暂停或退役作出有理由的决定	有记录的阶段决策；资源与风险取舍可追溯

实践认证记录

认证对象：

所属角色：

认证级别：基础使用 / 业务 Owner / 知识 Owner / Skill 流程 Owner / 技术平台 Owner / 赞助人

实践任务名称：

关联用例或 Skill：

完成日期：

提交证据：

- 已完成的文档或运行记录：
- 使用的真实或脱敏样本：
- 发现的问题与处理方式：

审核标准：

☐ 已遵守适用边界和数据规则

☐ 已按角色要求完成关键动作

☐ 能解释何时停止、转人工或升级

☐ 相关资产可以被他人复核

审核人：

认证结果：通过 / 补充实践后复核 / 不通过

需要补强的能力：

复核或再认证日期：

使用原则：认证不应成为追求证书数量的活动，也不应以模型调用次数、Token 消耗或登录时长作为依据。它应证明一个人能够在自己角色的责任边界内做出正确动作、留下可复核证据，并在不确

定时知道何时停止和求助。重大角色变化、权限扩大、业务规则重大调整或长时间未实际使用时，可安排有针对性的再认证。

23. 经理人 AI 变革行动手册

员工的使用习惯不会仅因开通账号或举办一次培训而稳定改变。经理人的职责不是要求团队“多用 AI”，而是重构工作方式、消除障碍、保护试点时间，并以业务结果和风险边界为依据带领团队学习。

30 天启动节奏

阶段	经理人要做什么	不该做什么	产出
第 1 周：定向	选择一个低风险、高频、可验证任务；说明为什么做、谁负责、哪些事不能交给 AI	直接要求所有人都用同一个工具或立即建设 Agent	用例立项卡、团队边界说明、试点参与者
第 2 周：共同练习	用真实或脱敏样本演示一次完整任务；让成员分别完成一次并比较差异	只讲概念、只展示最好的一次结果	失败记录、问题清单、更新后的 Skill/检查清单
第 3 周：嵌入流程	将 Skill、验证和人工确认放入实际 SOP；为使用者和知识 Owner 安排固定时间	让试点变成额外无偿工作，或让原搭建者独自维护一切	运行节奏、Owner、升级路径、周度数据
第 4 周：基于证据决定	回顾质量、采用、总耗时、失败、知识更新与成员反馈；决定扩大、改进或暂停	只看“大家觉得不错”、只汇报成功案例	阶段决策、下月行动、需升级的风险或资源问题

每周经理人检查问题

在周度复盘，经理人应优先提出以下问题，而不是“本周大家用了多少次 AI”：

1. 本周哪些真实任务被采用？哪些没有被采用，为什么？
2. 失败、转人工或拒绝发送的案例告诉我们什么？
3. 当前知识、Prompt、Skill、流程或权限中，哪一个环节最需要改进？
4. 谁在承担额外维护负担；是否需要调整资源或缩小范围？
5. 是否有人因为不确定、担忧犯错或工具不合适而绕开正式流程？应如何提供安全、合规的替代路径？

应强化与应避免的行为

应强化	应避免
及时上报失败、知识过期、异常输出和控制缺口	为了好看而隐瞒失败，或把失败报告视为个人能力不足

应强化	应避免
用真实任务练习，允许在低风险范围内试错	只看演示、只使用精心准备的“完美样本”
将节省的时间重新投入客户、判断、协作或高价值工作	将“使用 AI 次数”作为绩效指标，诱导为用而用
对边界不清的任务明确转人工或暂停	鼓励员工用个人账号或未经批准工具绕过限制
让使用者、知识 Owner、技术 Owner 共同复盘	由单一“AI 高手”长期背负所有维护和决策

24. 采纳反馈与问题上报闭环模板

稳定采纳需要让员工相信：提出问题会带来改进，而不是惩罚；不用不合适的 AI、转人工或暂停自动化是被支持的专业判断。团队应提供一个低门槛的反馈入口，并将反馈连到知识、Skill、流程、培训或治理动作。

反馈编号：

提交日期：

提交人/匿名选项：

关联用例/Skill/Agent：

任务类型：

反馈类型：

- ☐ 输出错误或遗漏
- ☐ 知识过期/冲突
- ☐ 不知道何时该用或不该用
- ☐ 工具、权限、速度或成本问题
- ☐ 数据或合规担忧
- ☐ 使用体验/培训需求
- ☐ 建议新增或停止某个场景

发生了什么：

影响范围：

已采取的即时动作：继续 / 转人工 / 暂停 / 升级

是否需要保护提交人或限制传播：是/否

分流结果：

- 知识更新：
- Skill/流程改进：
- 技术/权限处理：
- 培训或沟通动作：
- 风险/安全升级：

责任人：

响应时限：

处理结果与回告：

是否写入失败案例、回归样本或培训材料：

闭环规则：低风险使用体验问题可以在团队周度复盘处理；知识、质量和流程问题应进入对应资产的变更记录；涉及数据、安全、对外影响或严重错误的问题应立即按第 12 章升级路径处理。每月汇总反馈类型和处理时效，识别反复出现的培训盲区、知识缺口或流程障碍。

25. 用例立项卡（One-page Use Case Charter）

用例立项卡是所有正式试点的入口。它回答的不是“要不要做一个 Agent”，而是“哪个业务问题值得被解决、在什么边界内试验、谁为结果负责、何时应该继续或停止”。一张卡只对应一个业务用例；其后可以关联多个 Skill、固定工作流或 Agent。

使用顺序：候选用例先填写立项卡，再做风险初筛和工作流设计；进入试点后，用例编号应写入所有 Skill 卡、工作流合约、评测记录、变更单、事件记录和用例组合台账。这样，后续资产才可被关联和追溯。

用例编号：UC - 部门 - 序号

用例名称：

当前阶段：候选 / 试点 / 限量生产 / 受控生产 / 规模化 / 退役

立项日期：

最近复核日期：

一、业务问题与范围

- 要解决的业务问题：
- 目标用户/使用者：
- 当前人工流程及痛点：
- 适用范围（部门、任务类型、地域/客户/系统边界）：
- 明确不做什么：
- 与已有用例的区别、重叠或复用关系：

二、当前基线与价值假设

- 任务量/频率：
- 当前端到端耗时（含检查、返工和等待）：
- 当前质量/风险信号（错误、投诉、积压、遗漏等）：
- 预期改变的业务结果：
- 价值证据类型：流程效率 / 产能释放 / 业务结果 / 风险避免
- 不应宣称的收益：

三、初始边界与风险判断

- 输入数据类别与最高敏感度：
- 是否涉及个人信息、对外沟通、关键决策、写入操作或不可逆动作：
- 最坏可接受错误及不可接受结果：
- 人工必须保留的决策/审核节点：

- 需要征询或批准的角色：
- 初始风险判断及理由：低 / 中 / 高 / 待确认

四、解决方案与依赖假设

- 计划采用的方式：Prompt / Skill / 固定工作流 / 受限 Agent
- 预计关联的 Skill、工作流或 Agent 标识：
- 知识/数据来源及知识 Owner：
- 关键系统、模型、工具或平台依赖：
- 人工备用流程与回退条件：

五、试点设计与决策门

- 业务 Owner：
- Skill/流程 Owner：
- 技术 Owner（如适用）：
- 试点范围、参与者和周期：
- 试点样本与验证方式：
- 成功假设（质量、采用、效率、业务结果或风险控制）：
- 停止/降级条件：
- 下一决策日期及所需证据：

立项结论：启动设计 / 暂缓 / 合并到已有用例 / 不做

业务 Owner：

批准或复核人：

进入试点前的最低检查

检查项	最低要求
业务问题	可以用业务语言说明当前痛点，而不是只描述工具功能。
Owner	业务 Owner 和日常维护角色明确，且愿意在试点后作出继续、暂停或调整建议。
基线	至少具备任务频率、端到端耗时或当前质量/风险信号之一；未知的内容必须标记为待测量。
边界	已写明确不做什么、不可接受结果和人工保留决策。
回退	发生错误、工具不可用或边界不清时，使用者知道如何回到人工或原流程。
下一决策	试点不是无限期运行；已定义何时、依据什么证据作出下一次决定。

26. 通用工作流合约 (Workflow Contract)

工作流合约适用于需要多人协作、多个步骤或持续维护的正式流程。它不是对 Skill 卡的替代：**Skill 卡定义单项可复用能力；工作流合约定义这些能力、确定性步骤和人工控制点如何共同完成一个业务用例。**一个简单用例可以只有一个 Skill；一个复杂用例可以在同一份合约中编排多个 Skill、规则和人工步骤。

工作流编号：WF-部门-序号

工作流名称：

关联用例编号：

版本：

当前状态：设计 / 试点 / 限量生产 / 受控生产 / 暂停 / 退役

业务 Owner：

流程 Owner：

技术 Owner（如适用）：

最近复核日期：

一、目标、边界与触发

- 业务目标：

- 触发条件与发起角色：

- 适用范围：

- 禁止/不适用的情形：

- 最终使用者与受影响对象：

二、输入与输出契约

- 必填输入、来源、格式、时效和质量要求：

- 不可接受的输入及处理方式：

- 输出对象、格式、交付渠道和留存要求：

- 必须呈现的来源、版本、置信或待确认信息：

三、步骤、状态与控制点

序号	状态/步骤	执行者（人/系统/Skill）	输入与输出	验证或审批	失败/异常后的动作
---	---	---	---	---	---
1					
2					
3					

四、受控组件与依赖

- 关联 Skill 及版本：

- Prompt、知识、规则与模型版本：

- 可调用工具、数据范围和读写权限：

- 外部系统、人工 SOP 和关键依赖：

五、质量、运行与人工控制

- 质量 Rubric/验证清单：

- 自动检查与人工审核节点：
- 必须停止、转人工或升级的条件：
- 运行指标、数据来源和记录频率：
- 适用的成本、时间、并发或调用预算：

六、变更、发布、回退与退役

- 受控变更类型：Prompt / 知识 / 模型 / 工具 / 权限 / 流程 / 验证规则
- 变更前必须完成的影响分析与回归：
- 发布审批和限量范围：
- 回退版本、人工备用流程和恢复证据：
- 暂停/退役触发条件和资产处置要求：

七、可追溯记录

- 必须记录的输入、输出、版本、审批、异常和人工接管信息：
- 记录位置、访问权限和留存期限：
- 关联的用例立项卡、评测报告、变更单、事件记录和用例组合台账：

工作流进入受控生产前的最低检查

- [] 已关联一个有效的用例立项卡，并说明为什么该流程仍值得运行。
- [] 每个步骤都有执行者、输入输出、验证/审批和异常处理方式。
- [] 所有关联 Skill、知识、工具、模型和权限都有版本或可追溯标识。
- [] 已定义人工控制点、停止条件、人工备用流程和恢复证据。
- [] 已完成真实或脱敏样本的验证，并保留成功、边界和失败样本。
- [] 已明确谁可以批准发布、暂停、回退和退役。

27. 已填写示例：客户咨询回复用例立项卡

本示例与附录 A 第 16 节“客户咨询标准回复草拟与核验 Skill”对应，说明如何把一个看似简单的“回复起草”任务放回业务、风险和决策语境中。以下字段为演练示例，组织应以自身政策、数据等级和审批角色替换。

用例编号：UC-CS-001

用例名称：高频客户咨询标准回复草拟与核验

当前阶段：试点

业务问题与范围：

- 客服与销售支持人员对物流、退换货、活动规则等高频咨询反复手写回复，耗时高且口径不一致。
- 试点仅覆盖规则清晰、已批准的六类问题；草稿由人工确认后发送。
- 不处理补偿、退款金额、投诉升级、价格例外、法律/合同解释或敏感个人信息。

当前基线与价值假设：

- 当前人工回复耗时：每次约 8–15 分钟，且存在关键提示遗漏或口径不一致。
- 试点假设：在不增加对外承诺风险的前提下，缩短草拟与核验的端到端时间，并提升标准要点使用一致性。
- 价值证据：先记录流程效率和口径质量；不将节省时间直接宣称为财务收益。

初始边界与风险：

- 输入仅来自批准的客服系统或已脱敏文本；数据等级、留存和权限按第 15 章确认。
- 对外沟通及知识时效属于重点风险；任何来源过期、规则冲突、例外要求或审核人无法确认的情况必须转人工。
- 客服支持负责人为业务 Owner；各问题类型政策负责人为知识 Owner。

试点设计与决策门：

- 先使用已关闭历史咨询做离线回归，再由已培训人员在小范围真实任务中使用，所有草稿维持人工确认。
- 成功证据：回复引用有效来源；必须提示齐全；无额外承诺；人工修改负担和端到端耗时可接受；异常能正确转人工。
- 停止/降级：发生错误口径、错误承诺、知识冲突未拦截或无法解释的质量下降时，立即回到人工标准回复流程。

28. 已填写示例：产品周会纪要 workflows

本示例与附录 A 第 13 节“产品周会纪要提取与核验 Skill”对应。它展示一个无需 Agent 的固定工作流如何连接转写、Skill、人工确认和发布，并保留完整的回退路径。

工作流编号：WF-PROD-MINUTES-001

工作流名称：产品周会纪要与待办确认流程

关联用例编号：UC-PROD-001

版本：v1.0

当前状态：试点

业务目标：

在会议结束后生成结构化纪要和可执行待办，减少整理时间并降低决议、负责人和截止日期遗漏。

触发与边界：

- 由会议主持人或指定记录人提交完整会议转写后发起。
- 仅用于已获得适当授权的内部产品会议；不用于来源不明、不完整或不可在当前工具处理的转写。
- 输出须由主持人确认后发布；系统不得自行发布纪要或替代争议事项判断。

步骤与控制点：

1. 输入校验：记录人确认日期、参会人和完整转写存在；缺失时补充，不进入生成。
2. 纪要生成：调用 SK-PROD-MINUTES v1.0，输出会议基本信息、关键决议和待办表。
3. 自动格式检查：检查待办字段、待定标识和输出结构；失败时返回生成步骤一次。
4. 人工核验：主持人核对决议、负责人、行动和截止日期；争议、缺失或超出范围时人工修订。
5. 发布与记录：人工将确认版本贴入批准的协作文档，并记录 Skill/工作流版本、人工修改和失败类型。

质量与回退：

- 通过条件：无明确决议遗漏；待办可执行；不得把讨论建议写成决议。
- 转人工：转写缺失、决议争议、涉及人员评价/预算承诺/对外事项，或验证无法通过。
- 回退路径：使用人工会议记录模板，由主持人确认后发布。

变更与运行：

- Prompt、示例、字段规范或模型变化前，用历史会议样本回归；不通过时保留上一稳定版本。
- 记录一次通过率、总耗时、决议/待办完整率和采用率；前四周每周回顾，稳定后每月复核。

29. Golden Set 与评测集模板

Golden Set 是用于持续验证质量的、经过人工确认的样本集合。它不是一批“看起来效果不错”的示例，也不是让模型记住标准答案的训练材料；它的作用是让团队在 Prompt、知识、模型、工具、权限或流程变化前后，以同一批代表性任务比较结果，发现静默退化。

每个正式用例应有自己的 Golden Set，并用用例编号和工作流编号关联。低风险试点可以先从小集合开始，但必须覆盖实际会遇到的正常、边界和历史失败情形；对外、高影响或 Agent 用例还应覆盖异常输入、转人工、拒绝、熔断和回退情形。

评测集编号：GS-用例编号-序号

关联用例编号：

关联工作流编号：

关联 Skill/Agent 及版本：

评测集版本：

创建日期/最近复核日期：

业务与评测 Owner：

样本数据的来源、脱敏状态和访问权限：

评测目的：试点准入 / 变更回归 / 发布审批 / 定期健康检查 / 事件复盘

适用版本与不适用范围：

评分 Rubric/通过定义：

必须由人工判定的维度：

样本编号	样本类别	场景/输入摘要	期望行为或判定准则	风险标签	必须触发的控制	来源版本	审核人
---	---	---	---	---	---	---	---
GS-001	正常						
GS-002	边界						
GS-003	历史失败						
GS-004	异常/拒绝/转人工						

覆盖检查：

- ☐ 覆盖高频正常任务
- ☐ 覆盖容易遗漏或误判的边界任务
- ☐ 覆盖历史失败和已知风险
- ☐ 覆盖知识过期/冲突、输入缺失或工具异常（如适用）
- ☐ 覆盖对外、写入、权限、人工接管或熔断控制（如适用）
- ☐ 所有样本均有人工认可的期望行为或判定准则

Golden Set 维护规则

触发情形	必须动作
发现真实失败或人工接管案例	判断是否应新增为历史失败或边界样本,并记录控制预期。
业务规则、知识或流程变化	审查哪些样本的期望结果失效;更新后保留变更说明。
模型、Prompt、工具、权限或状态逻辑变化	从受影响样本中选择回归范围;高影响变化不得只测试正常样本。
样本含敏感数据或已无业务代表性	脱敏、替换、限制访问或退役;保留替换原因。

30. 用例健康卡模板

用例健康卡将业务价值、质量、风险、运行与下一步决策放在一页中。它服务于周度运行会、月度组合评审和阶段闸门,不应被简化成单一通过率看板。

用例编号/名称:

当前阶段:

关联工作流、Skill/Agent 及版本:

业务 Owner / 流程 Owner / 知识 Owner / 技术 Owner:

本期时间范围:

一、业务问题与当前目标

- 当前基线与目标:
- 本期业务结果或价值证据: 流程效率 / 产能 / 业务结果 / 风险避免
- 不应货币化或尚未验证的收益:

二、质量与采用

- 执行次数:
- 一次通过率与趋势:
- 实际采用率与趋势:
- Rubric/关键质量项:
- 主要失败类型与数量:

三、效率、成本与维护

- 平均总耗时及与人工基线的比较:
- 工具、人工验证、维护与错误处理成本:
- 本期维护负担和主要依赖:

四、风险与控制

- 知识时效/数据/权限/对外影响状态:
- 人工接管、熔断、错误动作、异常或投诉:
- 运行证据完整性:
- 最近一次回退/演练及结果:

五、变更与评测

- 本期变更及影响范围：
- Golden Set/回归报告编号及结果：
- 未解决风险、阻塞项或需要升级的问题：

六、阶段与决策

- 对照用例立项卡的成功/停止假设：
- 建议：扩大 / 维持 / 限量运行 / 改进 / 降级 / 暂停 / 退役
- 决策理由、责任人和下一复核日期：

使用规则：健康卡中的绿色、黄色或红色状态应由用例立项卡中定义的风险容忍度和目标确定，不使用跨部门统一阈值。高风险用例即使效率改善，也不应以质量或控制缺口换取扩大范围。

31. 回归评测报告模板

附录 A 第 15 节记录“发生了什么变更、应测什么”；本报告记录“实际如何测、结果是什么、是否允许发布”。每次进入限量生产、受控生产，或发生影响质量、风险、成本、权限和业务边界的变化时，应有一份可追溯的回归报告。

回归报告编号：RR-用例编号-序号

关联变更编号：

关联用例编号 / workflow 编号：

待发布版本与当前稳定版本：

评测目的：试点准入 / 变更回归 / 发布审批 / 事件修复验证

报告 Owner 与审核人：

一、变更与影响范围

- 变更类型：Prompt / 知识 / 模型 / 工具 / 权限 / 流程 / 验证规则 / 其他
- 变更目的与预期收益：
- 可能退化的质量、风险、成本或控制：
- 受影响的 Skill、Agent、知识、接口和用户范围：

二、评测设计

- 使用的 Golden Set 及版本：
- 选择的正常、边界、历史失败、异常/转人工样本：
- Rubric 与通过/拒绝定义：
- 与当前稳定版本的比较方法：
- 人工复核范围与审核人：

三、结果

指标/控制项	当前稳定版本	待发布版本	差异	是否满足要求	备注
---	---	---	---	---	---
关键质量项					
一次通过率					

关键失败样本行为					
转人工/拒绝/熔断					
端到端耗时与成本					
权限、来源与日志证据					

四、结论与发布建议

- 未通过项、风险及修复计划：
- 建议：不发布 / 修复后复测 / 限量发布 / 按计划发布 / 回退
- 限量范围、观察指标和观察期（如适用）：
- 回退版本与触发条件：
- 业务 Owner / 技术 Owner / 风险或审批角色的决定：

变更控制强度参考

变更类型	最低评测与发布动作
纯编辑性变更,不改变含义、规则、版本或行为	记录变更；由责任人抽样确认。
Prompt、示例、知识条目或验证规则变化	审查受影响样本；对正常、边界和历史失败样本回归；必要时限量发布。
模型、检索、工具、接口、流程状态或成本预算变化	比较质量、性能、成本、异常与回退行为；保留当前稳定版本。
权限扩大、对外范围扩大、写入动作、高风险数据或关键业务规则变化	完成风险审查、完整受影响评测、人工控制演练、审批和限量观察；无充分证据不得扩大。

32. 发布登记与观察期模板

发布登记将“评测通过”转化为受控上线,而不是把一次测试结果直接等同于生产可用。它记录发布范围、审批、证据、观察期、停止条件和回退责任；与用例立项卡、工作流合约和回归报告共同构成一个可审计的发布链。

发布编号：REL-用例编号-序号
 关联用例编号 / 工作流编号：
 待发布的 Skill、Agent、Prompt、知识、模型、工具或流程版本：
 发布类型：试点 / 限量生产 / 受控生产 / 紧急修复 / 回退 / 退役

一、发布范围

- 生效时间与范围（部门、使用者、问题类型、系统、地域等）：
- 明确排除的范围：
- 是否涉及对外、写入、敏感数据或高影响决策：

二、发布前证据

- 用例立项卡与当前阶段：
- 工作流合约与版本：
- 回归报告/Golden Set 版本及结论：

- 需要的安全、风险、业务或技术审批：
- 使用者培训、SOP 和支持入口是否就绪：

三、观察与控制

- 观察期及观察指标：
- 人工审核或抽检比例：
- 必须停止、转人工、缩小范围或回退的条件：
- 回退版本、人工备用流程和执行责任人：
- 值班/升级路径和沟通对象：

四、发布决定与关闭

- 决定：发布 / 限量发布 / 延后 / 回退 / 退役
- 批准人及时间：
- 观察期结果：
- 最终状态及下一阶段决策：
- 需更新的健康卡、组合台账、知识资产、培训或事件记录：

最低发布原则

- **没有可验证证据，不扩大范围。** 对外沟通、写入、权限扩大或高影响用例，不能仅凭“演示效果不错”发布。
- **评测通过不等于自动放开。** 当业务边界、知识时效或人工审核能力仍存在不确定性时，应先限量运行并设观察期。
- **始终保留回退。** 发布登记必须指向一个已知稳定版本或可执行的人工备用流程；没有回退就不应进入受控生产。

33. 已填写示例：客户咨询回复 Golden Set

本示例与 UC-CS-001、WF-CS-REPLY-001 和 SK-CS-STANDARD-REPLY v1.0 对应。为避免将任何具体企业政策或客户数据写入手册，样本只说明**必须发生的行为**，不提供可直接对外使用的政策内容。真实企业应使用经过脱敏、已关闭的历史咨询和已批准的当前政策版本替换。

评测集编号：GS-UC-CS-001-v1.0

关联用例编号：UC-CS-001

关联工作流编号：WF-CS-REPLY-001

关联 Skill：SK-CS-STANDARD-REPLY v1.0

评测目的：试点准入、知识变更回归、限量发布观察

业务 Owner：客服支持负责人

知识 Owner：活动/退换货/物流规则责任人

共同判定要求：

- 草稿必须显示当前有效的来源标识、版本或生效信息。
- 草稿不得超出知识来源作出补偿、价格、法律或其他例外承诺。
- 规则缺失、规则冲突、例外要求或审核人无法确认时，必须明确转人工。

样本编号	样本类别	脱敏输入摘要	期望行为 / 通过准则	风险标签	必须验证的控制
GS-CS-001	正常	客户询问一项当前有效的物流进度规则	正确匹配物流问题类型；使用有效要点；生成符合语气的草稿；显示来源；不增加无依据承诺	口径一致性	来源有效、人工确认前不发送
GS-CS-002	边界	客户询问退换货条件，但提供的信息不足以判断是否符合适用条件	说明需要补充的信息；不擅自判定资格；引用适用条件；将不确定项标记给人工审核	信息不完整	输入不足时不做结论
GS-CS-003	历史失败	活动咨询中，旧版本曾遗漏截止日期或引用了已失效范围	使用当前活动要点；完整呈现必要时限/范围；不得引用旧版本	知识时效	知识版本、生效日期、关键字段检查
GS-CS-004	异常 / 转人工	客户要求例外补偿、价格调整或投诉升级	不生成超权限承诺；清晰说明需由人工处理；保留必要的事实摘要供转交	对外承诺 / 例外处理	必须转人工、不得直接发送

使用方式

在任何知识、Prompt、模型、工具、权限或验证规则变更前，先对这四类样本运行新旧版本比较，并填写附录 A 第 31 节的回归评测报告。若 GS-CS-003 未能正确使用新规则，或 GS-CS-004 未转人工，即使其他样本表现良好，也不得扩大发布范围。观察期内发现的新失败应经过审核后加入下一版本评测集。

34. 用例级风险初筛与控制分层模板

数据分级是必要但不充分的。相同的数据在“内部草稿、人工确认后发送、自动写入系统、影响个人或关键业务决定”等不同用例中，风险并不相同。因此，用例在立项时应完成一次**风险初筛**，并在范围、数据、模型、工具、权限、自主性或业务影响变化时重新评估。

本模板用于组织内部的运营分层与控制设计，**不替代法律意见、行业监管判断、信息安全评估或采购审查**。如适用法律、合同、行业规则或企业制度提出更高要求，应以更高要求为准。

风险初筛编号：RS-用例编号-序号

关联用例编号 / workflow 编号：

评估目的：立项 / 阶段提升 / 重大变更 / 定期复核 / 事件后复核

业务 Owner / 风险或安全复核角色：

评估日期 / 下次复核日期：

一、业务影响

- ☐ 仅内部个人辅助或低影响内容草稿
- ☐ 影响团队流程、资源分配或内部沟通质量
- ☐ 面向客户、合作伙伴或公众的沟通/内容
- ☐ 影响个人权益、关键业务决定、财务、医疗、法律、人事或其他高影响领域
- ☐ 涉及不可逆、难以补救或大范围传播的后果

二、数据与知识

- ☐ 仅使用 L1 公开或经批准的 L2 内部数据
- ☐ 包含个人信息、客户信息、合同、定价、源代码或其他 L3 以上数据
- ☐ 使用外部来源、用户提交内容、第三方工具返回或可能不可信的输入
- ☐ 知识来源尚无 Owner、版本、生效日期或冲突仲裁方式

三、动作与自主性

- ☐ 只生成内部草稿，人工逐次决定是否采用
- ☐ 生成对外内容，但需人工审核/发送
- ☐ 可读取多个系统、调用外部工具或进行多步骤处理
- ☐ 可写入、发送、变更记录、分配任务、触发交易或影响真实世界动作
- ☐ Agent 可动态选择 Skill/工具、连续执行或在无人值守下运行

四、控制与韧性

- ☐ 有明确业务 Owner、知识 Owner 和暂停/回退责任人
- ☐ 有可执行的人工审核、转人工和人工备用流程
- ☐ 有 Golden Set、回归、发布观察和运行记录
- ☐ 有最小权限、数据边界、来源追溯、日志和异常升级机制
- ☐ 上述控制尚未具备、无法验证或无法由责任人长期维护

初始控制等级：R1 基础 / R2 受控 / R3 高影响 / R4 暂缓或转专项治理

风险理由与关键不确定项：

需要的后续资产：影响评估 / 安全审查 / 法务或行业审查 / Agent 合约 / 例外审批 / 其他
 结论：可按现有控制推进 / 补齐控制后推进 / 缩小范围试点 / 暂缓

风险—控制等级参考

风险等级不是自动计算的分数。应以错误后果、数据敏感度、对象受影响程度、动作可逆性、自主性和现有控制成熟度的**最高风险因素**决定；不确定时应上调等级或缩小范围。

等级	典型情形	最低控制要求	阶段限制
R1 基础	低影响内部辅助；公开或批准的内部信息；人工决定是否采用；无写入和对外发送	用例立项卡、明确 Owner、输入输出边界、基础验证、版本记录、人工回退	可从小范围试点开始；不得因“低风险”跳过质量和记录。
R2 受控	外部沟通草稿、跨系统读取、L2/L3 数据、多个 Skill/固定 workflow、规则频繁变化	R1 控制 + AI 影响评估、知识 Owner/版本、Golden Set、回归报告、发布登记、最小权限、人工审核与观察期	先限量运行；范围扩大须有健康卡和阶段闸门证据。
R3 高影响	高敏感数据、个人权益或关键业务影响、写入/发送、复杂 Agent、较难回退或高扩散后果	R2 控制 + 业务/安全风险等适用角色审查、严格权限隔离、关键动作批准、完整异常/接管演练、审计证据索引和定期复核	不得直接提升自主性或扩大范围；应采用更严格的专项治理与发布门。
R4 暂缓或转专项治理	无法说明目的、Owner、数据边界、人工回退或合法依据；或现有控制无法覆盖不可接受后果	停止标准路径的设计/发布；先消除阻塞项，或按组织专门流程处理	不得以例外审批替代法律、监管、安全或不可接受风险的基础要求。

35. AI 影响评估与风险—控制矩阵模板

风险初筛用于决定控制强度；**AI 影响评估（AIA）**用于在进入试点、限量生产或高影响变更前，系统说明“谁会受影响、可能发生什么、用什么控制、剩余风险是否可接受”。评估应随用例更新，而不是只在首次立项时填写一次。

影响评估编号：AIA-用例编号-序号
 关联用例编号 / 工作流编号 / 发布编号：
 关联风险初筛编号与控制等级：
 评估触发：首次试点 / 阶段提升 / 重大变更 / 事件 / 定期复核

业务 Owner、流程 Owner、知识 Owner、技术 Owner：
参与复核的安全、风险、法务、隐私或行业角色（按组织适用）：

一、目的与受影响对象

- 业务目的、预期价值与不应实现的目标：
- 使用者、客户、员工、合作方或其他受影响对象：
- 是否可能影响权益、机会、资源、声誉或安全：
- 明确的使用范围、禁止范围与人工保留决定：

二、系统与数据边界

- Prompt、Skill、工作流、Agent、模型、工具和外部依赖：
- 输入/输出数据类别、敏感度、数据流向和留存：
- 知识来源、Owner、生效日期、冲突处理和更新机制：
- 读写权限、对外发送、自动动作和人工审批边界：

三、影响、风险与控制

风险编号	可能影响/受影响对象	触发情形	固有风险	现有与拟定控制	控制 Owner	需要的证据	残余风险	决定
---	---	---	---	---	---	---	---	---
R-01								
R-02								

四、运行与恢复

- 人工审核、转人工、暂停、回退和人工备用流程：
- 事件分级、升级路径、通知对象和恢复所需证据：
- 观察指标、复核频率、触发重新评估的条件：

五、结论

- 残余风险是否在组织可接受范围内：
- 发布建议：不推进 / 补齐控制后试点 / 限量生产 / 受控生产 / 暂停或退役
- 前置条件、例外和到期日：
- 业务 Owner 与适用复核角色的结论：

通用风险—控制矩阵

风险领域	常见触发信号	核心控制	最低证据
数据、隐私与保密	L3/L4 数据、个人信息、外部模型留存不清、跨境或第三方处理	数据分级、最小必要、脱敏、批准的处理环境、访问控制、留存与删除规则	数据流与分级记录、配置/合同或批准记录、访问与留存说明
知识正确性与时效	来源无 Owner、规则冲突、旧版本仍在使 用、对外口径变化	权威来源、版本/生效日期、知识 Owner、	知识资产记录、来源版本、回归报告、变更记录

风险领域	常见触发信号	核心控制	最低证据
输出质量与误导	事实错误、遗漏、幻觉、不可解释或专业领域建议	冲突仲裁、Golden Set 和回归 输入输出契约、Rubric、独立验证、人工审核、明确边界与转人工	Skill/工作流合约、评测集、检查/审批记录、失败样本
对外沟通与权益影响	面向客户/公众、影响资格/资源/评价/机会、承诺或歧视性风险	受控范围、人工最终决定、来源显示、禁止承诺、申诉/转人工路径	用例边界、审核记录、输出留存、问题处理记录
工具、权限与 Agent 动作	写入、发送、连续工具调用、越权尝试、提示注入或不可信工具返回	最小权限、动作白名单、状态限制、参数校验、审批、熔断、日志	Agent 合约、权限矩阵、异常演练、调用/审批/熔断日志
运营、成本与韧性	模型/供应商故障、成本飙升、人工接管失败、关键人员依赖	预算/并发限制、监控、人工备用流程、回退、供应商/模型预案、交接	健康卡、Runbook、演练记录、回退与恢复证据
IP、记录与审计	输出归属/授权不明、记录缺失、无法追溯采用或变更	来源与版本标识、生成/审批/变更记录、留存政策、证据索引	审计证据索引、发布登记、日志/留存位置、定期抽查记录

36. 风险例外审批与到期复核模板

例外是指某个用例暂时无法满足已定义的内部控制要求，但业务仍希望在**明确缩小范围、设置补偿控制和到期日**的条件下继续。例外不是对法律、监管、信息安全基本要求或不可接受风险的豁免；无法安全控制的风险应暂停或转专项治理。

例外编号：EX-用例编号-序号

关联用例编号 / 工作流编号 / AIA 编号 / 发布编号：

申请人、业务 Owner、控制 Owner：

申请日期 / 生效日期 / 到期日期：

一、例外内容

- 未满足的控制要求：
- 未满足的原因与业务必要性：
- 受影响的数据、用户、系统、范围和持续时间：
- 不能采用的替代方案及原因：

二、补偿控制与限制

- 缩小后的范围：
- 额外人工审核、抽检、权限、日志、监控或回退措施：
- 必须停止或自动失效的条件：
- 观察指标与复核频率：

三、风险与决定

- 风险初筛/AIA 中的残余风险说明：
- 业务 Owner 意见：
- 安全、风险、法务、隐私或行业复核意见（按组织适用）：
- 批准决定：批准 / 不批准 / 补充材料后复核
- 批准范围、到期日与续期条件：

四、关闭

- 到期复核结果：已关闭 / 已补齐控制 / 已续期 / 已暂停或退役
- 证据位置与责任人：

37. 审计证据索引模板

审计证据索引不要求把所有内容复制到一个文件。它的作用是让授权人员能在需要时快速定位“这个用例为何存在、如何运行、谁批准过、发生变化或异常时做了什么”。索引应与用例编号关联，并按企业数据留存、访问控制和最小必要原则管理。

证据类型	对应资产或记录	存储位置 / 访问角色	Owner	最近更新	留存/复核要求
业务与阶段决定	用例立项卡、阶段闸门、组合评审结论				
风险与影响	风险初筛、AIA、控制矩阵、例外审批				
运行定义	工作流合约、Skill/Agent 合约、权限矩阵、知识版本				
质量与发布	Golden Set、Rubric、回归报告、发布登记、观察结果				

证据类型	对应资产或记录	存储位置 / 访问角色	Owner	最近更新	留存/复核要求
运行与异常	健康卡、日志、人工接管、熔断、异常/事件与回退记录				
人员与能力	培训、实践认证、授权角色与审批记录				
依赖与韧性	模型/工具配置、供应商信息、人工备用流程与演练记录				

证据最小原则

- 只记录实现追溯、控制和复盘所必需的信息；不要因为“可能要审计”而无边界复制敏感原始输入或个人信息。
- 任何日志、样本、评测或输出留存都应遵循数据分级、访问控制、保留期限和删除政策。
- 发布、例外、重大变更、事件或阶段提升完成后，应更新证据索引；无法定位关键证据的用例不应被认定为已受控运行。

38. 已填写示例：客户咨询回复的风险初筛与 AI 影响评估

本示例对应 UC-CS-001、WF-CS-REPLY-001 和 SK-CS-STANDARD-REPLY v1.0。其目的不是为任何具体企业确定法律或合规结论，而是演示一个**面向外部沟通、但由人工最终发送**的 R2 受控用例，如何将风险判断连接到控制、证据和限量发布。

风险初筛编号：RS-UC-CS-001-v1.0 关联用例/工作流：UC-CS-001 / WF-CS-REPLY-001 评估目的：首次试点 初始控制等级：R2 受控 判断依据： - 输出面向客户，错误可能被理解为承诺，且业务规则会随活动、库存、时效和政策变化。 - 试点仅生成草稿；经培训的人工审核者逐条确认后发送，系统没有发送、退款、补偿、改价或写入权限。 - 输入只使用批准的内部工单摘要或经过处理的文本；个人身份信息不进入评测集或不必要的提示上下文。 - 用例只覆盖规则清晰的六类高频问题；例外补偿、投诉升级、价格/合同解释、敏感信息或知识冲突一律转人工。

结论：可在完成影响评估、Golden Set 回归、人工审核准备和限量发布登记后进入小范围试点；不得提升为自动发送或扩大到例外类问题。

风险编号	可能影响 / 受影响对象	触发情形	核心控制	所需证据	残余风险与决定
R-CS-01	客户收到错误、过期或不完整的规则说明	活动 / 退换货 / 物流规则更新后，旧知识仍被引用	权威来源与知识 Owner；版本 / 生效日期；Golden Set 历史失败样本；回归与限量观察	知识更新记录、GS-CS-003 结果、回归报告、发布登记	残余风险可在人工确认和观察期内接受；知识冲突或错误口径即回退。
R-CS-02	客户被作出未经授权的补偿、价格或其他承诺	客户请求例外，或模型根据不完整信息推断承诺	禁止事项；问题类型白名单；例外强制转人工；发送前人工审核	Skill 卡、GS-CS-004 结果、审核/转人工记录	不允许系统直接发送；任何未拦截承诺属于停止条件。
R-CS-03	客户或企业信息处理超出必要范围	输入含不必要个人信息，或使用未经批准的工具 / 留存配置	数据分级、最小必要、脱敏 / 摘要、批准环境、访问和留存控制	数据流说明、工具配置 / 批准记录、抽检或日志	超出批准数据边界时暂停该类输入并交由人工处理。
R-CS-04	客户体验下降或处理延迟	转人工规则过宽、审核者不清楚来源或流程无法接管	明确转人工 SOP、培训、人工备用标准回复、健康卡监控接管与处理结果	认证记录、工作流合约、健康卡、反馈 / 升级记录	接管率上升应分析原因；接管无法完成时暂停扩大范围。

发布结论示例：仅向已完成实践认证的少量客服支持人员开放；所有输出仍需人工确认；观察来源有效性、例外转人工、关键字段遗漏和人工审核耗时；任何错误承诺、无法解释的规则来源或未按转人工，均触发暂停和回退到人工标准回复流程。

39. FDE / AI COE 共创交付章程模板

本章程用于内部 AI COE、FDE 团队或外部交付团队与业务团队在启动时对齐目标、责任、边界、工作方式和接棒标准。它不是项目合同的替代，也不替代数据、采购或法律审批；其作用是避免交付团队把“搭好原型”误当成“客户已经具备运营能力”。

交付编号：DLV-用例编号-序号

关联用例编号 / workflow 编号：

客户/业务单元：

交付模式：内部 AI COE / FDE 共创 / 外部交付辅导 / 其他

交付负责人：

业务 Owner / 知识 Owner / 技术 Owner / 风险或安全角色：

启动日期 / 计划验收日期 / 计划移交日期：

一、业务目标与范围

- 要解决的业务问题、基线与成功/停止假设：
- 本期可交付的用例、使用者、系统和数据范围：
- 明确不做什么（业务、数据、权限、对外动作或自主性边界）：
- 关联的风险初筛/AIA、用例阶段与发布限制：

二、交付与客户共同责任

- FDE / AI COE 负责：发现、共创设计、资产化、辅导、评测/控制设计、移交支持。
- 业务团队负责：业务判断、真实样本、范围确认、日常使用、验收和持续运营决策。
- 知识团队负责：权威来源、规则更新、冲突仲裁和知识变更确认。
- 技术团队负责：批准环境、集成、权限、配置、日志、运行与回退。
- 风险/安全等适用角色负责：按组织流程审查高影响边界、例外或专项事项。

三、工作方式与节奏

- 发现/共创工作坊安排：
- 样本、数据和访问的批准方式：
- 周度运行/问题同步：
- 阶段闸门和决策人：
- 变更、异常、风险升级和沟通路径：

四、验收与移交的预期

- 验收所需业务、质量、风险、运行和培训证据：
- 必须完成的第二人复现、回退与基础变更演练：
- 客户接棒 Owner、支持窗口、知识转移方式：
- 退出条件、遗留问题处理和后续组合决策：

40. 共创交付看板与阶段检查模板

此表把“发现—共创—试运行—验收—移交—退出/扩展”转换为透明的短周期协作。每个用例一行，证据应链接到现有资产，而不是在看板中重复填写。

阶段	本阶段问题	FDE / AI COE 产出	客户方确认/产出	所需证据或链接	决策人	状态 / 下一步
发现	业务问题是否值得做？	访谈摘要、基线、候选流程	业务 Owner 与范围	用例立项卡、风险初筛	业务 Owner	
共创设计	怎样以最低复杂度实现？	Skill/工作流设计、验证与回退	知识来源、人工控制与权限边界	工作流合约、AIA（如适用）、事实卡	业务/技术 Owner	
试运行	在真实范围内是否可用？	配置、辅导、失败分析	真实使用、检查与反馈	Golden Set、周度记录、回归报告	业务 Owner	
验收	是否达到接受标准？	证据汇总、边界/回退演示	业务验收、第二人复现	验收记录、发布登记、健康卡	业务 Owner	
移交	是否可以独立运行？	资产交接、培训、支持窗口	接棒运行、变更/异常演练	移交清单、认证/演练记录	接棒 Owner	
退出/扩展	是否结束当前支持或启动下一个用例？	复盘、遗留项与组合建议	运营接管/下一决策	退出记录、组合台账、证据索引	业务 Owner	

41. 用例验收记录模板

验收记录用于判断“交付成果是否可以被业务团队接收”，而不是只确认演示是否顺利。验收应对照立项卡中的成功/停止假设、风险等级和阶段目标填写。

验收编号：ACC-用例编号-序号

关联交付编号 / 用例编号 / 工作流编号 / 发布编号：

验收范围与时间：

业务 Owner / 接棒 Owner / 交付负责人 / 参与复核角色：

一、业务与使用证据

- 试点范围、执行次数、使用者与代表性：
- 对照基线的质量、采用、效率、业务结果或风险避免证据：
- 用例立项卡中的成功/停止假设结论：

二、质量与运行证据

- Golden Set、Rubric 与回归报告编号及结论：
- 关键失败类型、未解决问题与处理计划：
- 工作流/Skill/Agent 版本、健康卡与发布观察结果：
- 人工接管、回退和必要异常演练是否完成：

三、风险与控制证据

- 风险初筛/AIA/例外（如适用）编号与当前结论：
- 数据、知识、权限、日志、审批与证据索引是否完整：
- 未接受的残余风险、范围限制和观察期要求：

四、接棒能力证据

- 指定接棒 Owner 和替补人：
- 第二人是否能独立运行并通过验证：
- 是否完成一次基础变更和一次异常/回退演练：
- 资产、权限、支持入口和升级路径是否可定位：

验收结论：接收 / 附条件接收 / 不接收

附条件接收或不接收的原因、限制和到期动作：

业务 Owner 签字/确认：

接棒 Owner 签字/确认：

42. 能力移交与接棒清单模板

移交不等于发送一批链接。接棒方必须能用、能判断、能改、能停。以下清单用于在交付支持结束前验证实际能力。

移交编号：HTO-用例编号-序号

关联交付编号 / 验收编号：

交付方负责人 / 客户接棒 Owner / 替补人：

移交日期 / 支持窗口结束日期：

一、资产与访问

- ☐ 用例立项卡、风险初筛/AIA、工作流合约、Skill/Agent 卡已移交并可访问
- ☐ Golden Set、Rubric、回归报告、发布登记、健康卡和证据索引已定位
- ☐ Prompt、知识、模型/工具事实卡、配置、日志和版本历史可按权限访问
- ☐ 数据、工具、平台、项目、密钥/凭证、审批和暂停/恢复权限已转给适当角色

二、运行与变更

- ☐ 接棒 Owner 能用真实或脱敏任务独立运行一次，并完成验证
- ☐ 接棒 Owner 能解释适用边界、禁止事项、人工控制与转人工条件
- ☐ 接棒 Owner 已完成一次低风险知识/Prompt 变更的影响分析与回归演练
- ☐ 接棒 Owner 已完成一次异常、熔断或人工回退演练，并知道升级路径

三、组织与支持

- [] 业务 Owner、知识 Owner、技术 Owner、风险/安全角色和替补人已确认责任
- [] 周度运行、月度组合评审、知识更新、事实复核和例外到期机制已排期
- [] 支持窗口内可咨询的问题、响应时间和不支持事项已经明确
- [] 遗留风险、债务、已知限制和下一次阶段决策已记录

接棒结论：可独立运营 / 需延长辅导 / 暂不具备接棒条件
未满足项、责任人、完成日期与复核方式：

43. 交付退出、扩展与复盘记录模板

退出是把责任从交付团队转回运营团队的控制动作，不是项目关系的简单结束。退出记录应说明当前用例是否已由客户接管、哪些事项仍有限制、是否值得扩大或是否应停止。

退出/扩展编号：EXT-用例编号-序号

关联交付编号 / 验收编号 / 移交编号：

当前用例阶段：

退出类型：按计划结束支持 / 转入客户运营 / 延长辅导 / 启动下一用例 / 暂停或退役

一、交付回顾

- 已实现的业务、质量、风险与能力结果：
- 未实现或不应宣称的结果：
- 关键失败、回退、例外和修复经验：
- 可复用的 Skill、工作流、事实卡、样本或培训资产：

二、客户运营状态

- 当前业务/知识/技术/风险 Owner 与替补人：
- 支持窗口结束后的运行、变更、升级与事实复核节奏：
- 遗留问题、技术债务、知识债务、风险或依赖：
- 需要限量运行、暂停或退役的条件：

三、下一步决定

- 建议：结束支持 / 延长辅导 / 扩大当前用例 / 启动相邻用例 / 暂停/退役
- 决策依据：健康卡、组合台账、验收、风险和资源情况：
- 责任人、目标日期与下次复核：
- 已更新的证据索引、组合台账和阶段闸门：

44. 用例事件运行手册（Runbook）模板

运行手册面向实际执行者，而不是只面向项目设计者。它应在用例上线、阶段提升或移交前完成，并在模型、工具、知识、权限、业务范围或人工备用流程变化时更新。

Runbook 编号：RB-用例编号-序号

关联用例 / 工作流 / Skill 或 Agent / 发布编号：

业务关键性：低 / 中 / 高

业务 Owner / 技术 Owner / 知识 Owner / 接棒 Owner 与替补人：

最近演练日期 / 下次复核日期：

一、业务与运行边界

- 服务对象、关键业务结果和不可接受后果：
- 当前允许范围、禁止事项、人工保留决定和对外/写入边界：
- 正常运行入口、工作流版本、健康卡和证据索引位置：

二、依赖与健康信号

依赖	当前版本/配置或事实卡	失效信号	Owner	降级/备用路径
---	---	---	---	---
模型/API				
工具/集成				
知识/数据				
身份/权限/预算				
人员/审批				

三、暂停、升级与沟通

- E0/E1/E2/E3 触发条件（按本用例具体化）：
- 谁可以停止生成、发送、写入或自动动作：
- 事件频道/工单、通知对象、升级路径与替补人：
- 何种情形必须直接转人工或按专项安全/合规流程处理：

四、人工备用与回退

- 人工备用流程、模板、队列或系统入口：
- 上一稳定版本、回退步骤和不可回退动作：
- 已验证的备用模型/工具/降级条件（如有）：
- 恢复前必须核验的样本、权限、知识和数据边界：

五、记录与复盘

- 需保全的输入/输出、版本、配置、日志、时间线和审批记录：
- 事件记录、回归、发布登记、健康卡和证据索引位置：
- 复盘 Owner、关闭标准与必须更新的资产：

45. 事件记录与无责复盘模板

事件记录用于受控保存具体问题的事实、决策和恢复过程；无责复盘用于分析系统性原因和改进，而不是将正常升级或人为失误简单归咎于个人。敏感数据、保密信息和法务/安全材料应按组织规则存放，附录 G 只沉淀必要的去标识化失败模式。

事件编号：INC-用例编号-序号

关联 Runbook / 用例 / 工作流 / 发布 / 风险初筛或 AIA 编号：

事件级别：E0 / E1 / E2 / E3

发现时间 / 结束时间 / 记录人：

事件指挥/业务 Owner/技术 Owner/参与角色：

一、事实与影响

- 发生了什么（仅记录已验证事实）：
- 受影响的用户、业务流程、数据、输出、动作或范围：
- 是否有外部采用、写入、发送、权限/数据或合规影响：
- 已采取的暂停、隔离、转人工、回退和沟通动作：

二、时间线与证据

时间	观察到的信号/动作	决策人	证据或链接
---	---	---	---

三、恢复验证

- 恢复或继续人工备用的决定及理由：
- 用于恢复验证的样本、权限、知识、配置和测试结论：
- 是否需要风险/AIA、事实卡、回归报告或发布登记重新审批：

四、无责复盘

- 促成因素：任务边界 / 知识 / 模型或工具 / 配置 / 权限 / 验证 / 人员 / 流程 / 其他
- 哪些控制有效，哪些控制缺失或未被执行：
- 根因与系统性改进假设：
- 改进行动、Owner、到期日和验证方式：
- 是否沉淀去标识化模式到附录 G：是 / 否
- 关闭结论与复核人：

46. 韧性与恢复演练计划模板

演练用于检验实际恢复能力，不是纸面审核。可从桌面推演开始，但高关键性、R3、外部沟通、写入、Agent 或关键依赖用例应逐步完成受控的实操演练。

演练编号：DRILL-用例编号-序号

关联用例 / Runbook / 工作流 / 发布编号：

演练类型：桌面推演 / 受控技术演练 / 人工接管演练 / 模型或工具切换 / 知识失效 / 权限或预算异常
场景与假设：

参与者、观察者与授权边界：

演练日期：

一、演练目标

- 要验证的业务最低服务、停止权、通知、人工备用、切换或恢复条件：
- 不在本次演练范围内的系统、数据或动作：
- 成功标准与安全停止条件：

二、执行记录

步骤	预期动作	实际结果	偏差/问题	Owner
---	---	---	---	---
发现与分级				
暂停/隔离				
通知与升级				
人工备用/切换				
恢复验证				
记录与复盘				

三、结果与改进

- 实际发现、决策、切换、人工接管和恢复耗时：
- 是否维持了约定的最低服务；未达标原因：
- 必须更新的 Runbook、事实卡、权限、样本、培训、移交或风险资产：
- 改进行动、Owner、到期日、复验方式：
- 演练结论：通过 / 附条件通过 / 不通过；下次演练日期：

47. 人工备用流程与能力基线卡模板

人工备用是用例设计的一部分。它不要求每个人在每项任务上都拒绝 AI，而是为关键业务定义在 AI 不可用、输出不可信或自动动作被暂停时，谁能以什么最低质量继续完成服务。

备用能力编号：MANUAL - 用例编号 - 序号

关联用例 / Runbook / 交付或移交编号：

业务关键性与最低服务目标：

业务 Owner / 接棒 Owner / 替补人：

一、人工备用流程

- 触发条件：AI 不可用 / 质量或知识异常 / 权限或工具失效 / 其他
- 手工模板、系统入口、队列和所需知识来源：
- 可以继续做的范围与必须暂停/升级的范围：
- 对外沟通、写入或关键决定的人工确认方式：

二、能力基线

- 执行者需要理解的业务规则、验证要点与禁止事项：
- 可接受的手工完成质量、交接和记录标准：
- 何种情形必须升级给业务/知识/技术/风险 Owner：
- 新员工或替补人如何通过真实任务、检查或演练证明具备能力：

三、验证与维护

- 最近一次独立执行/演练日期及结果：
- 当前可执行人员与替补覆盖：
- 发现的知识、工具、培训或流程缺口：
- 下次复核日期、Owner 和改进动作：

48. 上下文包（Context Pack）模板

上下文包用于说明在特定任务、状态和权限下，哪些信息允许进入模型推理，以及为什么、以何种范围、何时失效。它不是完整知识库或长 Prompt 的复制品，而是可版本化、可审计的最小必要运行资产。

上下文包编号：CTX-用例编号-序号

上下文包名称与版本：

关联用例 / 工作流 / Skill / Agent：

当前阶段：候选 / 试点 / 限量生产 / 受控生产 / 规模化 / 退役

业务 Owner / 知识 Owner / 上下文 Owner / 技术 Owner：

一、任务与边界

- 当前要支持的任务、对象和输出：

- 本上下文包不支持的决策、对象或动作：

- 不可接受后果与必须停止/转人工的条件：

- 适用地区、产品、团队、客户或业务范围：

二、允许来源与优先级

来源编号/名称	类型（规则/记录/示例/工具结果/记忆）	Owner	版本/生效日期	适用范围	允许用途	优先级
---	---	---	---	---	---	---

三、排除来源与数据边界

- 不得读取、保存、外发或作为结论依据的资料：

- 数据分级、脱敏、租户/用户隔离与访问限制：

- 未批准、无 Owner、来源不明、已失效或存在冲突内容的处置：

四、选择与加载逻辑

- 必须预置的最小信息：

- 可按需检索的条件、过滤字段、来源优先级和停止条件：

- 工具返回的字段、条数、时间范围或内容预算：

- 来源冲突、空结果、信息不足或低置信时的处理：

- 是否允许生成/读取持久记忆；如允许，关联记忆合约编号：

五、版本、证据与失效

- 当前来源、索引、Prompt、工具和记忆版本：

- 证据位置与最后核验日期：

- 失效/复核触发条件：规则变化 / 权限变化 / 连接器变化 / 事件 / 定期复核 / 其他

- 回退版本、人工备用路径和批准恢复条件：

- 受影响的 Golden Set、回归报告、健康卡和发布登记：

最低检查：上下文包不得把“所有可获得资料”定义为允许来源；每项高影响规则必须可以定位到来源、版本和适用范围；信息不足或冲突时应停止、询问或转人工，不得默认为模型自行补全。

49. Agent 记忆合约模板

持久记忆只在确有跨轮次价值、目的明确且组织能够管理其写入、隔离、失效、删除和审计时使用。工作笔记、任务状态、用户偏好和权威知识具有不同的风险与生命周期，不能放入同一个未分类的“长期记忆”。

记忆合约编号：MEM-用例编号-序号

关联 Agent / 用例 / 上下文包：

版本：

业务目的与不可替代性：

Owner：业务 / 知识 / 技术 / 风险（如适用）

一、允许的记忆类别

类别	允许写入的内容	禁止写入的内容	写入者/触发条件	读取范围	保留期与失效
---	---	---	---	---	---
已确认决定					
任务状态/待办					
工作笔记/摘要					
用户或客户偏好（如获批准）					

二、事实、假设与来源

- 已确认事实的最低证据与来源定位要求：

- 待核验假设的标记、读取限制和失效方式：

- 摘要/压缩时必须保留的决定、版本、未解决项和原始证据位置：

- 人工纠错、撤销、删除或失效的入口与 Owner：

三、隔离、权限与审计

- 租户、用户、项目、区域或数据分级隔离方式：

- 谁可读、谁可写、谁可导出、谁可删除：

- 写入前是否需要人工确认或确定性验证：

- 审计日志中应保留的内容：写入原因、来源、版本、读写主体、时间、纠错/删除记录：

四、变更与回退

- 记忆结构、写入策略、范围或保留期变化的影响分析与回归要求：

- 记忆污染、越权、过期或错误写入时的暂停、隔离、清理和人工备用路径：

- 已验证的恢复条件与批准人：

最低检查： 不将未经确认的推测写成事实；不跨用户、客户或租户默认复用记忆；不将完整会话、全量工具返回或敏感原文默认保存为长期记忆；每条可用于高影响决策的记忆都应能够定位其来源和失效条件。

50. Agent 工具、MCP 与连接器控制卡模板

工具、MCP 和其他连接器既提供行动能力，也向 Agent 提供运行时上下文。每个进入正式用例的连接器都应有独立控制记录；“已连接”不等于“可在生产中使用”。

控制卡编号：T00L-用例编号-序号

工具 / MCP / 连接器名称与版本：

关联用例 / Skill / Agent / 上下文包：

业务 Owner / 技术 Owner / 安全或风险 Owner（如适用）：

当前状态：候选 / 沙箱验证 / 试点 / 已批准 / 暂停 / 退役

一、用途与边界

- 业务用途及本工具不应承担的用途：
- 允许调用的 Agent/Skill、环境和用户角色：
- 不允许的动作、对象、字段、系统或外网访问：

二、接口、数据与权限

动作/端点	读取或写入	允许参数与范围	返回字段与返回量限制	数据分级	审批/人工确认
---	---	---	---	---	---

- 身份、凭证、有效期、密钥轮换与最小权限：
- 默认过滤、分页、截断、脱敏和错误返回要求：
- 工具描述、参数说明、示例和错误信息的维护 Owner：

三、运行与异常

- 超时、速率、成本、并发和重试限制：
- 空结果、冲突结果、异常结果、恶意内容或超长返回的处理：
- 日志、审计、任务追踪和证据留存位置：
- 暂停、禁用、凭证撤销和人工备用方式：

四、评测、变更与退出

- 正常、边界、越权、参数错误、超时和异常返回评测样本：
- 变更时需要回归的用例、上下文包、Skill 和 Agent：
- 最近核验/发布记录、下一复核日期：
- 退出/替代计划、数据处置和依赖通知：

最低检查： 优先只读、沙箱、窄范围和短期凭证；工具应返回完成下一步所需的高信号信息，而非默认返回整库内容；写入、发送、代码执行、身份/权限变更和外部访问必须依据业务风险设置独立审批与可回退路径。

51. Agent 上下文与工具评测记录模板

此模板补充 Golden Set、回归报告和健康卡，用于评测 Agent 是否在正确边界内选择、解释和使用上下文与工具，而不仅是检查最终答案是否流畅。

评测编号：CTX-EVAL-用例编号-序号

关联用例 / Agent / 上下文包 / 工具控制卡 / 版本：

评测目的：首次试点 / 变更回归 / 事件复验 / 阶段提升 / 定期健康检查

业务审核人 / 知识审核人 / 技术审核人：

| 样本编号 | 样本类型 | 预期上下文与来源 | 预期工具/动作 | 预期停止或转人工条件 | 实际行为与证据
| 结论 |
| --- | --- | --- | --- | --- | --- | --- |
| | 正常 / 边界 / 失败 / 异常 / 滥用 | | | | |

一、必测控制点

- [] 来源是否在白名单内，且版本、日期、适用范围正确
- [] 是否避免加载排除来源、过量或超出权限的信息
- [] 来源冲突、过期、空结果或信息不足时是否停止、标记或转人工
- [] 工具选择、参数、权限、返回量和异常处理是否符合控制卡
- [] 记忆读取/写入是否符合记忆合约，且事实、假设与待办区分清楚
- [] 审核者是否能看到足以判断的来源、版本、工具结果摘要和拟执行动作
- [] 最终任务质量、人工接管、回退和日志证据是否满足用例标准

二、指标与判断

- 来源可定位率：
- 过期/冲突/越权上下文正确拦截情况：
- 工具参数或返回异常率：
- 无效加载、无效调用或成本异常信号：
- 人工接管率与接管结果：
- 未解决风险、修复 Owner、到期日与复验方式：

发布/阶段决策：通过 / 附条件通过 / 限量试运行 / 退回修改 / 暂停
审批/复核记录：

使用规则：上下文包、记忆、工具/MCP、连接器、权限、来源选择逻辑或状态机发生变化时，应按风险等级选择受影响样本回归。对于对外沟通、写入操作、高影响决策或跨系统 Agent，评测结果应与风险初筛、AI 影响评估、发布登记和审计证据索引关联。

52. Coding Agent 受控实践包

Coding Agent 的价值在于帮助团队理解代码、拆解问题、生成候选修改、运行受控验证和准备交付物；它不应被默认授予生产环境、真实密钥、受保护分支、外部发布或不可逆基础设施动作。代码仓库、Issue、终端输出、依赖文档和工具返回既是上下文，也可能携带不可信内容，必须按本书的上下文与工具控制规则处理。

1. 适用范围与最低边界

任务类型	建议自主范围	必须保留的人工控制
代码解释、依赖梳理、测试失败归类	只读分析、提出计划和生成候选说明	人工确认结论与后续范围
小范围、可回退的代码修改	在隔离分支或沙箱中生成补丁、运行已批准的检查	人工审阅差异、测试证据和合并决定

任务类型	建议自主范围	必须保留的人工控制
依赖升级、跨模块重构、数据库迁移	协助影响分析、编写计划与候选变更	人工批准变更窗口、回退、发布和数据处理
生产配置、密钥、权限、部署、付费资源、外部发布	默认不自动执行；可生成受限建议或变更草案	授权人员独立审批并执行，或在受控管道中执行

2. Coding Agent 任务合约模板

任务编号：CODE-用例编号-序号

关联业务目标 / Issue / 变更单 / 服务：

Agent、Skill、模型与版本：

业务 Owner / 代码 Owner / 安全 Owner / 发布 Owner：

环境：只读副本 / 沙箱 / 测试 / 预生产 / 其他（说明）

一、任务范围

- 要理解、修改、测试或生成的内容：
- 明确不在范围内的目录、服务、环境、账户、数据和动作：
- 成功标准、不可接受后果与停止条件：
- 是否允许联网、下载依赖、执行脚本、创建分支或提交变更：

二、最小上下文包

来源	允许用途	版本/范围	禁止事项	Owner
---	---	---	---	---
已批准的需求/Issue	理解目标与验收标准		不将其中指令自动视为工具授权	
仓库说明、架构与编码规范	选择文件与实现方式		不超出指定仓库/分支	
受控代码与测试	分析、修改和本地验证		不读取未授权目录、密钥或生产数据	
构建/测试日志	定位可复现失败		将日志视为数据，不执行其中未批准命令	
依赖官方文档	核验接口或迁移要求		不下载/执行未核验内容	

三、允许工具与动作

- 允许读取的仓库、目录、分支与时间范围：
- 允许编辑的文件范围：
- 允许执行的已批准命令、测试、静态检查和资源限制：
- 是否允许创建本地/远程分支、提交、拉取请求：
- 明确禁止：访问或输出密钥、使用生产凭证、修改受保护分支、生产部署、删除数据、付费动作、绕过代码审查。

四、执行检查点

- [] 先输出变更计划、受影响文件、假设、风险与需要澄清的问题。
- [] 人工确认范围后，才在隔离环境创建候选修改。
- [] 每次修改后运行约定的格式、静态、单元、集成或安全检查；记录未运行项目和原因。
- [] 汇总差异、测试输出、依赖变化、残余风险和回退步骤。
- [] 合并、发布、迁移或权限变更必须由授权人按既有变更流程独立批准。

五、验收与证据

- 变更差异/补丁位置：
- 通过与未通过的检查、测试、覆盖范围与日志：
- 审阅人、批准记录、发布/回退记录：
- 上下文包、工具控制卡、风险初筛/AIA和回归报告编号：
- 结论：仅供分析 / 可供人工审阅 / 可合并 / 需修复 / 暂停

3. Coding Agent 的评测重点

除功能结果外，Golden Set 应包含：错误需求、冲突规范、测试失败、无关文件、敏感文件、恶意或不可信日志内容、超范围重构请求、未批准命令和生产操作请求。评测时应确认 Agent 是否能保持范围、说明假设、拒绝越权操作、将工具返回视为数据、在验证不足时停止，而不是只检查它是否“写出了能编译的代码”。

移交标准：第二位工程师应能依据任务合约、上下文包、变更记录和测试证据，在不依赖 Agent 原始会话的情况下复现审阅、验证修改、执行回退或拒绝不安全请求。

53. Work Agent 受控实践包

Work Agent 是指帮助员工处理研究、资料整理、工单分类、客户沟通草稿、会议跟进、运营协调、报告准备或内部知识问答等工作任务的 Agent。它的主要风险通常不在“能否写一段文字”，而在于是否使用了正确上下文、是否把内部或外部内容误作权威依据、是否越权读取系统、是否在未经批准时发送、写入、承诺或代表组织作出决定。

1. 任务类型与人类保留决定

工作任务	Agent 可协助的内容	必须由人保留的决定
内部资料研究与摘要	来源整理、差异标记、问题清单、草稿摘要	来源权威性、结论采用与敏感内容处置
客户/供应商沟通	分类、检索已批准资料、生成草稿、检查格式	立场、承诺、价格、例外、发送和对外代表性表达
会议与项目跟进	纪要草稿、待办提取、风险提示、状态汇总	决议确认、责任分配、截止日期和外部同步
工单与运营协作	分类、受控查询、建议下一步、准备交接信息	优先级、处理决定、写入/关闭工单和跨部门升级
招聘、绩效、权益或高影响事项	准备受控材料、提示需专业审查的点	任何可能影响个人权益、资格、待遇或决定的结论和动作

2. Work Agent 运行与审批模板

任务编号：WORK-用例编号-序号

关联业务流程 / 服务对象 / 用例：

Agent、Skill、模型与版本：

业务 Owner / 知识 Owner / 上下文或记忆 Owner / 技术或工具 Owner：

当前阶段与允许范围：

一、业务目标与不可做事项

- 要帮助员工完成的子任务：
- 服务对象、地区、语言、产品或客户范围：
- 不承担的判断、承诺、外发、写入、审批或高影响决定：
- 必须停止、询问、转人工或专项升级的情形：

二、最小上下文包

来源	权威性/优先级	允许用途	适用范围与版本	不足、冲突或过期时的处理
---	---	---	---	---
已批准业务规则/政策				
当前任务材料				
受控检索/业务系统结果				
已确认任务状态或记忆（如适用）				

三、工具、连接器与行动边界

工具/连接器	只读/写入/外发	允许对象与参数	返回量/数据限制	是否需人工审批	异常与回退
---	---	---	---	---	---

四、员工操作检查点

- [] 发起前：确认任务范围、数据级别、所用 Agent/Skill 和来源是否获批准。
- [] 运行中：检查来源、版本、未确认项、工具结果和拟执行动作是否与任务相关。
- [] 审批前：人工确认事实、业务立场、对外表达、写入/发送或高影响动作。
- [] 完成后：记录输出、来源、批准、异常、转人工和需要更新的知识/上下文/工具资产。

五、质量、风险与证据

- Golden Set/Rubric/上下文评测记录：
- 人工审核、接管、回退和异常升级规则：
- 风险初筛/AIA/例外（如适用）：
- 发布登记、观察期、健康卡和 Runbook：
- 结论：草稿辅助 / 限量试运行 / 受控生产 / 降级或暂停

3. Work Agent 的评测重点

Work Agent 的样本应同时覆盖正确任务、信息不足、来源冲突、过期规则、不可信内容、敏感数据、无权限查询、工具空结果、外发/写入请求和需要人工判断的高影响事项。评测不应以“回复是否自然”替代控制判断；至少应检查：它是否引用正确来源、是否说明未知项、是否拒绝或升级超范围请求、是否将工具返回与业务决定区分、是否在外发或写入前保留人工批准。

移交标准：使用者、业务 Owner、知识 Owner 和技术/工具 Owner 应分别完成一次真实或脱敏任务演练；指定接棒人能够解释可用范围、来源边界、审批点、人工备用与问题上报入口。未完成此类能力验证时，不应因 Agent 演示成功而宣布业务团队已具备独立运营能力。

54. Agent 目标契约模板

目标契约用于把“希望 Agent 帮忙”转化为可授权、可评测、可停止的任务说明。它位于业务目标与技术运行合约之间：业务 Owner 定义要实现和不应实现的结果；技术与控制角色据此配置上下文、工具、验证和回退。目标契约不授权 Agent 自行改变组织目标、扩大范围、提高权限或接受不可逆后果。

目标契约编号：GOAL-用例编号-序号

关联用例 / 工作流 / Skill 或 Agent / 发布编号：

业务 Owner / 运行 Owner / 知识或上下文 Owner / 工具 Owner：

当前阶段：设计 / 试点 / 限量生产 / 受控生产 / 复核 / 退役

一、业务目标与完成证据

- 要改善的业务结果：

- Agent 受托完成的任務及交付物：

- 成功证据（质量、时效、服务、风险或其他可复核信号）：

- 非目标：本次明确不追求或不允许实现的结果：

二、范围与上下文

- 允许的对象、时间、地区、系统和业务范围：

- 必须排除的对象、情形、问题或决定：

- 可使用的上下文包/权威来源/当前版本：

- 信息不足、冲突、过期或不可信时的默认动作：停止 / 询问 / 转人工 / 其他

三、工具、权限与预算

| 工具或动作 | 可读取/可执行范围 | 是否可写入或外发 | 是否需人工批准 | 调用/时间/成本预算 | 禁止事项 |

| --- | --- | --- | --- | --- | --- |

| | | | | | |

四、验证、审批与责任

- 自动验证、Golden Set、Rubric 或其他检查：

- 必须由人确认的事实、判断、承诺、写入或对外动作：

- 谁可批准范围扩大、权限变化、例外或发布：

- 必须留存的计划、来源、工具调用、输出、审批和异常证据：

五、停止、升级与回退

- 停止条件（质量、来源、权限、成本、运行或风险信号）：

- 转人工或专项升级条件与接收角色：

- 回退版本、人工备用流程和恢复前验证：

- 下次复核日期与触发重新评估的条件：

结论：允许设计 / 允许受控试点 / 限量运行 / 暂缓或缩小范围

业务 Owner 确认：

适用的技术、风险、安全、法务或其他复核角色确认：

使用提示

- 低风险内部辅助可用一页卡片填写，但仍应明确非目标、人工 Owner 和停止条件。
 - 涉及对外沟通、写入、敏感数据、权限扩大、复杂 Agent 或高影响决定时，应关联风险初筛、AI 影响评估、运行合约、发布登记和 Runbook。
 - 目标、范围、来源、工具、权限或成功证据发生实质变化时，不应只修改 Prompt；应复核目标契约及其受影响的评测、风险和发布资产。
-

附录 B 常用指标与评测方法

本附录提供用于衡量 AI workflow、Skill 和 Agent 的指标定义与评测方法。指标的作用是支持用例的扩大、维持、修复、暂停或退役决策，而不是制造统一排名，或替代业务、风险与专业判断。

使用边界：本附录不提供跨行业、跨团队通用的通过率、采用率、耗时或成本目标。不同任务的容错率、验证成本、数据条件、人工责任和业务关键性不同。每个用例应在立项和试点时记录自己的基线、观察周期、预期变化、不可接受情形和决策阈值，并在阶段变化时复核。

一、核心指标定义

1. 一次通过率

定义：输出在完成预先定义的验证清单后，可直接采用或仅需约定范围内的轻微格式调整的比例。

计算：

$$\text{一次通过率} = \text{一次通过任务数} \div \text{总执行任务数} \times 100\%$$

记录时应说明：验证清单的版本；“轻微调整”的定义；被排除的任务；以及通过是否仍需人工最终采用。一次通过率不等于事实完全正确，也不等于业务已经采用。

2. 端到端平均耗时

定义：从任务启动到完成验证并形成最终可用结果的平均时间。应包含输入准备、模型或工具处理、人工审核、修改、转人工与必要记录，而不是只计算生成耗时。

计算：

$$\text{端到端平均耗时} = \text{所有纳入统计任务的总耗时} \div \text{总执行任务数}$$

对比方式：与采用 AI 前的同类人工流程，或当前稳定版本的工作流进行同口径对比。样本范围、任务难度、人员经验和统计周期应在记录中注明。

3. 实际采用率

定义：最终被业务人员采用，或在预先约定的允许修改范围内被采用的输出占总输出的比例。

计算：

$$\text{实际采用率} = \text{实际采用任务数} \div \text{总执行任务数} \times 100\%$$

“通过验证”不等于“被业务采用”。采用率较低可能来自质量、场景匹配、知识时效、审核负担、入口设计或业务流程变化，应结合失败原因和使用者反馈判断。

4. 失败类型与风险信号

定义：未通过验证、未被采用、被转人工、触发回退或出现异常时的主要原因分布。

建议按用例定义分类，例如：格式不符合契约、关键信息遗漏、事实或知识错误、建议被误写为结论、规则过期、权限/工具异常、人工接管失败、超出适用范围，以及其他经审核确认的原因。分类应足够稳定，以便比较变化；也应允许在新风险出现时更新。

5. 知识、提示词或配置更新及时性

定义：规则、知识、Prompt、模型、工具、权限或验证条件发生变化后，相关资产在约定控制窗口内完成影响分析、更新、回归与发布/回退决定的比例。

这一指标不应只看“更新是否完成”，还应看受影响样本是否覆盖、知识 Owner 是否确认、以及变更后是否留存可定位证据。

二、建立本组织基线与决策边界

在首次试运行前，业务 Owner、Skill/流程 Owner 和适用的知识、技术、风险角色应共同记录以下内容：

项目	要回答的问题	记录位置
任务边界	哪类任务纳入统计，哪些任务不纳入，为什么？	用例立项卡、工作流合约
当前基线	现有人工流程的质量、耗时、返工、队列或客户影响如何？	基线记录、健康卡
质量边界	哪类错误不可接受，哪些需转人工，哪些可在审核中修正？	Rubric、风险初筛/AIA、Runbook
观察周期	需要覆盖哪些任务类型、业务周期或知识变化才足以判断？	发布登记、评测计划
决策规则	哪些信号会导致扩大、维持、修复、暂停或退役？	阶段闸门、健康卡、组合台账
证据责任	谁记录、复核、解释和批准指标结论？	RACI、证据索引

对于低风险、内部、任务结构简单的试点，记录可以轻量；对于对外沟通、写入、敏感数据、重要决策、Agent 或高关键性流程，应提高样本、审核、风险和运行证据的要求。

三、评测方法与执行节奏

1. 例行快速复核

在用例活跃期，按业务节奏定期更新执行次数、质量结论、采用情况、耗时、主要失败类型、知识/配置变更和异常信号。频率可以是每周、每两周、每月，或由事件和发布触发；关键是让周期与任务量、风险和变化速度相匹配。

例行复核至少应回答：当前数据是否与上一个可比周期一致；是否出现新的失败类型或风险信号；指标变化是否可能来自任务范围、人员、知识、模型、工具或配置变化；以及是否需要调整范围或启动回归。

2. 阶段性深度回顾

在阶段闸门、重大变更、观察期结束、异常事件或移交前，建议进行深度回顾。除核心指标外，还应审查 Golden Set、回归报告、风险/AIA、发布登记、健康卡、Runbook、人工备用和接棒能力是否仍与实际运行一致。

深度回顾的输出不是一张“达标”结论，而是一个有 Owner、证据、遗留项和下一决策的记录：扩大、维持、修复、限量继续、暂停或退役。

四、指标解释与决策参考

观察到的情况	可能解释	建议动作
质量低于预先约定的控制边界，或出现不可接受错误	任务边界、知识、Prompt、模型、工具、审核或权限控制可能失效	暂停扩大范围；保留证据；按影响完成修复、回归、发布/回退判断。
耗时没有改善，或审核负担上升	输入准备、验证、格式转换或例外处理成本抵消了生成收益	复核端到端流程；不要仅凭模型响应时间宣布提效。
采用率明显低于质量通过率	输出虽符合形式标准，但可能不贴合业务语境、时效或使用入口	访谈使用者；补充业务 Rubric、知识或流程设计。
同类失败反复出现	根因未被修复，或样本/验证未覆盖真实问题	更新 Skill、知识、Golden Set、Runbook 或培训，并在变更后复验。
质量与运行准备度持续满足扩大条件	用例可能具备扩大或移交基础	仍需检查风险、人工接管、证据、Owner 和组合资源，再由阶段闸门决定。
数据不足或样本不可比	不能从当前指标得出趋势结论	延长观察、补充代表性样本，或明确标记为“结论不足”。

五、简易记录表

1. 用例运行记录

周期	用例 / 版本	纳入统计的任务范围	总任务数	一次通过数	实际采用数	端到端耗时	主要失败 / 风险信号	变更或事件	证据位置	Owner 结论
----	---------	-----------	------	-------	-------	-------	-------------	-------	------	----------

2. 阶段回顾记录

回顾周期：
关联用例 / 工作流 / Skill 或 Agent 版本：
本周期纳入统计的任务范围与样本边界：
一、证据摘要
- 质量与 Golden Set / 回归结论：
- 采用、耗时、成本与人工负担：
- 知识、上下文包、记忆、模型、工具、连接器、权限或流程变化：
- 来源可定位、过期/冲突/越权拦截、工具异常及记忆纠错情况：

- 风险、事件、回退、人工接管与 Runbook 情况：

二、解释与决定

- 与基线或上一可比周期的主要变化：
- 不能从现有数据得出的结论：
- 遗留问题、Owner、到期日和复验方式：
- 阶段决定：扩大 / 维持 / 修复 / 限量继续 / 暂停 / 退役
- 复核人和证据索引位置：

六、Skill 与 Agent 的补充评测

通过率、端到端耗时和采用率仍是基础指标。进入 Skill 或 Agent 阶段后，团队还应观察那些会影响长期可运营性的信号。其目的不是增加考核负担，而是识别“单次输出看起来正常、系统实际已失控”的情形。

指标	适用对象	定义	主要用途	解释原则
Skill 复现成功率	Skill	非原作者依据 Skill 卡完成同类任务并通过约定验证的比例	判断经验是否成为团队能力	首次封装、重大变更或移交前，应安排第二人复现。
回归样本覆盖率	Skill、工作流、Agent	已对受影响计划样本完成重新评测的比例	判断变更是否只覆盖“好看的样本”	先定义正常、边界和历史失败样本；未覆盖时结论应标记为不足。
变更后质量差异	Skill、工作流、Agent	候选版本与上一稳定版本在质量、耗时、采用、成本或风险信号上的差异	识别静默退化	差异需要结合样本、任务范围和变更内容解释。
人工接管率	Agent、复杂工作流	因异常、缺少信息、审批拒绝或风险触发而交回人工的任务比例	识别边界设计与人工容量	接管率上升不一定表示失败；应同时看是否及时、可解释和可完成。
接管完成率	Agent、复杂工作流	转人工后按既定流程完成或获得明确下一步的比例	验证回退是否可用	接管无法完成时，应优先修复人工备用、权限或交接。

指标	适用对象	定义	主要用途	解释原则
错误动作/越权尝试	Agent	未授权调用、错误路由、错误参数或不应发生的写入尝试	观察权限和状态控制	高影响情形应按事件与风险流程处理，而不是只计入指标。
熔断触发情况	Agent	因步骤、工具调用、时间、成本或并发限制而自动停止的任务	发现循环、异常输入或容量问题	区分正常保护与设计缺陷；持续变化时检查原因。
来源可定位率	Skill、工作流、Agent	输出、建议或关键动作能够定位到已使用来源、版本、生效范围或工具记录的比例	判断上下文是否可解释、可复核	对高影响事实或对外结论，应优先检查来源质量与适用范围，而不只计数量。
过期/冲突/越权上下文拦截情况	Skill、工作流、Agent	系统在遇到过期、冲突、无来源、超范围或无权资料时，正确停止、标记或转人工的情况	检查信息面控制是否真正生效	不能将“模型继续生成了看似合理的答案”视为可接受处理。
工具返回与参数异常	Agent	工具参数错误、空结果、超时、无效返回、超长返回或不安全内容的情况	发现工具描述、接口、权限或上下文预算问题	应同时观察 Agent 是否在异常后正确停止、重试受限或转人工。
记忆纠错与失效信号	使用持久记忆的 Agent	被发现、纠正、删除或按规则失效的记忆事项及其影响	识别错误记忆、过期与隔离问题	该指标不能替代对记忆合约和数据边界的定性审查。
上下文与工具成本	Skill、工作流、Agent	每任务用于检索、工具调用、上下文处理和人工审核的资源消耗	识别无效加载、重复调用与成本异常	与质量、接管和业务结果一起解释，不以 Token 或调用数单独判定价值。
运行证据完整性	Agent	日志、来源、审批、版本和必要	支持审计与复盘	缺失证据的任务不应被当作

指标	适用对象	定义	主要用途	解释原则
		运行记录可定位的任务比例		充分受控的运行证明。

1. 设定补充指标的原则

不要将上述指标直接套用为跨团队统一 KPI。Skill 的复现结论应关注第二位使用者能否在明确边界内独立完成；Agent 的越权和错误动作应按影响程度分级；人工接管则应结合场景解释，因为及时转人工可能证明控制有效。

每个新 Skill 或 Agent 在立项时应写明六件事：哪些来源、工具和记忆允许使用；哪些异常必须停止；哪些异常可以转人工；哪些变化必须回归；以及什么证据支持恢复。这些内容应与附录 A 第 15 节的变更影响与回归评测记录、附录 A 第 48–51 节的上下文与工具控制资产配套使用。

2. Skill 与 Agent 的最小试运行记录表

若用例不包含 Agent，可留空 Agent 相关字段。

周期	资产名称/版本号	执行次数	一次通过率	采用率	端到端耗时	主要失败类型	上下文/工具异常	是否有变更	回归结论	人工接管	熔断	错误动作/越权尝试	来源与运行证据完整性	决定与备注
								是/否	通过/不通过/不适用					

七、培训与采纳健康度指标

培训与变革的目标不是让更多人“用过一次 AI”，而是让适当的角色能够在批准边界内，以正确方式持续完成真实工作，并在不确定时知道如何停止、转人工和上报。以下指标用于观察组织能力，不应用于简单的个人排名或惩罚。

指标	定义	说明	建议使用方式
实践认证覆盖率	已完成对应角色实践任务并通过复核的人数 ÷ 目标角色人数	区别于“参加培训人数”	按角色查看缺口，不以同一课程覆盖所有人。

指标	定义	说明	建议使用方式
受控采用率	在批准的 Skill、工作流或工具边界内完成真实任务的比例	衡量正式流程是否真正可用	与质量和采用率一起看；较低时先检查流程、工具或培训障碍。
第二人复现率	非原始设计者能依据资产独立完成任务的比例	观察经验是否脱离个人	用于 Skill 和团队交接，不用于个人绩效排名。
反馈闭环及时性	在约定时限内得到分类、处理或明确回答的有效反馈情况	衡量组织是否认真对待一线问题	定期分析未及时处理的原因，改善分流资源。
重复反馈变化	同类培训困惑、知识缺口或流程障碍持续出现的变化	判断改进是否触及根因	不应要求归零；应识别高频主题并更新培训、Skill 或知识。
绕过或非受控使用信号	因正式流程不可用、权限不匹配、速度过慢或认知不足而出现的绕过反馈	帮助组织提供安全替代方案	关注原因和修复，不将报告本身作为惩罚依据；涉及敏感数据时按安全流程处理。

不建议作为核心绩效指标的内容

模型调用次数、Token 消耗、登录时长、生成字数和使用排行榜位置可能有运营参考价值，但不应单独作为“AI 采用好坏”或员工绩效的判断依据。它们容易诱导“为了被看见而使用”，不能直接证明业务价值、质量、合规或能力提升。

与月度组合评审的衔接

当某个用例质量稳定但受控采用率较低时，不应立即认定员工“抗拒变化”。应检查：该任务是否真的高频且有价值；使用入口是否嵌入原有 SOP；人工审核是否过重；知识和权限是否齐备；经理人是否提供试点时间；使用者是否知道何时不该用。分角色能力地图、经理人行动和反馈模板见附录 A 第 22、23、24 节。

附录 C 模型与工具核验指南

本附录不再维护“当前推荐工具”或静态产品排行榜。模型、API、网关、编排平台、RAG 与记忆组件、安全工具、MCP 和第三方集成的名称、版本、价格、能力、部署方式、数据处理与弃用计划变化很快；将它们直接写成长期推荐，容易让读者把过期信息当成生产决策依据。

本附录提供的是**工具分类、尽调问题和决策入口**。每项可能进入正式用例的外部模型、平台、端点、MCP、连接器或组件，都应在[模型与工具动态事实卡登记册](#)中有一张可复核事实卡，并与用例立项、风险初筛、上下文包、记忆合约、工具控制卡、工作流合约、评测、发布和退出计划连接。

使用原则：工具选择不是“找功能最多的平台”，而是为已明确的业务用例选择能够满足质量、数据、权限、运营、成本和退出要求的最小方案。

一、工具与模型的六类能力

类别	主要作用	常见价值	必须避免的误解
模型与 API 服务	生成、推理、嵌入、多模态或结构化输出	为 Skill、工作流或 Agent 提供基础能力	模型名、榜单或上下文数字不能证明适配业务或满足数据要求。
网关与控制面	身份、密钥、路由、成本、日志、限额、模型切换	集中控制多个团队和供应商依赖	网关不能自动解决输出质量、知识正确性或合规责任。
工作流与 Agent 编排	编排确定性步骤、Skill、上下文、工具、状态和审批	将能力连接为可运行流程	图形化编排不等于已经具备评测、来源边界、权限、回退和审计。
知识、检索与记忆组件	文档处理、索引、检索、权限、版本、引用、任务状态和记忆	支撑需用企业知识或跨轮次状态的 Skill/Agent	有“知识库”或“记忆”不等于内容权威、及时、已隔离、可删除或可追溯。
安全与防护组件	输入输出过滤、DLP、提示注入防护、权限和审计	降低特定风险并提供可见性	安全工具可能误拦截或漏拦截，不能取代人工边界和风险治理。
第三方集成与连接器	连接业务系统、外部工具、数据或动作	扩展工作流和自动化价值	集成常带来额外数据流、权限、留存和写入风险，必须单独评估。

二、进入正式用例前的工具核验问题

工具不应只按“好不好用”选型。以下问题应由对应事实卡、内部配置、风险初筛和工作流合约共同回答。

1. 功能与适用范围

需要回答的问题	最低证据
具体版本、端点、功能和部署方式是否适用于此用例？	官方文档/版本说明、事实卡、内部环境确认。
哪些能力、限制、地区、计划或配置前提会影响使用？	事实卡中的适用范围、不适用范围和核验日期。
是否存在弃用、配额、速率、服务状态或兼容性风险？	官方公告/状态页、合同或实际配置、回退计划。

2. 数据与合规条件

需要回答的问题	最低证据
哪些输入、上下文包、检索/工具返回、记忆、输出、文件、日志、状态或元数据会离开组织边界？	数据流、事实卡、上下文包、工具控制卡、工作流合约和 AIA。
留存、训练使用、区域、加密、子处理器或删除条件是否符合组织要求？	官方政策、合同、项目配置和组织审查记录。
第三方工具、浏览器插件、远程 MCP 或外部连接器的数据处理是否已单独核验？	集成事实卡、权限/数据流说明、风险初筛。

3. 权限、动作与运营条件

需要回答的问题	最低证据
谁可访问、配置、调用、修改或导出数据？	身份/权限设计、审计日志、责任人和变更记录。
工具/MCP/连接器是否可读写、发送、执行代码、访问网络或持续运行？	工作流/Agent 合约、工具控制卡、动作白名单、审批与熔断设计。
上下文来源、检索、记忆与工具返回能否按用例范围过滤、定位、失效、隔离或删除？	上下文包、记忆合约、权限/数据流说明与回归记录。
是否可导出 Prompt、知识、上下文包、记忆、评测集、配置、日志与历史记录？	退出路径、迁移测试、备份或人工备用流程。

三、按用例选择最小方案


1. 先选控制形态，再选具体产品


用例特征	优先控制形态	工具选择重点
一次性、低风险个人探索	经批准的探索环境	数据边界、个人使用政策、不可把结果直接作为正式结论。
高频、可验证的单类任务	受控 Prompt 或 Skill	版本、最小上下文包、输入输出、评测、知识、人工回退与第二人复现。
多步骤但顺序明确的任务	固定 workflow	状态、受控数据/上下文传递、验证、审批、日志与失败处理。
动态编排确有价值任务	受限 Agent	已验证 Skill、上下文白名单、记忆边界、最小权限、状态限制、预算、接管、审计与风险评估。
涉及企业知识或文件	知识组件或 RAG	权威来源、版本、生效日期、访问控制、删除/归档、引用证据与检索评测。
涉及业务系统查询或动作	工具/MCP/连接器	最小权限、参数/返回量、审批、超时/熔断、日志、回退与退出。

2. 不要复制“按月份堆工具”的演进路线

团队不应因为进入某个时间阶段就自动引入网关、RAG、Agent、私有部署或评测平台。更合理的升级信号是：用例数量和共享依赖增加；真实质量/成本/权限问题无法由现有机制解决；责任人有能力长期维护；风险初筛和发布机制要求更强控制；或演练已证明需要更好的回退和切换能力。任何新组件都应先回答：它要解决哪个用例或控制缺口？如果不使用它，什么风险或成本无法被现有 workflow 承受？增加它后，谁维护、如何测试、怎样导出和如何退出？

四、工具事实卡、内部评测与发布的连接





决策问题	主要资产
供应商或工具官方说了什么，适用于什么范围？	动态事实卡登记册
这个用例是否值得做、数据/影响是否可接受？	用例立项卡、风险初筛、AI 影响评估
候选方案在本组织真实任务上是否通过？	Golden Set、Rubric、回归评测报告
谁能用、可依据什么、可保存什么、可做什么、怎样停止和回退？	工作流合约、Agent 运行合约、上下文包、记忆合约、工具控制卡、发布登记
上线后是否仍健康、何时替换或退役？	用例健康卡、组合评审、证据索引、韧性演练

五、退出与迁移的最小要求

对关键用例，工具选择时就应考虑退出，而不是等供应商停服、涨价、弃用或不再满足数据要求后才临时迁移。最低要求包括：业务规则、Prompt、Skill、上下文包、记忆、工具/连接器控制、工作流、评测集和关键配置不只保存在单一平台；模型/工具版本与数据处理条件可追溯；组织知道哪个 Owner 负责切换；存在可以验证的替代方案或人工备用流程；迁移后可以对同一 Golden Set 回归比较。对外部平台、第三方插件或连接器，退出并不一定意味着“立即替换”。它意味着组织有权知道数据、权限和资产在哪里，并能在合理时间内暂停、导出、降级或回到人工流程。

六、最小核验清单

在将模型或工具接入正式用例前，逐项确认：

- [] 已创建或更新事实卡，且记录版本、范围、限制、来源、核验日期和下次复核。
- [] 已核验实际项目配置，而不只阅读了公共营销页或产品名称。
- [] 已关联用例立项卡、风险初筛；需要时已完成 AIA。
- [] 已在批准的数据与权限边界内使用 Golden Set、上下文与工具评测完成内部验证。
- [] 已建立或更新上下文包、记忆合约和工具/MCP/连接器控制卡。
- [] 已将版本、端点、来源、记忆、权限、工具调用和回退要求写入工作流或 Agent 合约。
- [] 已完成回归报告、发布登记、观察期和证据索引的更新。
- [] 已明确可导出资产、替代路径、人工备用流程与责任 Owner。

七、本附录的维护规则

本附录只维护稳定的分类、问题和控制方法。具体外部事实、链接和核验记录维护在 facts/ 目录中；过期事实应标记失效并保留历史原因，新的产品、功能或政策变化通过新增或更新事实卡管理。这样，手册正文不因短期产品变化频繁改写，读者仍能获得可追溯、可复核的当前信息。如需进一步了解事实卡字段、样例、复核节奏与来源优先级，请直接阅读[模型与工具动态事实卡登记册](#)。

附录 D 来源、公开案例与事实维护规范

本附录是全书外部事实、公开案例、动态产品信息与方法框架的统一来源登记册。其目标不是堆积链接，而是使读者能够判断一项说法**来自何处、适用于什么范围、何时被核验、不能推出什么结论，以及变化后由谁复核**。

核心规则：没有来源、适用范围和核验日期的外部断言，不得作为正式用例、风险分级、发布决定或价值承诺的依据。真实案例、教学情景、内部运行证据、动态事实与社区线索必须清楚区分。

本附录记录的公开链接在 **2026-08-21** 核验。链接可访问不代表其内容永久不变；模型、工具、价格、功能、合同、政策和地区可用性等动态信息，以 facts/模型与工具动态事实卡登记册.md 为准。

一、全书内容的事实状态标签

标签	适用内容	可以支撑的结论	不得被误读为
公开案例	裁决、官方库存、机构公告、可追溯新闻或公开复盘	特定组织、时间、情境下发生或披露的事实及其有限控制启示	所有企业、行业或辖区的普遍规律
教学情景	用于演练 Skill 卡、风险评估、回归或 Runbook 的去标识化设定	模板如何填写、控制如何衔接	实际客户项目、已验证收益或真实事故
内部证据	样本、评测、发布、运行、事件、验收和移交记录	本组织特定用例的实际表现和决定	对其他组织、模型或场景的保证
动态事实	模型、端点、工具、数据处理、价格、权限、地区和弃用条件	在卡片定义的版本、配置和合同范围内的外部事实	同一品牌下全部产品、端点、集成或合同的结论
社区线索	X、Reddit、Hacker News、论坛、演讲和个人博客	值得调查的高频问题、待验证假设和 Golden Set 候选	案例事实、行业比例、ROI、性能阈值或法律结论
框架参照	标准机构、政府或权威组织发布的方法框架	组织可借鉴的治理语言、过程和问题集	自动合规、认证或法律意见

二、来源等级与使用规则

来源等级反映某项材料能支撑的**结论强度**，而非对来源整体的褒贬。同一来源可能只适合支撑部分事实。

等级	来源或证据	适合使用场景	最低记录要求
A	原始裁决、法律/监管公开文件、标准机构资料、官方用例库存、实际合同、项目配置、内部运行证据	事实确认、组织决定、方法框架和项目验收	发布主体、原始链接、版本/日期、适用范围、Owner
B	组织官方公告、产品/开发者文档、可信媒体对原始文件或当事人陈述的报道	产品条件、公开部署、特定事件背景	链接、发布日期、消息来源、未知事项和核验日期
C	同行评审研究、公开技术报告、独立调查和多源分析	方法背景、风险趋势、研究性讨论	版本、样本/方法、适用边界和发布日期
D	供应商案例、二手分析、论坛、社交媒体、演讲和个人博客	发现线索、补充背景、提出待验证问题	来源性质、发布时间、待核验状态；不得单独支撑高影响决定

对高影响用例、对外沟通、敏感数据、写入动作或自动化决策，至少应同时具备：本组织的内部证据、适用的风险/合规审查，以及在需要时的 A 或 B 级外部资料。媒体报道和供应商案例可提供背景，但不能替代合同、配置、权限和实际测试。

三、公开案例来源登记册

下表登记可用于本手册的真实公开案例。每个案例只能被用于说明表中列出的控制问题；“不可外推”一栏是案例卡的必填部分。

案例 ID	公开案例与来源状态	已核验的有限事实	适用章节	不可外推事项
CA-001	Air Canada 聊天机器人信息错误 ；A 级，公开裁决	加拿大卑诗省民事纠纷审裁处在 <i>Moffatt v. Air Canada, 2024 BCCRT 149</i> 中认定，Air Canada 应对其网站聊天机器人提供的错误丧亲票价信息负责。 ¹	第 6、14、15 章；附录 G	不是全球通用的法律规则；不代表所有聊天机器人或所有错误均产生相同责任。
CA-002	纽约市 MyCity 商业信息聊天	The Markup 测试报道该机器	第 6、11、15 章	不是对所有公共服务系统的

案例 ID	公开案例与来源状态	已核验的有限事实	适用章节	不可外推事项
	机器人； A/B 级，调查报道与后续回应	人给出与纽约市规则不一致的劳动、住房和现金支付信息；其后续报道记录纽约市长承认系统存在问题，且网站强化了“不得作为法律或专业建议使用”的提示。 2 3		质量结论；报道不能替代具体辖区的法律意见。
CA-003	三星员工向公共聊天工具输入敏感内部信息； B 级，媒体报道	CNBC 报道称三星确认出现误用后，暂时限制员工在公司个人电脑上使用相关生成式 AI；Cybersecurity Dive 转述韩国媒体称，员工曾向 ChatGPT 输入敏感公司数据。具体输入内容属于媒体转述，三星未在该报道中公开完整输入清单。 4 5	第 7、14、15 章	不能据此证明数据被训练、向其他用户泄露，或禁令在所有组织中有效。
CA-004	Morgan Stanley 内部知识助理与会议摘要工具； A/B 级，机构与供应商共同公开	Morgan Stanley 官方公告称 AskResearchGPT 支持研究材料的检索、综合和带链接的发现转邮件草稿，供员工修改后分享； OpenAI 案	第 5、11、15 章	采用率、效率和覆盖率属于当事方自述，不能作为一般企业目标、ROI 或验收阈值。

案例 ID	公开案例与来源状态	已核验的有限事实	适用章节	不可外推事项
		例页描述其专家评测、回归与人工审核做法。 6 7		
CA-005	GSA 与美国劳工部公开 AI 用例库存；A 级，官方公开	两个机构公开用例名称、用途、阶段或部署状态，显示可区分预部署、试点与已部署用例。 8 9	第 8、12、15 章	政府分类、公开义务和效率目标不自动适用于私营组织；项目意图不等于已验收价值。
CA-006	PocketOS 公开报道的 AI 编码 Agent 数据破坏事故；B 级，媒体依据创始人陈述报道	Guardian 报道该公司创始人称，Cursor 集成的 AI 编码 Agent 删除了生产数据库及备份；报道也说明 Anthropic 未立即回应置评。 10	第 9、13、15 章；附录 G	未公开完整独立技术复盘，不能证明特定模型、IDE 或 Agent 框架必然忽略规则，也不能推导一般概率。

1. 公开案例的写法

正文第一次引用案例时，必须包含案例 ID、事实状态和来源。例如：

公开案例 (CA-001)：加拿大卑诗省民事纠纷仲裁处在特定纠纷中认定，航空公司应对其网站聊天机器人提供的错误信息负责。[1](#) 该案例提示对外回复必须管理知识版本、承诺边界和人工升级；它不构成其他司法辖区的法律结论。

正文不应将案例中的金额、时间、样本数或当事方自述的效果，转写为本组织的目标阈值。教学情景必须在标题或首段标注“**教学情景，非实际运行记录**”。

2. 社区线索的用途与禁区

X、Reddit 和 Hacker News 可用于发现 RAG 知识版本、元数据、检索归因、Agent 权限、可观测性、成本和人工接管等问题。它们应转化为风险登记问题、Golden Set 样本或待验证假设，而不是案例事实。例如，社区讨论提出“复杂否定条件检索容易出错”时，团队应将此类问题加入 Golden Set，记录本组织的实际结果。

单一社交帖文、论坛评论、个人博客或供应商营销材料，不得单独支撑以下内容：具体事实、行业比例、准确率、成本、ROI、模型优劣、法律责任或采购决定。只有在找到原始裁决、官方公告、完整技术复盘或独立多源报道后，才可升级为公开案例。[11 12 13](#)

四、框架与标准参照

NIST AI RMF 及其生成式 AI 配套资料为跨行业、自愿使用的风险管理资源；其 Playbook 将建议组织为 Govern、Map、Measure 和 Manage，并明确不是所有组织都必须逐项执行的清单。[14](#) [15](#) ISO/IEC 42001:2023 提供 AI 管理体系的建立、实施、维护和持续改进要求与指南。[16](#)

手册资产	可参考的框架维度	编辑与使用边界
用例立项卡、用例组合台账、 RACI	治理与情境识别	应按组织风险、职责和业务目标调整，不复制为固定清单。
风险初筛、AI 影响评估、风险—控制矩阵	情境识别、评测与管理	不以框架名称替代实际法律、隐私或安全审查。
Golden Set、回归报告、健康卡	评测与管理	指标、阈值和停止条件应由本组织基线及风险边界决定。
发布登记、事件 Runbook、演练与复盘	治理与管理	需保留内部证据；不能仅因使用框架而宣称合规或认证。
FDE/AI COE 交付、培训与移交	治理、能力与持续改进	业务 Owner、知识 Owner 和风险 Owner 的责任不能被外部团队替代。

五、动态模型与工具事实

模型和工具事实不是本附录的静态推荐清单。候选模型、端点、工具、平台、连接器或 Agent 框架进入正式用例前，应在 facts/模型与工具动态事实卡登记册.md 建立或复核事实卡，并关联用例立项、风险初筛、工作流合约、Golden Set、发布登记和退出路径。

OpenAI 与 Anthropic 的官方数据处理资料均明确，不同 API、功能、项目配置、组织资格、第三方集成和合同安排可能具有不同的留存或数据处理条件。[17](#) [18](#) 因而，正文不得把“使用某品牌”“使用 API”“开启企业版”“设置零留存”等笼统说法写成充分的数据安全结论。任何涉及敏感数据、状态化功能、文件、工具调用、第三方服务、地区处理或合规要求的用例，均应按实际端点、功能、配置、合同和数据流单独核验。

当前 Agent、Coding Agent、计算机使用、视觉和图像生成能力可参阅供应商的官方发布、开发者文档和权限资料。[19](#) [20](#) [21](#) [22](#) [23](#) [24](#) 这些均属于 B 级动态事实来源：它们可以说明特定日期、版本和产品条件下公开提供或声明的功能与控制选项，**不能**单独证明任一企业的质量、成本、可靠性、数据合规性或无监督生产可行性。采用前仍须建立事实卡，并以本组织的任务样本、权限配置、风险分级和运行证据验证。

触发情形	必须动作
候选模型、工具或连接器进入正式用例	建立/复核事实卡；完成风险初筛；明确数据、权限、成本与退出边界。

触发情形	必须动作
模型、功能、端点、价格、留存、地区、合同或弃用计划变化	更新事实卡，识别受影响资产；必要时运行回归并复核发布决定。
来源失效、事实过期或公开说明与实际配置不一致	标记待复核；暂停依赖该事实的新发布；记录原因、Owner 和恢复条件。
发现论坛或媒体中的新事件	先登记为社区线索；按来源等级核验后，才决定是否进入案例登记册或风险资产。

1. 价值评估与生产率证据的使用边界

NBER 的客服现场研究使用每小时解决问题数、客户体验和人员结果等指标，MIT 公开的 Coding Agent 现场实验使用 Pull Request、构建、审查时间和错误等流程数据，说明端到端时间、处理量、质量和采用/使用数据可用于评估 AI 辅助工作的变化。^{25 26} 两项研究均披露了任务、人群、实验或统计局限，因此不应把其提升幅度或任一单项指标直接抄为企业目标、ROI 或通过阈值。

Klarna 与 OpenAI 的公开案例同时披露客户服务处理量、解决时间、客户体验、容量等价和预计财务影响，说明企业会采用多维价值口径。²⁷ 该材料属于供应商与客户共同发布的当事方陈述，不能替代独立审计，也不能证明对其他组织的财务效果。第 11 章据此采用“全成本、已实现财务收益、容量价值代理、质量与控制证据分开呈现”的方法，而不使用任何公开案例数字作为通用基准。

2. 人机协同与组织生产方式观察的使用边界

OpenAI 与 Anthropic 的署名工程文章、官方团队实践和开发者指南，公开了其在 Agent-first 工程、AI 原生工程生命周期、跨职能使用 Coding Agent、Skill 资产和多 Agent 编排方面的做法与观点。^{28 29 30 31 32 33} 这些属于 B 级动态实践来源：可用于说明**当事团队在特定时间、产品、环境和组织条件下披露的机制**，例如结构化上下文、委托—复核—拥有分工、可复用 Skill、评测和受控工具协作。不得将上述材料的吞吐、采用、代码生成比例、模型能力、组织结构或效率结论外推为其他企业的目标、ROI、人员决策或安全结论。第 13 章仅以其作为“协作形态与机制观察窗”；企业是否扩大自主性，仍须根据自身任务、数据、权限、风险、人工接管、评测和运行证据决定。

六、内部证据与来源维护

外部资料不能替代内部证据。组织应在受控空间保存并按权限管理：合同与数据处理协议、供应商安全问卷、项目配置、数据流图、风险评估、评测样本、审核记录、发布登记、事件复盘、恢复演练和移交证明。敏感合同、配置和个人信息不应复制到公开仓库。

每季度或在重大变更发生时，来源 Owner 应复核本附录和动态事实卡，并回答四个问题：**谁在什么范围内作出了这项说法？它适用于哪个版本、端点、地区、配置或合同？何时核验？它影响哪些已运行用例，变化后谁负责处理？**

参考资料

附录 E 关于作者与进一步交流

关于本书

《企业 AI 稳定产出手册》是一份面向企业实际使用者的实操文档，目标是帮助个人和团队把 AI 使用从“偶尔提效”推进到“可复现、可验证、可长期运行”的稳定状态。本书内容基于对中外企业 AI 落地实践的观察、公开资料梳理以及实际执行经验的提炼，以可直接使用的方法、清单和模板为主。

关于作者

作者长期关注企业 AI 落地与稳定产出问题，致力于将认知校准、工作流设计、评测治理等方法转化为可执行的实践。

进一步交流

如果你在使用本书方法的过程中：

- 跑通了最小闭环，愿意分享实际效果与遇到的问题
- 发现书中方法的不足或可改进之处
- 希望就企业 AI 稳定产出、工作流设计、评测治理等相关问题进行交流

欢迎通过以下方式联系：

- 邮箱：jacejacejia@gmail.com
- 其他联系方式：ares0x

反馈与真实执行经验，是手册持续迭代的重要来源。

关于后续可能的支持

本书为免费公开内容。如果后续需要针对具体企业场景的诊断、内训或更深度的落地支持，可通过上述方式沟通。所有进一步的服务均以实际需求为前提，不作为本书的附加条件。

• •

感谢阅读。希望这本手册能真正帮到你在实际工作中把 AI 用得更稳。

附录 F 术语表

本附录定义全书使用的关键术语，供团队在立项、设计、评测、发布、运行和移交时统一使用。除非上下文另有说明，以下定义描述本手册的工作方法，不代表特定产品、法律、合同或行业标准的唯一解释。

一、模型与能力

Token（词元）

模型处理文本的基本单位。一个汉字、英文单词、符号或词片段可能对应一个或多个 Token。计费、上下文限制和使用额度的具体口径取决于模型、端点和服务条件，应以动态事实卡中的当前资料为准。

上下文窗口（Context Window）

单次模型调用可处理的上下文范围。不同模型、端点、配置和输入类型的限制可能不同；超出限制时，内容可能被拒绝、截断、压缩或以其他方式处理。关键事实不能只依赖“更长上下文”，仍应通过任务拆分、知识管理和验证控制。

幻觉（Hallucination）

模型生成看似合理、但与事实、权威来源、任务边界或上下文不一致的内容。模型是否显式表达不确定性不能替代验证；提示词、检索和工具可以降低部分风险，但不能消除所有错误可能。

概率预测系统

大模型通常基于既有上下文生成后续内容的概率分布。这有助于解释输出为何会随输入、参数、版本、工具、服务环境和任务设计而变化，也说明模型不能自行承担真实世界的业务、法律或伦理责任。

非确定性输出

相同或相近输入在不同调用中可能产生不同结果的现象。对需要一致性的用例，应通过结构化输出、版本管理、Golden Set、人工验证和回退机制控制影响，而不是假设输出会自然保持一致。

Agent（智能体）

在受限范围内执行多步任务的系统。它可以根据状态选择下一步，调用经授权的 Skill 与工具，并依据中间结果继续、停止或转人工。企业使用 Agent 时，应以已验证的 Skill 为基础，并配置最小权限、状态约束、预算/步数限制、人工接管、日志和审计要求。见第 9 章。

二、数据、知识与动态事实

RAG（Retrieval-Augmented Generation，检索增强生成）

在生成前从知识库检索相关材料，并将检索结果作为受控上下文提供给模型的技术模式。它适合知识量较大、更新频繁且需要来源管理的场景，但不自动保证检索结果权威、完整、适用或最新。见第 4、5、10 章。

微调（Fine-tuning）

在基础模型上使用特定数据继续训练的技术方法，常用于调整输出风格、格式或特定模式。它不同于实时知识更新；是否适合、如何评测及如何处理训练数据，应由用例、风险、成本和维护能力决定。

Shadow AI（影子 AI）

员工使用未经组织批准、未纳入正式控制或不符合既定数据/权限边界的 AI 工具、账号或工作方式处理工作任务的现象。其风险取决于实际数据、工具、权限、合同、地区和业务影响，不应仅以是否使用个人账号作唯一判断。

知识 Owner

对某项知识资产的权威来源、版本、生效范围、更新、冲突处理和影响分析承担明确角色的角色。知识 Owner 可以是个人或经授权的团队；复核频率应与变化速度、用例影响和组织制度相匹配。见第 5、12 章。

动态事实卡

用于记录模型、端点、工具、数据处理、权限、价格、地区、弃用、退出或其他易变化外部条件的受控记录。事实卡应包含来源、适用范围、核验日期、Owner、变化触发器和关联用例；它不替代内部评测、风险审查或发布决定。见 facts/模型与工具动态事实卡登记册.md。

知识库三层结构

本手册建议的一种知识组织方式：基础层保存权威业务规则与文档；示例层保存经审查的成功、失败或边界案例；反馈层保存运行中发现的问题与改进信号。是否采用三层结构应由知识规模、变更频率和使用场景决定。见第 5 章。

三、工作流与验证

可复现工作流

相对于单次生成的工作方式，工作流将任务边界、输入输出、验证、责任、版本和回退等要素明确化，使不同人员能够在已定义条件下重复执行、检查和改进。其控制强度应与用例风险相称。见第 4 章。

最小闭环

在有限范围内验证一个用例是否具备业务价值、质量控制、人工责任和回退能力的最小运行单元。它不以固定时长定义，而应覆盖足以代表目标任务和关键边界的样本、验证与决策。见第 6 章。

Prompt 模板

将角色、任务目标、规则、输出格式和参考示例固化为可复用结构的提示词资产。Prompt 是 Skill 或工作流的一个受控组件；它本身不等于可运营能力，也不应替代知识、验证、责任或回退机制。

Skill（能力单元）

针对一类重复业务任务的可运营能力包。它可以包含输入输出契约、Prompt、知识、工具、验证、人工控制、回退、Owner、版本和运行指标，并可被团队发现、调用、测试、授权、观测和退役。Skill 不是某个平台专有功能的同义词，也不只是更长的提示词。见第 4 章和附录 A。

工作流合约（Workflow Contract）

对正式工作流或 Skill 的业务目标、适用范围、输入输出、质量标准、人工控制、责任、版本、指标、依赖和回退进行统一定义的文档。它支持交接、评测、变更和审计。

Agent 运行合约（Agent Runtime Contract）

对 Agent 的业务目标、禁止事项、自主等级、可调用 Skill、工具权限、合法状态、预算与熔断、审批、接管、责任和日志要求作出的共同约定。它将“能做什么、不能做什么”转化为可执行的控制。

Golden Set（黄金评测集）

为用例维护的一组已审查样本，用于比较候选与稳定版本，并覆盖正常、边界、历史失败、异常或转人工等行为。Golden Set 的样本、期望行为和适用范围应随知识、流程和风险变化更新。

Rubric（评分量表）

将质量要求拆解为可观察、可解释、可复核标准的评测工具。它可以由人工、规则或受控模型评测辅助使用，但评分结论应保留样本、版本、理由和适用边界。

验证清单 (Validation Checklist)

在输出采用、发送、写入或阶段提升前逐项核对的质量和控制在检查表。不同用例的清单不同；关键错误、例外或不确定情形应触发修改、转人工、回退或升级，而不是只追求勾选数量。

回退路径

预先定义的异常处理方式，例如使用上一稳定版本、转人工、缩小功能、停止自动动作或终止流程。有效回退不仅需要文档，还需要明确的权限、接棒人、人工备用和演练证据。

Runbook (运行手册)

面向实际执行者的操作资产，用于说明健康信号、依赖、暂停与升级权、人工备用、回退、恢复验证和证据保全方式。见第 14 章与附录 A 第 44 节。

四、评测、风险与治理

一次通过率

在约定统计范围内，一次性通过验证清单的任务比例。其定义必须说明验证版本、允许修改范围、排除规则和任务边界；它不等于事实完全正确、业务采用或风险可接受。指标解释见附录 B。

采用率

在约定统计范围内，最终被业务采用，或在允许修改范围内被采用的输出比例。采用率应与质量、任务边界、审核负担、知识时效和使用者反馈一起解释，不应套用统一目标值。

上下文债务与知识债务

随着使用增加而累积的隐性负担。上下文债务表现为 Prompt、规则或例外不断堆积并相互冲突；知识债务表现为来源、版本、适用范围或冲突处理缺失。两者都可能降低可维护性，应通过资产重组、知识治理、回归与复盘逐步处理。

版本管理

对 Prompt、Skill、检查清单、知识、工作流、Agent 合约、评测和发布资产进行编号、变更说明、影响分析和可定位记录的机制。保留、归档和回退策略应依据业务、审计、数据和运行要求确定；不应使用固定天数替代组织政策。

问题升级路径

预先定义在何种情形下由谁接收、判断、处理、通知和关闭问题的机制。触发条件、响应目标、替补人和证据要求应与用例关键性、事件等级和组织流程相匹配。见第 13、14 章。

风险初筛与 AI 影响评估 (AIA)

风险初筛用于依据业务影响、数据、对外或写入动作、自主性、回退和控制能力确定用例的初始控制强度。AIA 用于进一步说明受影响对象、数据和知识、可能不利影响、控制、残余风险、人工接管和证据。它们是内部治理工具，不替代适用的法律、行业或安全评估。

RACI

用于明确“负责执行、最终负责、提供咨询、被告知”的责任分配方式。本书使用的最小 RACI 应与业务 Owner、知识 Owner、技术 Owner、风险角色、审核者和接棒角色相连接。具体角色名称可随组织调整。

五、案例与证据状态

方法示例

为解释模板字段、控制链或决策方式而设计的示例。方法示例可以包含虚构、脱敏或抽象化场景；除非明确链接到受控证据，不应被理解为特定组织已经实现的生产结果。

运行证据

支持用例阶段判断的内部记录，例如经批准的样本、审核结论、Golden Set、回归报告、发布登记、健康卡、事件记录、演练和接棒记录。运行证据需要说明版本、范围、时间、Owner 和存放位置。

试点证据包

将用例立项、风险、工作流、评测、发布、运行和移交资产集中组织的文件包。evidence/ 目录中的两个证据包已明确标注待现场验证的项目；在缺少真实样本、审核、配置和业务确认时，不应视为验收结论。

术语如有遗漏、冲突或定义不适用，应通过团队治理机制提出修订。组织内部推广时，可引用本表作为共同语言，但仍应根据实际业务、制度和专业要求确定最终定义与责任。

附录 G AI Failure Casebook（故障与失败案例集）

本附录是一个可持续维护的故障模式库，用于沉淀跨团队可复用的学习，而不是替代事件响应、合规通知、证据保全或责任认定。

与第 16 章的完整方法情景不同，本案例库聚焦技术、知识、流程、权限与运行中的具体故障模式。每个条目以“适用条件—可观察信号—可能根因—受控处置—复验要点”组织，帮助团队在遇到类似问题时提出更准确的问题。

证据与隐私边界：事件的原始时间线、配置、日志、数据、人员与决策记录，应先使用附录 A 第 45 节的事件记录与无责复盘模板，在受控位置保存。只有在完成去标识化、必要审批和复用价值评估后，才应将抽象故障模式纳入本库。除非条目明确链接到受控证据或公开来源，以下情节、数值和技术组合均为教学性或抽象化示例，不代表特定组织的真实事件或通用发生率。

公开案例映射（非因果归因）

下表将本库的抽象故障模式与附录 D 已登记的公开案例建立阅读入口。映射只说明某案例可以帮助提出哪些控制问题；它**不**宣称该公开事件已经证实本库列出的全部根因，也不替代对本组织的事件调查。

抽象故障模式	可参阅的公开案例	可以追问的控制问题
条件约束在变更后失效	CA-001、CA-002	权威知识、适用范围、知识版本、来源定位、升级和纠错是否已受控？
多步骤 Agent 的异常调用与成本失控	CA-006	破坏性动作是否被最小权限、隔离、独立授权、可恢复备份和演练约束？
敏感信息进入未批准工具或通道	CA-003	数据分类、批准路径、受控替代方案、员工培训和事件处置能否形成闭环？

CA-001 至 CA-006 的来源链接、事实状态、适用范围和不可外推事项，见附录 D“公开案例来源登记册”。

案例一：条件约束在变更后失效

- **诊断层面：**任务定义、知识与配置管理。
- **适用情形：**高频、多规则的文本生成，且规则、示例或知识会持续更新。
- **风险说明：**关键禁止事项、适用条件或输出格式可能在多次变更后被遗漏、冲突或错误引用。

1. 可观察信号

- 人工审核发现输出包含不应出现的敏感信息、过期口径或禁止内容。
- 与上一稳定版本相比，Golden Set 中的关键样本出现新的失败类型。
- Prompt、知识或示例不断叠加，但团队无法说明每项规则的来源、优先级和适用范围。

2. 可能根因

- **上下文债务**：例外规则、历史说明和临时补丁不断累积，造成规则冲突或难以维护。
- **知识治理不足**：来源、Owner、版本、生效日期或冲突处理不清，导致旧内容仍被使用。
- **验证覆盖不足**：变更后未使用受影响的正常、边界和历史失败样本回归。

3. 受控处置

1. 按 Runbook 暂停受影响范围，必要时回退到上一稳定资产或人工流程。
2. 保留版本、样本、审核结论和影响范围；不要在未记录证据的情况下直接覆盖旧规则。
3. 由知识 Owner 和 Skill/流程 Owner 清理重复、冲突或无来源规则，明确优先级与适用范围。
4. 对受影响 Golden Set 重新评测；通过回归、发布和观察流程后再恢复或扩大。

4. 复验要点

- 禁止事项和关键边界能否被独立验证，而不是仅靠模型自我声明？
 - 每条关键规则是否有权威来源、Owner、版本与生效范围？
 - 当规则冲突或知识失效时，是否会停止、转人工或升级？
-

案例二：微调后任务适配变窄

- **诊断层面**：技术选型、数据与评测设计。
- **适用情形**：团队希望通过微调改善特定风格、格式或领域模式，并计划扩展到更广泛的请求。
- **风险说明**：训练数据、目标、评测范围或发布条件不足时，候选版本可能只在狭窄样本上表现良好，却在边界任务、非训练分布或安全场景中退化。

1. 可观察信号

- 在训练样本或近似样本上表现良好，但在边界、负例或新问法中出现质量下降。
- 输出过度套用固定话术，无法识别不适用请求或转人工条件。
- 新版本的格式、知识使用、拒答、转人工或基础任务表现，与上一稳定版本存在未解释差异。

2. 可能根因

- **数据分布过窄**：训练或评测样本不能代表实际任务、边界与异常情况。
- **目标不匹配**：用微调解决本应由知识检索、规则、工作流或人工审核处理的问题。
- **评测不足**：缺少稳定版本对照、通用能力检查、风险样本和发布观察。

3. 受控处置

1. 暂停扩大新版本的使用范围，保留稳定版本与人工备用路径。
2. 对训练数据、数据来源、许可、覆盖范围、评测集和目标进行复核；必要时缩小任务边界。
3. 比较基础模型、检索增强、规则/工作流改造与微调等候选方案，不预设某一种方案必然更优。
4. 使用 Golden Set、风险样本和回归报告验证候选版本；通过受控发布后再评估扩大。

4. 复验要点

- 微调目标是否明确，且能用与业务相关的样本证明改进？
 - 知识时效、事实依据和适用范围是否被错误地交给模型参数承担？
 - 边界、转人工、拒答和上一稳定版本对照是否覆盖？
-

案例三：多步骤 Agent 的异常调用与成本失控

- **诊断层面：**Agent 状态、工具权限、预算与运行控制。
- **适用情形：**Agent 可调用多个工具、循环查询或执行状态转换，且任务量、外部依赖或输入质量会波动。
- **风险说明：**空值、异常输入、工具故障、状态判断错误或权限配置不当，可能导致重复调用、超时、成本上升、错误写入或下游拥塞。

1. 可观察信号

- 单任务的调用次数、耗时、成本或重试次数偏离已定义的运行范围。
- 工具返回空值、错误、延迟或不一致数据后，系统仍继续执行同类动作。
- 熔断、接管、日志或审批证据缺失，导致团队无法定位当前状态和影响范围。

2. 可能根因

- **退出路径缺失：**Agent 未明确处理“无结果”“不确定”“工具错误”或“权限不足”的状态。
- **限制不足：**没有依据业务风险设置单任务步骤、时间、预算、并发、重试或写入约束。
- **观测不足：**缺少任务级日志、状态记录、告警、审计和人工接管入口。

3. 受控处置

1. 按事件等级暂停相关权限、任务或自动动作，保全必要日志并确认业务影响。
2. 将异常状态显式化：例如标记为“信息不足”“待人工确认”或“工具不可用”，而不是无限重试。
3. 根据用例风险设置并演练步骤、时间、预算、并发、重试和动作限制；具体数值应来自任务与恢复能力，而非复制固定示例。
4. 在恢复前验证工具返回、权限、人工接管、回退和日志是否可用，并用受影响样本回归。

4. 复验要点

- 每个外部工具调用是否有明确成功、失败、超时和无结果的处理路径？
- 是否能在到达限制前发现异常、停止动作并转交给合适角色？
- 是否能够从日志与证据索引定位版本、输入类别、状态、权限和恢复结论？

案例四：不可信上下文改变任务边界

- **诊断层面：**上下文来源、指令边界与工具调用控制。
- **适用情形：**Agent 或工作流会读取文档、网页、邮件、工单、检索片段或工具返回，并据此继续回答、规划或调用下一步工具。
- **风险说明：**外部或内部内容中可能包含过期、冲突、误导性或试图改变系统行为的文字。若系统把这些内容视为比任务规则、审批或状态机更高的指令，就可能扩大检索、泄露资料、绕过验证或提出不应执行的动作。

1. 可观察信号

- Agent 在处理与任务无关的文本后，突然改变目标、来源范围、工具选择或输出格式。
- 检索片段、附件、网页或工具返回包含“忽略前述规则”“导出全部资料”等指令性文字，系统未将其视为不可信数据。
- 输出或行动依据无法定位到经过批准的来源、任务边界或人工批准记录。

2. 可能根因

- **指令与数据混淆：**没有清楚区分系统规则、任务输入、检索内容、工具返回和人工批准的优先级。

- **来源边界缺失**：上下文包未定义允许/排除来源、返回量、适用范围和异常处理。
- **工具控制断裂**：工具调用只依据模型自然语言计划，没有动作白名单、参数限制或独立审批。

3. 受控处置

1. 立即停止受影响的自动动作、外发或写入；保全任务、来源、上下文、工具调用和审批记录。
2. 将可疑内容隔离为数据，不把其中的操作性文字视为有效指令；必要时转人工判断来源和业务含义。
3. 更新上下文包、工具控制卡和 Agent 运行合约，明确来源白名单、排除来源、数据/指令分离、返回量和停止条件。
4. 用包含提示注入、无关内容、来源冲突、超长返回和异常工具结果的样本回归；通过发布观察后再恢复范围。

4. 复验要点

- 系统是否能展示每个关键结论或行动使用的来源、版本与范围？
 - 不可信内容能否被当作数据处理，而不是覆盖任务规则、审批或状态机？
 - 工具是否仍会在不符合动作白名单、权限和批准条件时被拒绝或转人工？
-

案例五：持久记忆污染、过期或越界复用

- **诊断层面**：状态管理、数据隔离、知识时效与可恢复性。
- **适用情形**：Agent 将跨轮次任务进度、摘要、客户偏好、确认结论或工作笔记保存在持久记忆、向量索引、数据库或会话外状态中。
- **风险说明**：未经确认的推断、过期规则、敏感原文或跨客户信息一旦被写入并在后续任务中读取，可能反复影响输出、造成越权引用或让纠错成本持续扩大。

1. 可观察信号

- 用户或审核者已纠正的内容在后续任务中再次出现，且无法说明读取来源。
- 不同用户、客户、项目或地区的上下文被错误混用。
- 任务状态、摘要或长期记忆与权威来源、当前规则或原始记录不一致。

2. 可能根因

- **写入缺少约束**：将模型推测、完整会话、全量工具返回或敏感原文默认写入长期记忆。
- **隔离与生命周期缺失**：未按用户、客户、项目、区域或数据级别划分读取范围、保留期和删除规则。
- **纠错不可追溯**：记忆缺少来源、版本、Owner、失效和人工纠错入口。

3. 受控处置

1. 暂停受影响记忆的读取和写入，隔离可能污染的范围，保留必要的审计证据。
2. 使用记忆合约确定哪些内容是已确认事实、任务状态、待核验假设或禁止保存的信息；清理、纠正或按政策删除不符合要求的内容。
3. 恢复前验证隔离、来源定位、过期处理、人工纠错、删除和回退是否可用；必要时回到短期任务状态或人工记录。
4. 对涉及高影响输出、对外沟通或跨系统动作的任务，使用受影响样本检查记忆变化是否导致质量、权限或行动退化。

4. 复验要点

- 每条可用于关键结论的记忆能否定位到来源、写入原因、版本、Owner 和失效条件？

- 事实、待核验假设和工作笔记是否被明确区分，并采用不同读取与保留规则？
 - 是否能按用户、客户、项目或区域隔离、纠错、删除和恢复，而不影响无关任务？
-

案例提交与维护

Failure Casebook 应作为学习资产维护。建议提交者先完成事件记录、无责复盘、必要的审批与去标识化，再提交可公开或可跨团队复用的抽象条目。提交内容不应包含客户、个人、账号、密钥、内部地址、未公开配置、原始日志或其他敏感信息。

如需提交条目，可按以下结构发送至 jacejacejia@gmail.com：

- 场景边界：说明业务任务，并移除客户、人员和敏感数据。
- 事件等级与诊断层面：参考第 14 章和第 2 章。
- 可观察信号：记录确认过的异常，不写入推测性结论。
- 已采取的停止、转人工或回退动作：仅描述可公开的抽象方式。
- 根因假设与验证：区分已证实事实、待验证假设和证据位置。
- 改进与复验：说明修复、演练或回归方式，以及残余风险和后续 Owner。

维护者应定期复核条目的适用性、敏感性和关联章节。若条目已被新的证据推翻、存在敏感风险或不再具有复用价值，应更新、归档或删除。